

二元选择模型：非参数方法

Binary Choice Models: Nonparametric Methods

Intermediate Econometrics

Jia Chengye

School of Economics
Shandong University of Finance and Economics

Spring 2026

参数方法的局限与非参数思想的提出
条件数学期望与回归函数的非参数解读
经验分布函数与直方图
核密度估计 (Kernel Density Estimation)
Nadaraya–Watson 核回归估计量
局部多项式估计 (Local Polynomial Regression)

非参数推断：置信区间与 Wild Bootstrap
级数方法 (Series Methods)
混合数据、离散核与条件分布
规格检验与二元选择的非参数应用
总结与 S3 预告

参数方法的局限与非参数思想的提出

在上一讲 **LectureS1** 中，我们系统研究了二元选择模型的**参数方法**：

- ▶ **线性概率模型 (LPM)**: $P(Y = 1 | X = x) = x'\beta$
- ▶ **Probit**: $P(Y = 1 | X = x) = \Phi(x'\beta)$
- ▶ **Logit**: $P(Y = 1 | X = x) = \Lambda(x'\beta) = \frac{e^{x'\beta}}{1 + e^{x'\beta}}$

参数方法的共同特征 (Zhou 2013, §1.1) :

1. **函数形式已知**—— $P(Y = 1 | X = x)$ 只差一个**有限维参数** $\beta \in \mathbb{R}^k$;
2. **误差分布已指定**——正态 (Probit)、逻辑 (Logit) 或均匀 (LPM);
3. **收敛速度最优**—— $\sqrt{n}$ 收敛; 标准误可由 Fisher 信息矩阵解析得到;
4. **识别代价**——以「强函数形式假设」换取「快收敛速度」。

本讲的核心问题：如果这些函数形式假设**错了**，会怎样？

动机一：参数设定错误的数学后果 (Caetano Class 1)

假设真实模型是 $Y_i = m(X_i) + u_i$, $E[u_i | X_i] = 0$, 其中 $m(\cdot)$ 是**未知**函数。研究者却假设 $m(x) = x'\beta$ 并使用 OLS / MLE 估计。

错误设定下的渐近结果 (伪真值, pseudo-true value) :

$$\hat{\beta} \xrightarrow{p} \beta^* = \arg \min_{\beta} E[(m(X) - X'\beta)^2]$$

结论: $\hat{\beta}$ 收敛到**最佳线性投影系数**, 而不是真实的 $m(x)$ 。

后果 (依次严重化) :

1. **条件期望估计偏差:** $\hat{m}(x) = x'\hat{\beta} \neq m(x)$;
2. **边际效应估计偏差:** $\partial m / \partial x_j$ 的估计系统性错误;
3. **预测失效:** 在 X 分布尾部预测值可能落在 $[0, 1]$ 之外 (LPM 问题);
4. **统计推断无效:** 所有 t 、 F 、 LR 检验的临界值都不再可用;
5. **政策含义错误:** 反事实预测与异质性分析全部失真。

动机二: Zhou 例 1.1——密度函数的参数设定错误

设总体服从 Weibull 分布 $X \sim \text{Weibull}(k = 1.5, \lambda = 1)$, 真实密度:

$$f(x) = 1.5 x^{0.5} \exp(-x^{1.5}), \quad x > 0.$$

研究者却假设 $X \sim \mathcal{N}(\mu, \sigma^2)$ 并用 $(\bar{X}, S^2)$ 估计参数。

参数方法的失败

用正态分布拟合 Weibull 数据:

- ▶ **对称 vs. 非对称**——正态对称, Weibull 右偏;
- ▶ **支撑区间错配**——正态 $\mathbb{R}$, Weibull $(0, \infty)$;
- ▶ **尾部行为错配**——正态指数衰减, Weibull 按 $\exp(-x^{1.5})$ 衰减;
- ▶ **众数位置错配**——正态在 μ , Weibull 在 $(k-1)^{1/k}/\lambda$ 。

核密度估计的启示:

只要让数据「告诉我们」密度的形状, 而不预先规定形状, 就能避免以上所有错配。

这就是**核密度估计** (kernel density estimation, **KDE**) 的核心动机:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

动机三：Zhou 例 1.2——回归函数的参数设定错误

考虑**非线性回归**：真实 $g(x) = x + 2 \exp(-\sin x)$, $u_i \sim \mathcal{N}(0, 0.5^2)$ 。研究者尝试用多项式 OLS 拟合：

$$\text{Model 1 (线性): } \hat{g}_1(x) = \hat{\alpha}_0 + \hat{\alpha}_1 x,$$

$$\text{Model 2 (二次): } \hat{g}_2(x) = \hat{\alpha}_0 + \hat{\alpha}_1 x + \hat{\alpha}_2 x^2,$$

$$\text{Model 3 (三次): } \hat{g}_3(x) = \hat{\alpha}_0 + \hat{\alpha}_1 x + \hat{\alpha}_2 x^2 + \hat{\alpha}_3 x^3.$$

问题：无论多项式阶数多高，都无法刻画 $g(x) = x + 2 \exp(-\sin x)$ 中 $\sin x$ 带来的周期性振荡。

- ▶ **Model 1：**完全忽略振荡，拟合为单调直线；
- ▶ **Model 2/3：**在有限区间局部近似 $\sin x$ ，但在数据尾部严重偏离；
- ▶ **任何有限阶多项式：** $\sin x$ 的 Taylor 展开是**无穷级数**，有限阶截断必有偏误。

非参数方法的承诺：若 $g(\cdot)$ 光滑，**核回归**（NW 估计量）能够在**不假设任何函数形式**的前提下一致估计 g 。

动机四：Li & Racine——非参数是半参数的基石

方法论谱系 (Li & Racine 2007, Ch.1) :

参数方法

- ▶ 假设强, $\sqrt{n}$ 快
- ▶ 错了就完全错

半参数方法 (单指标、部分线性)

- ▶ $E[Y|X] = G(x'\beta)$, G 未知
- ▶ $\hat{\beta}$ 仍 $\sqrt{n}$, $\hat{G}$ 非参数率

非参数方法 (本讲)

- ▶ $E[Y|X] = m(x)$, 形式完全未知
- ▶ 收敛率慢 $n^{-2/(4+d)}$
- ▶ 是半参数方法的必要构件

为什么先学非参数?

1. **S3 的单指标模型**需要用非参数方法估计链接函数 G ;
2. **Ichimura (1993)** 的 SLS 用核回归估计 $E[Y|x'\beta]$;
3. **Klein-Spady (1993)** 的半参数效率界依赖非参数密度估计;
4. **规格检验** (Härdle-Mammen, Li-Zheng) 比较参数模型与非参数基准。

三讲一体:

S1 参数 $\rightarrow$ S2 非参数 $\rightarrow$ S3 半参数

核心任务：在不假设函数形式的前提下，估计

$$m(x) = E[Y | X = x] \quad \text{以及} \quad f(x) = \text{密度函数}$$

第一部分（引言）

- ▶ §1 参数方法局限与非参数思想
- ▶ §2 条件期望与回归函数

第二部分（密度估计）

- ▶ §3 经验分布函数与直方图
- ▶ §4 核密度估计 (KDE) & 窗宽

第三部分（核回归）

- ▶ §5 Nadaraya–Watson 估计量
- ▶ §6 大样本性质与窗宽选择

第四部分

- ▶ §7 局部多项式估计

第五部分

- ▶ §8 非参数推断（置信区间与 Wild Bootstrap）

第六部分

- ▶ §9 级数方法（Fourier、Hermite、样条）

第七部分

- ▶ §10 扩展：离散 & 混合数据核
- ▶ §11 在二元选择模型中的应用

第八部分

- ▶ §12 总结与 S3 预告

附录

- ▶ 12 个详细证明 (proof-b1 ~ proof-b12)

条件数学期望与回归函数的非参数解读

条件数学期望 (Conditional Expectation)

给定随机变量 Y 和 X , 若 $E[|Y|] < \infty$, 则

$$m(x) \equiv E[Y | X = x] = \int y f_{Y|X}(y | x) dy$$

其中 $f_{Y|X}(y | x) = f_{X,Y}(x, y) / f_X(x)$ 是**条件密度**。

关键性质 (全期望律 / Law of Iterated Expectations, LIE) :

$$E[Y] = E[E[Y | X]] = \int m(x) f_X(x) dx.$$

积分形式（对非参数估计至关重要）：

$$m(x) = \frac{\int y f_{X,Y}(x, y) dy}{f_X(x)} = \frac{E[Y \cdot \mathbb{1}\{X = x\}]}{f_X(x)} \quad (\text{形式记号})$$

这个积分形式**只涉及两个未知物**：联合密度 $f_{X,Y}$ 和边缘密度 f_X 。只要能**非参数地**估计密度，就能**非参数地**估计 $m(x)$ ——这是 NW 估计量的出发点。

回归函数的最优性

定理（条件期望的最小均方误差性质）：在所有 X 的可测函数 $g(\cdot)$ 中， $m(x) = E[Y|X = x]$ 是唯一最小化均方预测误差的函数：

$$m(\cdot) = \arg \min_g E[(Y - g(X))^2].$$

证明梗概：分解 $Y - g(X) = [Y - m(X)] + [m(X) - g(X)]$ ，两项正交（ $E\{[Y - m(X)]h(X)\} = 0$ 对任意 h 成立），故

$$E[(Y - g(X))^2] = E[(Y - m(X))^2] + E[(m(X) - g(X))^2]$$

第一项与 g 无关，第二项取 $g \equiv m$ 时为零。 $\square$

► 完整证明

方法论含义：

- ▶ **参数方法** (OLS、Probit) 事实上解 $\min_{\beta} E[(Y - x'\beta)^2]$ 或 $\min_{\beta} E[(Y - \Phi(x'\beta))^2]$ ；
- ▶ **非参数方法** 直接对 $m(\cdot)$ 求最优——不对形式设限；
- ▶ **正交分解**「偏误 + 方差」的雏形出现在此处——非参数估计的 MSE 分解源自同一思想。

关键事实：当 $Y \in \{0, 1\}$ 时，

$$E[Y | X = x] = 0 \cdot P(Y = 0 | X = x) + 1 \cdot P(Y = 1 | X = x) = P(Y = 1 | X = x).$$

估计条件期望 $\equiv$ 估计条件概率。

参数方法 (LectureS1) :

$$P(Y = 1 | X = x) = \Phi(x'\beta) \quad \text{Probit}$$

$$P(Y = 1 | X = x) = \Lambda(x'\beta) \quad \text{Logit}$$

$$P(Y = 1 | X = x) = x'\beta \quad \text{LPM}$$

代价：若链接函数错， $\hat{\beta}$ 不一致。

非参数方法 (本讲) :

$$P(Y = 1 | X = x) = m(x)$$

形式完全自由—— $m(x)$ 可以是 S 形、倒 U 形、分段常数或周期函数。

代价：收敛率 $n^{-2/(4+d)}$ ，维数诅咒。

两种范式的权衡：偏误（错设风险） vs. 方差（收敛速度）。 半参数方法 (S3) 尝试在两者之间寻找最优折中。

参数与非参数回归的系统对比

维度	参数方法	非参数方法
函数形式	预先指定 ($m(x) = x'\beta$)	数据驱动 ($m(x)$ 未知但光滑)
未知量	有限维 $\beta \in \mathbb{R}^k$	无穷维 $m(\cdot) \in \mathcal{F}$
识别假设	强 (函数形式正确)	弱 (光滑性 + 矩条件)
收敛速度	$\sqrt{n}$	$n^{-2/(4+d)}$ ($d = \dim X$)
渐近分布	正态, 解析协方差	正态 (需欠平滑) 或 bootstrap
可解释性	系数即边际效应	需计算 $\hat{m}'(x)$
维数诅咒	无	有 ($d \uparrow \Rightarrow$ 率急剧恶化)
外推能力	可外推到数据支撑外	无法外推 (需数据附近)
计算成本	低 (一次优化)	高 (每点都是加权平均)

黄金法则 (Hansen 2022, Ch.19) : 参数方法在**设定正确**时最优, 非参数方法在**设定未知**时最稳健。
实务中常并用: 以非参数为「无偏基准」检验参数模型。

收敛速度的直觉：参数 vs 非参数

参数收敛速度 $\sqrt{n}$:

$$\hat{\beta} - \beta = O_p(n^{-1/2})$$

为什么快? 所有 n 个观测值都在估计同一个参数 β ——每个 X_i 都携带 β 的信息。

非参数收敛速度 $n^{-2/(4+d)}$:

$$\hat{m}(x_0) - m(x_0) = O_p(n^{-2/(4+d)})$$

为什么慢? 只有 X_i 靠近 x_0 的观测才对 $m(x_0)$ 有用——有效样本量约为 nh^d 。

收敛速度的直觉：等价样本量表

维数 d	收敛率	n = 100 等价参数样本量	n = 1000 等价参数样本量	n = 10000 等价参数样本量
1	$n^{-2/5}$	≈ 6.3	≈ 15.8	≈ 39.8
2	$n^{-1/3}$	≈ 4.6	≈ 10.0	≈ 21.5
4	$n^{-1/4}$	≈ 3.2	≈ 5.6	≈ 10.0
8	$n^{-1/6}$	≈ 2.2	≈ 3.2	≈ 4.6

维数诅咒 (Curse of Dimensionality, Bellman 1961): d 每增加一维，达到同等精度所需样本量指数级增长——这驱动了 S3 中半参数方法（如单指标模型把 d 维问题化约为 1 维）的发展。

经验分布函数与直方图

经验分布函数 (Empirical Distribution Function)

EDF (Zhou 2013, §2.1)

给定 i.i.d. 样本 $\{X_1, \dots, X_n\}$, **经验分布函数**定义为

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}\{X_i \leq x\}.$$

即「 $\leq x$ 的观测所占比例」。

EDF 的大样本性质:

1. **无偏性**: $E[\hat{F}_n(x)] = F(x)$ (因 $E[\mathbb{1}\{X_i \leq x\}] = F(x)$) ;
2. **相合性**: $\hat{F}_n(x) \xrightarrow{P} F(x)$ (LLN) ;
3. **渐近正态**: $\sqrt{n}[\hat{F}_n(x) - F(x)] \xrightarrow{d} \mathcal{N}(0, F(x)[1 - F(x)])$;
4. **均匀相合性 (Glivenko–Cantelli 定理)**: $\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0$.

EDF: 为什么比密度估计收敛快?

EDF 是「分布函数层面」的非参数估计。它以 $\sqrt{n}$ 速度收敛——**为什么比密度估计快?** 因为 $F(x)$ 是**积分**过的量 (平滑), 而 $f(x) = F'(x)$ 需要**微分**——微分操作放大噪声, 因此密度估计本质上更困难。

一般规律: 估计**积分量** (CDF、矩、分位数) 比估计**微分量** (密度、导数) 更易。这个「积分赢, 微分输」的模式将贯穿整个非参数理论。

尝试 1： 直接对 $\hat{F}_n$ 求导得到 $\hat{f}_n$ 。

$$\hat{f}_n(x) \stackrel{?}{=} \frac{d}{dx} \hat{F}_n(x).$$

问题： $\hat{F}_n$ 是**阶梯函数**（每个 X_i 处跳 $1/n$ ），导数几乎处处为 0，在跳点为 $+\infty$ ——**毫无信息**。

尝试 2： 用**有限差分**近似：

$$\hat{f}_n(x) \approx \frac{\hat{F}_n(x+h) - \hat{F}_n(x-h)}{2h} = \frac{\#\{X_i \in (x-h, x+h]\}}{2nh}.$$

上式正是**直方图思想**的数学表达：用局部频率近似局部密度。引入了一个关键参数 h ——**窗宽 (bandwidth)**。

- ▶ h 太小 $\Rightarrow$ 窗口内样本少 $\Rightarrow$ 方差大；
- ▶ h 太大 $\Rightarrow$ 窗口覆盖多种 x $\Rightarrow$ 偏误大。

窗宽选择将贯穿整个非参数估计理论。

直方图估计量 (Histogram): 定义

直方图

将 X 的取值范围分为若干等宽的**桶 (bin)**，每个桶宽为 h ，中心为 b_j 。定义直方图估计量：

$$\hat{f}_{\text{hist}}(x) = \frac{1}{nh} \sum_{i=1}^n \mathbb{1}\{X_i \in B_j\}, \quad \text{其中 } x \in B_j.$$

即「 x 所在桶内的样本数 / (nh) 」。

等价表示 (指示核)： $\hat{f}_{\text{hist}}(x) = \frac{1}{nh} \sum_{i=1}^n \mathbb{1}\left\{\frac{X_i - x}{h} \in [-1/2, 1/2)\right\}.$

直方图的三个根本缺陷 (Caetano Class 1, p.3; Zhou §2.2) :

1. **同权问题**—— “there is no reason why we should require that all observations between $x - h$ and $x + h$ have the same weight.” 靠近 x 的 X_i 应比远处的 X_i 权重更大;
2. **不连续性**—— $\hat{f}_{\text{hist}}$ 在桶边界跳跃, $\hat{f}'$ 不存在;
3. **桶定位敏感**——桶的起点微小平移可能改变形状 (众数位置、峰值高度) 。

直方图的偏误与方差

考虑 x 位于桶 $B_j = [b_j - h/2, b_j + h/2)$ 内的情况。

偏误 (Bias): 在桶中心做 Taylor 展开,

$$E[\hat{f}_{\text{hist}}(x)] = \frac{1}{h} \int_{b_j - h/2}^{b_j + h/2} f(u) du = f(x) + \underbrace{(b_j - x)f'(x)}_{\text{依赖 } x \text{ 在桶内位置}} + O(h^2).$$

对 x 平均: $\text{Bias}(x) = O(h)$ (**比 KDE 的 $O(h^2)$ 差**)。

方差 (Variance): $n_j = \sum_i \mathbb{1}\{X_i \in B_j\} \sim \text{Binomial}(n, p_j)$, 其中 $p_j \approx hf(b_j)$:

$$\text{Var}[\hat{f}_{\text{hist}}(x)] = \frac{p_j(1 - p_j)}{n^2 h^2} \approx \frac{f(x)}{nh} \quad (h \rightarrow 0).$$

IMSE (积分均方误): $\text{IMSE} = \int [\text{Bias}^2 + \text{Var}] dx = O(h^2) + O(\frac{1}{nh})$.

最优窗宽: $h^* \propto n^{-1/3}$, 最优 $\text{IMSE} = O(n^{-2/3})$ 。

对比 KDE (下一节): 最优 $\text{IMSE} = O(n^{-4/5})$ ——**收敛更快**。原因: KDE 用光滑核函数消除了桶边界效应, 偏误从 $O(h)$ 降为 $O(h^2)$ 。

核密度估计 (Kernel Density Estimation)

从直方图到 KDE: Step 1 (均匀核重写)

思路 (Rosenblatt 1956; Parzen 1962) : 用光滑权重函数 $K(\cdot)$ 替代直方图的硬指示权重。

Step 1: 直方图可以重写为

$$\hat{f}_{\text{hist}}(x) = \frac{1}{nh} \sum_{i=1}^n K_0\left(\frac{x - X_i}{h}\right), \quad K_0(u) = \mathbb{1}\{|u| \leq 1/2\}.$$

这里 K_0 是**均匀核**——在窗口内同权，窗口外零权。

从直方图到 KDE: Step 2 (光滑核替换)

Step 2: 为解决「同权问题」，把 K_0 替换为**连续光滑**的核函数 K ，满足：

- ▶ $K(u) \geq 0$ (非负, 保证 $\hat{f} \geq 0$) ;
- ▶ $\int K(u) du = 1$ (归一化, 保证 $\hat{f}$ 积分为 1) ;
- ▶ $K(u) = K(-u)$ (对称, $\int uK(u)du = 0$) ;
- ▶ $|u|$ 越大 $K(u)$ 越小 (远处权重小) 。

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right).$$

这就是**核密度估计量 (KDE)**。

核函数 (Kernel) — Li & Racine §1.4

函数 $K: \mathbb{R} \rightarrow \mathbb{R}$ 是二阶核当满足:

$$(K1) \quad \int K(u) \, du = 1 \quad (\text{归一化})$$

$$(K2) \quad \int u K(u) \, du = 0 \quad (\text{对称} \Rightarrow \text{一阶矩为零})$$

$$(K3) \quad \kappa_2 \equiv \int u^2 K(u) \, du > 0, \text{ 有限} \quad (\text{二阶矩存在})$$

$$(K4) \quad R(K) \equiv \int K(u)^2 \, du < \infty \quad (\text{粗糙度有限})$$

κ_2 的作用：决定 KDE 偏误的常数项—— $\text{Bias} = \frac{h^2 \kappa_2}{2} f''(x) + o(h^2)$ 。

$R(K)$ 的作用：决定 KDE 方差的常数项—— $\text{Var} = \frac{R(K)f(x)}{nh} + o\left(\frac{1}{nh}\right)$ 。

高阶核 ($\int u^j K du = 0$ for $j = 1, \dots, q-1$, $\int u^q K \neq 0$) 可降低偏误至 $O(h^q)$ ，但会导致 $\hat{f}$ 可能为负——实务中极少使用。

名称	表达式 $K(u)$	支撑	$\kappa_2 = \int u^2 K$	$R(K) = \int K^2$
均匀	$\frac{1}{2} \mathbb{1}\{ u \leq 1\}$	$[-1, 1]$	$1/3$	$1/2$
三角	$(1 - u) \mathbb{1}\{ u \leq 1\}$	$[-1, 1]$	$1/6$	$2/3$
Epanechnikov	$\frac{3}{4} (1 - u^2) \mathbb{1}\{ u \leq 1\}$	$[-1, 1]$	$1/5$	$3/5$
双重权	$\frac{15}{16} (1 - u^2)^2 \mathbb{1}\{ u \leq 1\}$	$[-1, 1]$	$1/7$	$5/7$
三重权	$\frac{35}{32} (1 - u^2)^3 \mathbb{1}\{ u \leq 1\}$	$[-1, 1]$	$1/9$	$350/429$
高斯	$(2\pi)^{-1/2} \exp(-u^2/2)$	$\mathbb{R}$	1	$(2\sqrt{\pi})^{-1}$

实用权衡:

- ▶ **有限支撑** (Epanechnikov、双重权) —— 计算快, 边界清晰;
- ▶ **无限支撑** (高斯) —— $\hat{f}$ 光滑到所有阶, 但数值慢;
- ▶ **光滑度** —— 双重权比 Epanechnikov 光滑, 估计量二阶可导;
- ▶ 实证中**核的选择影响小** (< 5% 效率损失), **窗宽选择影响大** —— 先关心 h 。

定理 (Epanechnikov 1969; Hodges–Lehmann 1956) : 在所有满足 (K1)–(K4) 的二阶对称核中,

$$K^*(u) = \frac{3}{4}(1 - u^2)\mathbb{1}\{|u| \leq 1\}$$

最小化渐近积分均方误 AMISE 的主导常数: $\min_K C(K)$, 其中 $C(K) = \kappa_2^{2/5} \cdot R(K)^{4/5}$.

直觉: κ_2 控制偏误, $R(K)$ 控制方差——最优核平衡两者。Epanechnikov 在约束 $\int K = 1$ 和 $\int u^2 K = \kappa_2$ 下, **最小化** $R(K)$ (变分法求解)。

► 证明

Epanechnikov 核的最优性：相对效率

相对效率 (relative efficiency): 若 K_{Ep}^* 定义效率为 1, 其他核的效率为

$$\text{eff}(K) = \frac{C(K_{Ep}^*)}{C(K)}.$$

核	相对效率
Epanechnikov	1.000
Biweight (Quartic)	0.994
Triweight	0.987
Gaussian	0.951
Uniform	0.930

最大效率损失约 7%——**核的选择远不如窗宽选择重要。** Zhou (2013, §2.3) 建议：「窗宽决定质量，核函数决定风格。」

核密度估计量的正式定义

核密度估计量 (Kernel Density Estimator, KDE)

给定 i.i.d. 样本 $\{X_1, \dots, X_n\} \sim f$, 核函数 K 满足 (K1)–(K4), 窗宽 $h > 0$, **Rosenblatt-Parzen 估计量**为

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) = \frac{1}{n} \sum_{i=1}^n K_h(x - X_i)$$

其中 $K_h(u) \equiv \frac{1}{h}K(u/h)$ 是**尺度化核**。

加权平均解读: $\hat{f}_h(x)$ 是 n 个「核包 (kernel bumps)」的平均:

- ▶ 每个观测 X_i 贡献一个以 X_i 为中心、宽度 $\propto h$ 的核包 $K_h(\cdot - X_i)/n$;
- ▶ 观测密集区 $\Rightarrow$ 核包重叠多 $\Rightarrow \hat{f}$ 大;
- ▶ 观测稀疏区 $\Rightarrow$ 核包少 $\Rightarrow \hat{f}$ 小。

两个极限情形：

- ▶ $h \rightarrow 0$ ：核包退化为 Dirac 点 $\delta(x - X_i)$ ， $\hat{f}_h$ 变成原始数据尖峰——**过拟合**；
 - ▶ $h \rightarrow \infty$ ：所有核包展平为近常数， $\hat{f}_h \approx 1/(nh) \sum K(0) \rightarrow 0$ ——**过平滑**。
- 合理的 h 在中间——下面几张幻灯片专注于**如何选** h 。

KDE 偏误的推导: Taylor 展开

设 $X_i \stackrel{\text{iid}}{\sim} f$, f 二阶连续可导。计算

$$E[\hat{f}_h(x)] = E\left[\frac{1}{h}K\left(\frac{x-X}{h}\right)\right] = \int \frac{1}{h}K\left(\frac{x-u}{h}\right)f(u)du.$$

换元 $u = x - hv$, $du = -h dv$:

$$E[\hat{f}_h(x)] = \int K(v)f(x-hv)dv.$$

Taylor 展开 $f(x-hv) = f(x) - hvf'(x) + \frac{(hv)^2}{2}f''(x) + o(h^2)$ 并代入:

$$\begin{aligned} E[\hat{f}_h(x)] &= f(x) \underbrace{\int K(v)dv}_{=1} - hf'(x) \underbrace{\int vK(v)dv}_{=0} \\ &\quad + \frac{h^2}{2}f''(x) \underbrace{\int v^2K(v)dv}_{=\kappa_2} + o(h^2). \end{aligned}$$

$$\text{Bias}[\hat{f}_h(x)] = \frac{h^2}{2} \kappa_2 f''(x) + o(h^2).$$

解读:

- ▶ 偏误与 h^2 成正比—— $h \uparrow \Rightarrow$ 偏误大;
- ▶ 偏误与 $f''(x)$ 成正比——曲率大处 (峰、谷) 偏误最严重;
- ▶ 在 $f'' > 0$ (U 形) 处向上偏, $f'' < 0$ (倒 U) 处向下偏——**峰值被压平, 谷值被抬高。**

▶ 附录证明

$$\text{Var}[\hat{f}_h(x)] = \frac{1}{n} \text{Var} \left[\frac{1}{h} K \left(\frac{x - X}{h} \right) \right] = \frac{1}{n} \left\{ \mathbb{E} \left[\frac{1}{h^2} K^2 \left(\frac{x - X}{h} \right) \right] - (\mathbb{E}[\cdots])^2 \right\}.$$

主项： (换元 $v = (x - u)/h$)

$$\mathbb{E} \left[\frac{1}{h^2} K^2 \left(\frac{x - X}{h} \right) \right] = \frac{1}{h} \int K^2(v) f(x - hv) dv = \frac{f(x)}{h} \int K^2(v) dv + O(1).$$

次项 $(\mathbb{E}[\cdots])^2 = (f(x) + O(h^2))^2 = O(1)$, 与主项 $O(1/h)$ 相比可忽略。

$$\text{Var}[\hat{f}_h(x)] = \frac{R(K) f(x)}{nh} + o\left(\frac{1}{nh}\right).$$

解读：

- ▶ 方差与 $(nh)^{-1}$ 成正比——**有效样本量** $nh \rightarrow \infty$ 方差才消失；
- ▶ 方差与 $f(x)$ 成正比——密度高处估计更精确（更多邻近观测）；
- ▶ 方差与 $R(K)$ 成正比——「粗糙」的核方差更大。

逐点均方误差 (Pointwise MSE):

$$\text{MSE}(x) = \text{Bias}^2 + \text{Var} = \frac{h^4}{4} \kappa_2^2 [f''(x)]^2 + \frac{R(K)f(x)}{nh} + o(h^4) + o\left(\frac{1}{nh}\right).$$

积分均方误差 (IMSE): 对 x 积分,

$$\text{IMSE}(h) = \int \text{MSE}(x) dx = \frac{h^4}{4} \kappa_2^2 R(f'') + \frac{R(K)}{nh} + \text{高阶项},$$

其中 $R(f'') = \int [f''(x)]^2 dx$ 衡量密度的**粗糙度** (振荡越多, $R(f'')$ 越大)。

渐近 IMSE (AMISE):

$$\text{AMISE}(h) = \underbrace{\frac{h^4}{4} \kappa_2^2 R(f'')}_{\text{偏误}^2} + \underbrace{\frac{R(K)}{nh}}_{\text{方差}}$$

偏误-方差权衡在此处以完全解析的形式呈现:

- ▶ $h \uparrow \Rightarrow$ 偏误项 $\uparrow$, 方差项 $\downarrow$;
- ▶ $h \downarrow \Rightarrow$ 偏误项 $\downarrow$, 方差项 $\uparrow$;
- ▶ **最优** h^* 使两项平衡——见下一张幻灯片。

最优窗宽的推导与 $n^{-1/5}$ 速率

一阶条件：对 $\text{AMISE}(h)$ 求 h 的导数并令为零：

$$\frac{d}{dh} \text{AMISE}(h) = h^3 \kappa_2^2 R(f'') - \frac{R(K)}{nh^2} = 0.$$

解得：

$$h_{\text{AMISE}}^* = \left[\frac{R(K)}{\kappa_2^2 R(f'')} \right]^{1/5} n^{-1/5}.$$

代入 AMISE ：

$$\text{AMISE}(h^*) = \frac{5}{4} [\kappa_2^2 R(f'') R(K)^4]^{1/5} n^{-4/5}.$$

三个关键含义：

1. **最优窗宽速率** $h^* \propto n^{-1/5}$ —— n 越大， h^* 越小（核包越窄）；
2. **最优 IMSE 速率** $n^{-4/5}$ ——**比参数 n^{-1} 慢**，但是可达的最快非参数速率；
3. **实际不可用**： h^* 依赖未知的 $R(f'')$ ——需要实用替代方案。

思路 (Silverman 1986) : **假设** f 是 $\mathcal{N}(\mu, \sigma^2)$, 计算 $R(f'')$ 的解析值:

$$R(f'') = \int [f''(x)]^2 dx = \frac{3}{8\sqrt{\pi} \sigma^5}.$$

代入最优窗宽公式 (高斯核 $\kappa_2 = 1$, $R(K) = 1/(2\sqrt{\pi})$) :

$$h_{\text{Normal}}^* = \left[\frac{4}{3} \right]^{1/5} \sigma n^{-1/5} \approx 1.06 \sigma n^{-1/5}.$$

Silverman 拇指法则 (ROT): 定义与优劣

Silverman 拇指法则 (ROT)

$$\hat{h}_{\text{ROT}} = 1.06 \cdot \min \left\{ \hat{\sigma}, \frac{\text{IQR}}{1.34} \right\} \cdot n^{-1/5}.$$

其中 $\hat{\sigma}$ 是样本标准差, IQR 是四分位距, 1.34 是标准正态 IQR。取 min 使法则对厚尾/偏态更稳健。

优点: 极简单, 无需迭代; 实务中常作为其他方法的**初始值**。

缺点: 若真实 f 远离正态 (多峰、厚尾、非对称), $\hat{h}_{\text{ROT}}$ **系统性过大**——倾向**过平滑**。
Zhou (§2.4) 将此称为「正态参考法的危险」。

插入法 (Plug-In Bandwidth): 两阶段构造

思路 (Sheather & Jones 1991) : 既然 h^* 依赖未知 $R(f'')$, 就**非参数地**估计 $R(f'')$, 再「插入」公式。

两阶段插入法

Stage 1: 用**先导窗宽** g 估计 $\hat{f}_g''(x)$, 得

$$\widehat{R(f'')} = \int [\hat{f}_g''(x)]^2 dx.$$

Stage 2: 代入最优窗宽公式,

$$\hat{h}_{PI} = \left[\frac{R(K)}{\kappa_2^2 \widehat{R(f'')}} \right]^{1/5} n^{-1/5}.$$

Sheather-Jones 方法使用迭代求解保证 $g = g(h)$ 一致。

性质 (Sheather 2004) :

- ▶ **理论最优**: $\hat{h}_{PI}/h^* \xrightarrow{P} 1$, **渐近一致**;
- ▶ **实务表现**: 在双峰、偏态分布下明显优于 ROT;
- ▶ **软件实现**: R 中 `bw.SJ()`; Stata 中 `kdensity, bwidth(sj)`; Python 中 `statsmodels.nonparametric.KDEUnivariate`;
- ▶ **推荐**: Sheather-Jones 插入法是实务**首选**。

思路 (Rudemo 1982; Bowman 1984) : 直接最小化 IMSE 的样本估计。

IMSE 展开:

$$\text{IMSE}(h) = E \int [\hat{f}_h(x) - f(x)]^2 dx = E \int \hat{f}_h^2 - 2E \int \hat{f}_h f + \int f^2.$$

第三项 $\int f^2$ 与 h 无关。第一项直接计算: $\int \hat{f}_h^2 dx$ 。第二项用**留一法 (leave-one-out)**估计:

$$E \int \hat{f}_h(x) f(x) dx = E[\hat{f}_h(X)] \approx \frac{1}{n} \sum_{i=1}^n \hat{f}_{h,-i}(X_i),$$

其中 $\hat{f}_{h,-i}(x) = \frac{1}{(n-1)h} \sum_{j \neq i} K\left(\frac{x-X_j}{h}\right)$ 。

最小二乘交叉鉴定法 (LSCV)

$$CV(h) = \int \hat{f}_h^2(x) dx - \frac{2}{n} \sum_{i=1}^n \hat{f}_{h,-i}(X_i), \quad \hat{h}_{LSCV} = \arg \min_h CV(h).$$

性质：数据驱动、通用（无分布假设）、 $\hat{h}_{LSCV}/h^* \xrightarrow{P} 1$ 。**缺点：**CV 函数常呈**多峰**， $\hat{h}_{LSCV}$ 方差大——实务中波动较剧烈。

窗宽选择方法的对比

特性	Silverman ROT	插入法 (SJ)	LSCV
计算成本	一次性, $O(n)$	中等, 需迭代	需网格搜索
对 f 的假设	正态参考	无 (非参数 $\hat{f}'')$	无
偏好	过平滑	平衡	略欠平滑
稳定性	很稳定	稳定	方差大
一致性	若 f 非正态则 不一致	一致 $\hat{h}/h^* \xrightarrow{P} 1$	一致 $\hat{h}/h^* \xrightarrow{P} 1$
实务推荐	初始值/快速预览	首选	交叉验证; 二选
R 函数	<code>bw.nrd0</code>	<code>bw.SJ</code>	<code>bw.ucv</code>

Zhou (2013, §2.5) 实务建议:

1. 先用 ROT 看「大致形状」;
2. 用 SJ 插入法作为**正式报告**的窗宽;
3. 用 LSCV 做**稳健性检查**——两种方法差异大提示样本存在非标准结构 (多峰、厚尾);
4. 对数据做变换后再估计 (如对右偏数据取对数) 也是常见策略。

(KDE-1) $\{X_i\}$ 是 i.i.d. 样本, 真实密度 f 二阶连续可导。

(KDE-2) 核 K 满足 (K1)–(K4)。

(KDE-3) 窗宽 $h = h_n$ 满足 $h \rightarrow 0$ 且 $nh \rightarrow \infty$ 。

定理 1 (逐点相合性) : 在 (KDE-1)–(KDE-3) 下, $\hat{f}_h(x) \xrightarrow{P} f(x)$ 。

证明梗概: $E[\hat{f}_h(x)] \rightarrow f(x)$ (偏误 = $O(h^2) \rightarrow 0$) , $\text{Var}[\hat{f}_h(x)] \rightarrow 0$ ($= O(1/nh) \rightarrow 0$) 。由 MSE 相合即可。

定理 2 (渐近正态性) : 若另假设 $nh^5 \rightarrow C \in [0, \infty)$,

$$\sqrt{nh} \left[\hat{f}_h(x) - f(x) - \frac{h^2}{2} \kappa_2 f''(x) \right] \xrightarrow{d} \mathcal{N}(0, R(K)f(x)) .$$

偏误不消失！ 在最优窗宽下 ($h \propto n^{-1/5}$, $nh^5 \rightarrow C > 0$)，偏误项**与方差同阶**，不可忽略。这带来两个实务选项：

- ▶ **欠平滑 (undersmoothing)**：选 $h = o(n^{-1/5})$ ，使偏误项 $\sqrt{nh} \cdot h^2 \rightarrow 0$ ；
- ▶ **偏误校正**：估计 $\hat{f}''$ 并减去偏误——构造置信区间时常用。

Nadaraya–Watson 核回归估计量

回忆 §2 的基本关系：

$$m(x) = E[Y | X = x] = \frac{\int y f_{X,Y}(x, y) dy}{f_X(x)}.$$

策略 (Nadaraya 1964; Watson 1964)：用核估计量分别替换分子与分母的密度。

Step 1：对联合密度 $f_{X,Y}(x, y)$ 使用二维乘积核：

$$\hat{f}_{X,Y}(x, y) = \frac{1}{nh_x h_y} \sum_{i=1}^n K\left(\frac{x - X_i}{h_x}\right) K\left(\frac{y - Y_i}{h_y}\right).$$

从条件期望到核回归: Step 2-3

Step 2: 计算**分子**——对 y 积分 (关键: 用零矩性质 $\int yK((y - Y_i)/h_y)dy = h_y Y_i$) :

$$\int y \hat{f}_{X,Y}(x, y) dy = \frac{1}{nh_x} \sum_{i=1}^n K\left(\frac{x - X_i}{h_x}\right) Y_i.$$

Step 3: **分母**是 $\hat{f}_X(x) = \frac{1}{nh_x} \sum_i K((x - X_i)/h_x)$ 。两者相除:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^n K_h(x - X_i) Y_i}{\sum_{i=1}^n K_h(x - X_i)}.$$

Nadaraya–Watson 估计量

给定 i.i.d. 样本 $\{(X_i, Y_i)\}_{i=1}^n$, 核 K 满足 (K1)–(K4), 窗宽 $h > 0$:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^n K\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)} = \sum_{i=1}^n w_i(x) Y_i$$

其中**局部权重**为

$$w_i(x) = \frac{K_h(x - X_i)}{\sum_{j=1}^n K_h(x - X_j)}, \quad \sum_{i=1}^n w_i(x) = 1.$$

三个解读：

1. **局部加权平均**—— $\hat{m}_{NW}(x)$ 是 $\{Y_i\}$ 的凸组合，权重由 X_i 与 x 的距离决定；
2. **局部常数拟合**——下一页显示 NW 等价于「在 x 处用 WLS 拟合常数」；
3. **数据驱动**——完全无需假设 $m(\cdot)$ 的函数形式。

NW 作为局部常数加权最小二乘 (LCLS)

等价优化问题：在点 x 处，求 α 最小化局部加权 SSR：

$$\hat{\alpha}(x) = \arg \min_{\alpha \in \mathbb{R}} \sum_{i=1}^n K_h(x - X_i) [Y_i - \alpha]^2.$$

一阶条件： $\frac{\partial}{\partial \alpha} = -2 \sum_i K_h(x - X_i) [Y_i - \alpha] = 0$ ，解得

$$\hat{\alpha}(x) = \frac{\sum_i K_h(x - X_i) Y_i}{\sum_i K_h(x - X_i)} = \hat{m}_{NW}(x).$$

关键视角： NW = 局部常数拟合。在每一点 x ，用距离 x 近的样本拟合一个**水平线** α ，该水平线即为 $\hat{m}_{NW}(x)$ 。

这一视角为**局部多项式估计** (§7) 做了铺垫：若把「局部常数」替换为「局部线性」或「局部二次」，就得到**Fan & Gijbels (1996)** 的局部多项式估计量——它在边界处表现更优。

NW 估计量的正则性假设

- (NW-1) 样本: $\{(X_i, Y_i)\}_{i=1}^n$ 为 i.i.d. 样本; $E[Y^2] < \infty$ 。
- (NW-2) 回归函数: $m(x) = E[Y | X = x]$ 二阶连续可导。
- (NW-3) 密度: X 的密度 f_X 二阶连续可导, 在 x 处 $f_X(x) > 0$ 。
- (NW-4) 条件方差: $\sigma^2(x) = \text{Var}(Y | X = x)$ 在 x 附近连续。
- (NW-5) 核: K 满足 (K1)–(K4) (二阶、对称)。
- (NW-6) 窗宽: $h = h_n$, $h \rightarrow 0$, $nh \rightarrow \infty$ 。
- (NW-7) 矩条件: $E[|Y|^{2+\delta} | X = x] < \infty$ 对某 $\delta > 0$ (用于 CLT)。
- (NW-8) 等变差序列条件: 针对时间序列数据推广时添加。

这些条件比参数方法严——非参数方法换取更弱的函数形式假设, 代价是更强的光滑性和矩条件。实务中 $f_X(x) > 0$ 是边界问题的根源: 在 X 分布尾部 f_X 很小, NW 的方差爆炸。

NW 偏误: 分子与分母的 Taylor 展开

分子 $\hat{m}_1(x) = \frac{1}{nh} \sum_i K_h(x - X_i) Y_i$, 分母 $\hat{f}_X(x)$ 。用 $Y_i = m(X_i) + u_i$, $E[u_i|X_i] = 0$:

$$E[\hat{m}_1(x)] = E\left[\frac{1}{h} K\left(\frac{x - X}{h}\right) m(X)\right] = \int K(v) m(x - hv) f_X(x - hv) dv.$$

Taylor 展开 (设 $\varphi(u) = m(u)f_X(u)$) :

$$\varphi(x - hv) = \varphi(x) - hv\varphi'(x) + \frac{h^2 v^2}{2} \varphi''(x) + o(h^2).$$

代入并使用 $\int K = 1$, $\int vK = 0$, $\int v^2 K = \kappa_2$:

$$E[\hat{m}_1(x)] = \varphi(x) + \frac{h^2 \kappa_2}{2} \varphi''(x) + o(h^2).$$

类似 $E[\hat{f}_X(x)] = f_X(x) + \frac{h^2 \kappa_2}{2} f_X''(x) + o(h^2)$ 。

比率偏误（一阶近似）：

$$\text{Bias}[\hat{m}_{\text{NW}}(x)] = \frac{h^2 \kappa_2}{2} \left[m''(x) + 2 \frac{m'(x)f'_x(x)}{f_x(x)} \right] + o(h^2).$$

注意括号内的第二项——设计密度项 $\frac{m'f'_x}{f_x}$ 。在 f_x 急剧变化处（分布尾部），NW 偏误被放大。**局部线性估计量将消除这一项 (§7)。**

▶ 完整推导

类似 KDE 方差推导，主项来自 $\text{Var}\left[\frac{1}{nh} \sum K_h(x - X_i)Y_i\right]$ 的 $O(1/nh)$ 部分。使用分解 $Y = m(X) + u$ 并注意 $\text{Var}(u | X) = \sigma^2(X)$ ，可推出：

$$\text{Var}[\hat{m}_{\text{NW}}(x)] = \frac{R(K) \sigma^2(x)}{nh f_X(x)} + o\left(\frac{1}{nh}\right).$$

$$\text{Var}[\hat{m}_{\text{NW}}(x)] = \frac{R(K) \sigma^2(x)}{nh f_X(x)} + o\left(\frac{1}{nh}\right).$$

三个关键因素：

- ▶ **分子** $\sigma^2(x)$ ——条件方差大处估计噪声大；
- ▶ **分母** $f_X(x)$ ——密度低处（尾部）方差爆炸——这是非参数方法**外推能力差**的直接原因；
- ▶ **分母** nh ——**有效样本量**，在点 x 附近约有 $nhf_X(x)$ 个「有效观测」。

定理 3 (NW 逐点相合性) : 在 (NW-1)–(NW-6) 下, 若 $f_X(x) > 0$, 则

$$\hat{m}_{NW}(x) \xrightarrow{p} m(x).$$

证明梗概: 由 $MSE = Bias^2 + Var = O(h^4) + O(1/nh) \rightarrow 0$, 故 $\hat{m}_{NW}(x) \rightarrow m(x)$ 于 L^2 , 因而亦 in probability. $\square$

► 附录

相合性的率: 由最优偏误–方差权衡, 取 $h^* \propto n^{-1/5}$, 得

$$|\hat{m}_{NW}(x) - m(x)| = O_p(n^{-2/5}).$$

这比参数方法的 $O_p(n^{-1/2})$ **慢**——但**无函数形式偏误**。

在多维情形 $d \geq 2$: $h^* \propto n^{-1/(4+d)}$, $|\hat{m} - m| = O_p(n^{-2/(4+d)})$ ——**维数诅咒**显现。

定理 4 (Nadaraya–Watson CLT)：在 (NW-1)–(NW-7) 下，若 $nh^5 \rightarrow C \in [0, \infty)$,

$$\sqrt{nh} \left[\hat{m}_{NW}(x) - m(x) - B_{NW}(x)h^2 \right] \xrightarrow{d} \mathcal{N}(0, V_{NW}(x)),$$

其中

$$B_{NW}(x) = \frac{\kappa_2}{2} \left[m''(x) + 2 \frac{m'(x)f'_X(x)}{f_X(x)} \right], \quad V_{NW}(x) = \frac{R(K)\sigma^2(x)}{f_X(x)}.$$

收敛率： $\sqrt{nh}$ ——比参数 $\sqrt{n}$ 慢，等价于只有 nh 个「有效观测」。

在最优 $h = O(n^{-1/5})$ **下**： $\sqrt{nh} \cdot h^2 = n^{2/5} \cdot n^{-2/5} = O(1)$ ——**偏误项** Bh^2 **不消失**，需欠平滑或偏误校正才能做置信区间。

与 KDE CLT 的完全对应：结构相同 ($\sqrt{nh}$ 速率、 h^2 偏误、 $R(K)$ 与 f_X 进入方差)，只是把「f」换成了「m」、把「f(x)」换成了「 $\sigma^2(x)/f_X(x)$ 」。

► 证明

NW 最优窗宽 (AMSE 最优)

逐点 AMSE:

$$\text{AMSE}(x; h) = B_{\text{NW}}(x)^2 h^4 + \frac{V_{\text{NW}}(x)}{nh}.$$

一阶条件对 h 求导: $4B^2h^3 - V/(nh^2) = 0$, 解得

$$h_{\text{NW}}^*(x) = \left[\frac{V_{\text{NW}}(x)}{4B_{\text{NW}}(x)^2} \right]^{1/5} n^{-1/5}.$$

全局 AMISE 最优窗宽 (对 x 积分加权):

$$h_{\text{global}}^* = \left[\frac{R(K) \int \sigma^2(x) w(x) dx}{\kappa_2^2 \int (m''(x) + 2m'(x)f'_X(x)/f_X(x))^2 f_X^2(x) w(x) dx} \right]^{1/5} n^{-1/5}.$$

与 KDE 的类比: 结构类似, 但涉及两个未知函数 m 和 f_X 及其导数——回归问题比密度估计更复杂。故实务中常用数据驱动交叉验证而不是插入法。

预测误差目标:

$$\text{APE}(h) = E[(Y - \hat{m}_h(X))^2].$$

留一法估计:

$$\text{CV}(h) = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{m}_{h,-i}(X_i)]^2,$$

$$\text{其中 } \hat{m}_{h,-i}(X_i) = \frac{\sum_{j \neq i} K_h(X_i - X_j) Y_j}{\sum_{j \neq i} K_h(X_i - X_j)}.$$

留一法的必要性: 若使用全样本, X_i 在 $\hat{m}_h(X_i)$ 的分母与分子中都占主导 ($K_h(0)$ 最大), 导致**过拟合**——CV 在 $h \rightarrow 0$ 时趋于 0, 失去选择能力。

性质 (Härdle–Marron 1985) :

- ▶ LSCV 是 AMISE 的渐近无偏估计;
- ▶ $\hat{h}_{\text{LSCV}}/h_{\text{AMISE}}^* \xrightarrow{P} 1$ ——一致;
- ▶ CV 函数常多峰——需全局网格搜索;
- ▶ R 函数: `np::npreg()` 自动 LSCV; `locpol::regCVBwSelC()`。

边界偏误问题 (Boundary Bias)

问题：在 X 支撑的**边界点**附近（如 $x = x_{\min} + h$ ），核权重 $K_h(x - X_i)$ 只能使用「单边」样本：

$$\text{Bias}[\hat{m}_{\text{NW}}(x_{\text{boundary}})] = O(h) \quad \text{不再是 } O(h^2).$$

为什么是 $O(h)$ 而不是 $O(h^2)$?

内点处： $\int vK(v)dv = 0$ （对称核），**一阶项消失**，偏误从 h^2 开始。

边界处：积分区间不对称（如 $[0, 1]$ 变成 $[-1, 0]$ ）， $\int_{\text{截断}} vK(v)dv \neq 0$ ——**一阶项不消失**，偏误退化为 h 阶。

后果：在经济应用中，常要估计**分布边缘的效应**（最低收入者、最高年龄段、政策阈值附近）——正是边界偏误最严重之处。

解决方案（按复杂度递增）：

1. 忽略边界（只在内部报告）——简单但浪费数据；
2. **边界核**——修改 K 使其在截断区间保持零阶矩；
3. **局部线性估计** (§7) ——**自动**把偏误降回 $O(h^2)$ ，这是最优方案；
4. **映射变换**——对 X 做映射使支撑为 $\mathbb{R}$ （如对正变量取对数）。

多元回归: $X = (X^{(1)}, \dots, X^{(d)}) \in \mathbb{R}^d$ 。

乘积核 (Product Kernel)

使用每一维单独的核:

$$K\left(\frac{x - X_i}{\mathbf{h}}\right) = \prod_{\ell=1}^d K\left(\frac{x^{(\ell)} - X_i^{(\ell)}}{h_{\ell}}\right).$$

多元 NW 估计量:

$$\hat{m}_{\text{NW}}(x) = \frac{\sum_i \prod_{\ell} K\left(\frac{x^{(\ell)} - X_i^{(\ell)}}{h_{\ell}}\right) Y_i}{\sum_i \prod_{\ell} K\left(\frac{x^{(\ell)} - X_i^{(\ell)}}{h_{\ell}}\right)}.$$

窗宽向量: $\mathbf{h} = (h_1, \dots, h_d)$, 可每维不同; 实务常用**标准化**让 $h_{\ell} \propto \hat{\sigma}_{\ell} \cdot h$ 。

乘积核 vs. 球形核:

- ▶ **乘积核**——计算快，实务首选；各维窗宽可分别选；
- ▶ **球形核**（如多元 Epanechnikov $K(\|u\|)$ ）——各向同性，但窗宽选择困难；
- ▶ 两者的渐近性质**相同阶**——区别仅在常数；
- ▶ **各向异性带宽矩阵推广**： H 为正定矩阵， $K_H(u) = |H|^{-1/2}K(H^{-1/2}u)$ ，可处理相关协变量——Wand & Jones (1995, Ch.4)。

维数诅咒：收敛率恶化

多元 NW 的 AMSE:

$$\text{AMSE}(x) = O(h^4) + O\left(\frac{1}{nh^d}\right).$$

平衡两项: $h^* \propto n^{-1/(4+d)}$, 最优 $\text{AMSE}^* = O(n^{-4/(4+d)})$ 。

d	$h^* \propto$	$\text{MSE}^* \propto$	达到 $\text{MSE} = 0.01$ 所需 n 参数 (n^{-1})	非参数
1	$n^{-1/5}$	$n^{-4/5}$	100	178
2	$n^{-1/6}$	$n^{-2/3}$	100	1,000
3	$n^{-1/7}$	$n^{-4/7}$	100	3,981
5	$n^{-1/9}$	$n^{-4/9}$	100	27,826
10	$n^{-1/14}$	$n^{-2/7}$	100	1.85×10^6

Bellman (1961) 的维数诅咒: d 每增加 1, 所需样本量几何级增长。经济应用中 $d = 5 \sim 10$ 常见, 这使得纯非参数回归实际上不可行——必须限制结构 (单指标、可加性、部分线性)。

高维球面现象： $\mathbb{R}^d$ 中单位球的体积

$$V_d = \frac{\pi^{d/2}}{\Gamma(d/2 + 1)} \xrightarrow{d \rightarrow \infty} 0.$$

高维单位球的**体积几乎为 0**——数据在高维空间中**极为稀疏**。

直观示例：若要在 $[0, 1]^d$ 中覆盖 10% 的体积（「 x 附近的邻域」），所需立方体边长：

d	边长 = $0.1^{1/d}$
1	0.10
2	0.32
5	0.63
10	0.79
20	0.89

维数诅咒：结构假设的必要性

即 $d = 10$ 时要覆盖 10% 体积需要近 80% 的边长——「局部」已变「全局」，核回归本质上退化为全局参数回归。

这解释了为什么没有任何方法能「纯非参数地」解决高维问题——必须引入**结构假设**（单指标、可加性、稀疏性）。**半参数方法（S3）**由此而生。

三类常用结构假设（按约束强度递增）：

- ▶ **可加性** (additive) : $m(x) = \sum_{\ell} m_{\ell}(x_{\ell})$;
- ▶ **部分线性**: $m(x) = z'\gamma + m_0(x_0)$;
- ▶ **单指标**: $m(x) = G(x'\beta)$ ——**S3 重点**。

三大策略, 按约束强度递增。

策略 1: 加性模型 (Additive Model; Stone 1985)

$$m(x_1, \dots, x_d) = c_0 + \sum_{\ell=1}^d m_{\ell}(x_{\ell}).$$

每个 m_{ℓ} 以 **单维率** $n^{-2/5}$ 估计——摆脱维数诅咒。

策略 2: 部分线性模型 (Robinson 1988)

$$Y_i = Z_i' \gamma + m(X_i) + u_i, \quad m \in \mathcal{F}.$$

γ 以 $\sqrt{n}$ 率估计, m 以非参数率。

策略 3: 单指标模型 (Ichimura 1993; Klein–Spady 1993)

$$E[Y | X = x] = G(x'\beta), \quad G \text{ 未知.}$$

β 以 $\sqrt{n}$ 率估计, G 以 1 维非参数率——把 d 维问题化约为 1 维。

S3 的核心: 单指标模型是二元选择非参数化的最自然扩展——保留 Probit/Logit 的 $x'\beta$ 结构, 但释放链接函数的形式。

局部多项式估计 (Local Polynomial Regression)

NW 的局限（回顾）：

- ▶ 偏误含设计密度项 $2m'(x)f'_X(x)/f_X(x)$;
- ▶ 边界处偏误退化为 $O(h)$ 。

Fan & Gijbels (1996) 的洞见： NW 在 x 附近用**常数**近似 m ——这丢失了**一阶信息**（斜率）。若改用**局部线性**近似

$$m(X_i) \approx m(x) + m'(x)(X_i - x),$$

偏误就能自动消去 m' 相关的一阶效应。

思路：在每一点 x 处，对 m 做 p 阶 **Taylor 展开**，用加权最小二乘估计展开系数。

$$m(X_i) \approx \beta_0 + \beta_1(X_i - x) + \cdots + \frac{1}{p!}\beta_p(X_i - x)^p.$$

$\hat{\beta}_0$ 即为 $\hat{m}(x)$; $\hat{\beta}_1$ 即为 $\hat{m}'(x)$ （**免费得到导数估计！**）。

局部 p 阶多项式估计 (Local Polynomial of Order p)

在点 x 处, 求 $\beta(x) = (\beta_0, \beta_1, \dots, \beta_p)'$ 最小化加权 SSR:

$$\hat{\beta}(x) = \arg \min_{\beta} \sum_{i=1}^n K_h(x - X_i) \left[Y_i - \sum_{j=0}^p \beta_j (X_i - x)^j \right]^2.$$

估计量: $\hat{m}_{LP(p)}(x) = \hat{\beta}_0(x)$; $\hat{m}_{LP(p)}^{(r)}(x) = r! \hat{\beta}_r(x)$ 。

特殊情形:

- ▶ $p = 0$: **局部常数** = Nadaraya–Watson;
- ▶ $p = 1$: **局部线性** (LL) —— Fan & Gijbels 推荐的**默认选择**;
- ▶ $p = 2$: **局部二次** (LQ) —— 用于估计 m'' 或复杂曲率;
- ▶ p 偶数 $\Rightarrow p + 1$ 奇数: 可进一步降低内点偏误阶——**奇阶多项式占优 (odd-order wins)**。

局部多项式估计：矩阵形式

记号： $\mathbf{X}_x$ 为 $n \times (p+1)$ 设计矩阵：

$$\mathbf{X}_x = \begin{pmatrix} 1 & (X_1 - x) & \cdots & (X_1 - x)^p \\ \vdots & \vdots & & \vdots \\ 1 & (X_n - x) & \cdots & (X_n - x)^p \end{pmatrix}, \quad \mathbf{W}_x = \text{diag}\{K_h(x - X_1), \dots, K_h(x - X_n)\}.$$

WLS 解：

$$\hat{\beta}(x) = (\mathbf{X}_x' \mathbf{W}_x \mathbf{X}_x)^{-1} \mathbf{X}_x' \mathbf{W}_x \mathbf{Y}.$$

抽取第 0 个分量： $\hat{m}(x) = \mathbf{e}_0' (\mathbf{X}_x' \mathbf{W}_x \mathbf{X}_x)^{-1} \mathbf{X}_x' \mathbf{W}_x \mathbf{Y}$, 其中 $\mathbf{e}_0 = (1, 0, \dots, 0)'$ 。

等价权重形式： $\hat{m}(x) = \sum_{i=1}^n \ell_i(x; h) Y_i$, 其中

$$\ell_i(x; h) = \mathbf{e}_0' (\mathbf{X}_x' \mathbf{W}_x \mathbf{X}_x)^{-1} (1, X_i - x, \dots, (X_i - x)^p)' \cdot K_h(x - X_i).$$

故局部多项式估计也是**线性平滑器 (linear smoother)**——理论性质与 NW 可类比。

$p = 1$ 情形。定义局部矩：

$$S_j(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - X_i)(X_i - x)^j, \quad j = 0, 1, 2.$$

$$T_j(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - X_i)(X_i - x)^j Y_i, \quad j = 0, 1.$$

使用这些局部矩，局部线性估计量可以写成封闭形式——见下一张幻灯片。

局部线性估计量 (Local Linear, LL)

$$\hat{m}_{LL}(x) = \frac{S_2(x)T_0(x) - S_1(x)T_1(x)}{S_0(x)S_2(x) - S_1(x)^2}.$$

等价地：

$$\hat{m}_{LL}(x) = \sum_{i=1}^n \ell_i^{LL}(x) Y_i, \quad \ell_i^{LL}(x) = \frac{[S_2(x) - S_1(x)(X_i - x)] K_h(x - X_i)}{n[S_0(x)S_2(x) - S_1(x)^2]}.$$

实用观察：当 f_X 对称时 $S_1 \approx 0$, LL 几乎退化为 NW；当 f_X 不对称时（或在边界）， $S_1 \neq 0$ 产生**设计偏误修正**——这是 LL 优越性的数学根源。

内点 (x 离边界远):

$$\text{Bias}[\hat{m}_{\text{NW}}(x)] = \frac{h^2 \kappa_2}{2} \left[m''(x) + 2 \frac{m'(x) f'_x(x)}{f_x(x)} \right] + o(h^2),$$

$$\text{Bias}[\hat{m}_{\text{LL}}(x)] = \frac{h^2 \kappa_2}{2} m''(x) + o(h^2).$$

关键差异: LL 偏误不含设计密度项!

- ▶ NW 偏误在 f_x 急剧变化处 (尾部、多峰谷底) 被放大;
- ▶ LL 偏误只依赖 m'' ——「**设计自适应 (design-adaptive)**」 (Fan 1992) ;
- ▶ 方差两者相同: $\text{Var}[\hat{m}_{\text{LL}}(x)] = R(K)\sigma^2(x)/(nhf_x(x))$;
- ▶ **LL 弱占优 NW**——偏误更小 (或相等), 方差相同。

结论: 实务默认选择局部线性 (LL) 而非 NW——「同等方差下的更小偏误」几乎是「免费午餐」。

LL 对比 NW: 边界处的决定性优势

边界点 (x 在支撑边缘) :

$$\text{Bias}[\hat{m}_{\text{NW}}(x_{\text{bd}})] = O(h), \quad \text{Bias}[\hat{m}_{\text{LL}}(x_{\text{bd}})] = O(h^2).$$

LL 自动解决边界问题!

原因: LL 在每一点**显式拟合截距 + 斜率**。即使样本「只在一侧」, 回归直线也能合理外推到 x 处——无需对核作特殊处理。

实证启示:

- ▶ **RDD (回归断点)**: 断点处本质是边界问题——**Imbens & Kalyanaraman (2012)**、**Calonico–Cattaneo–Titiunik (2014)** 的 RD 带宽理论全部基于 LL 估计;
- ▶ **分位回归端点**: 在 τ 接近 0 或 1 时, LL 修正「稀疏尾部」偏误;
- ▶ **生存分析**: 在寿命分布截断处, LL 给出无偏残存率估计。

偏误阶（内点, p 阶局部多项式）：

- ▶ $p = 0$ (NW): Bias = $O(h^2)$;
- ▶ $p = 1$ (LL): Bias = $O(h^2)$, 但无设计偏误;
- ▶ $p = 2$ (LQ): Bias = $O(h^4)$? —— **不, 仍是 $O(h^2)$** ;
- ▶ $p = 3$ (LC, local cubic): Bias = $O(h^4)$ 。

奇阶多项式占优定理 (Fan & Gijbels 1996, Thm 3.1): 只有当 p 从偶数增加到奇数时, 偏误阶才降低。这是因为**对称核下高阶奇矩为零**——奇数阶多项式的额外项不增加方差。

实务推荐:

- ▶ **估计 m 本身** $\Rightarrow$ 用 LL ($p = 1$)——简单、稳健、无设计偏误;
- ▶ **估计导数 $m^{(r)}$** $\Rightarrow$ 用 $p = r + 1$ 或 $p = r + 3$ 阶多项式;
- ▶ $p \geq 3$ 的额外收益通常被方差增加抵消—— $p = 1$ **是黄金标准**。

定理 5 (LL CLT, Fan & Gijbels 1996) : 在 NW 类似假设下,

$$\sqrt{nh} \left[\hat{m}_{LL}(x) - m(x) - B_{LL}(x)h^2 \right] \xrightarrow{d} \mathcal{N}(0, V_{LL}(x)),$$

其中

$$B_{LL}(x) = \frac{\kappa_2}{2} m''(x), \quad V_{LL}(x) = \frac{R(K)\sigma^2(x)}{f_X(x)}.$$

与 NW 对比:

	NW	LL
偏误常数	$\frac{\kappa_2}{2} [m'' + 2m'f'/f]$	$\frac{\kappa_2}{2} m''$
方差常数	$R(K)\sigma^2/f$	$R(K)\sigma^2/f$
边界偏误	$O(h)$	$O(h^2)$

$\sqrt{nh}$ **收敛率不变**——LL 相对于 NW 是**偏误的改进**, 不是收敛率的改进。要改进收敛率必须假设更多光滑性 (使用更高阶多项式)。

局部多项式：窗宽选择与实用建议

窗宽选择方法（同 NW 可推广）：

- ▶ **LSCV**: $CV(h) = n^{-1} \sum_i [Y_i - \hat{m}_{LL,-i}(X_i)]^2$;
- ▶ **插入法**: $\hat{h} = \left[R(K) \hat{V} / (\kappa_2^2 \int (\widehat{m''})^2 f_X^2 w) \right]^{1/5} n^{-1/5}$ ——Ruppert–Sheather–Wand (1995);
- ▶ **自适应窗宽**: 在 x 处用本地方差选 $h(x)$ ——**Cattaneo** 等人的「MSE-optimal local bandwidth」。

方法对比表：

方法	估计方程	内点偏误阶	边界偏误阶	设计自适应
NW (LC)	$\min_{\alpha} \sum w_i (Y_i - \alpha)^2$	h^2	h	否
LL	$\min_{\alpha, \beta} \sum w_i (Y_i - \alpha - \beta(X_i - x))^2$	h^2	h^2	是
LQ	LL + $(X_i - x)^2$ 项	h^2	h^2	是
LC	LQ + $(X_i - x)^3$ 项	h^4	h^4	是

Zhou (§3.3) 与 Hansen (Ch.19) 一致建议：默认使用 LL。若需导数估计或 RDD 分析，则考虑更高阶（奇数阶）局部多项式。

非参数推断：置信区间与 Wild Bootstrap

目标：对某固定点 x_0 构造 $m(x_0)$ 的置信区间。

从定理 4/5 (CLT) 出发：

$$\sqrt{nh} \left[\hat{m}(x_0) - m(x_0) - B(x_0)h^2 \right] \xrightarrow{d} \mathcal{N}(0, V(x_0)).$$

问题：偏误项 $B(x_0)h^2$ 在极限分布中**不是 0**！若按惯例写：

$$\hat{m}(x_0) \pm z_{\alpha/2} \sqrt{\hat{V}/nh},$$

所得区间的**覆盖率不是名义水平** $1 - \alpha$ ——而是向偏误方向**系统偏离**。

三大解决方案：

1. **欠平滑 (Undersmoothing)**——选 h 使 $\sqrt{nh} \cdot h^2 \rightarrow 0$ ，牺牲效率换取偏误消失；
2. **偏误校正 (Bias Correction)**——估计 $\hat{B}(x_0)$ 并减去——Calonico, Cattaneo, Titiunik (2014) 的「稳健」方法；
3. **Wild Bootstrap**——用自助法直接重抽样分布，绕过解析公式。

实务选择：三种方案各有优劣，接下来三张幻灯片分别展开。默认推荐：CCT 偏误校正。

欠平滑法 (Undersmoothing): 定义

欠平滑窗宽 (Undersmoothed Bandwidth)

选取 $h = h_n$ 满足

$$h \rightarrow 0, \quad nh \rightarrow \infty, \quad \text{且} \quad nh^5 \rightarrow 0.$$

常见实现: $h = c \cdot n^{-1/4}$ (比最优 $n^{-1/5}$ 小)。

效果: 由 $nh^5 \rightarrow 0$:

$$\sqrt{nh} \cdot h^2 = \sqrt{nh^5} \rightarrow 0,$$

故偏误项消失:

$$\sqrt{nh} [\hat{m}(x_0) - m(x_0)] \xrightarrow{d} \mathcal{N}(0, V(x_0)).$$

标准 $(1 - \alpha)$ 置信区间：

$$\hat{m}(x_0) \pm z_{\alpha/2} \sqrt{\frac{\hat{R}(K) \hat{\sigma}^2(x_0)}{nh \hat{f}_X(x_0)}}.$$

代价： h 比最优小 $\Rightarrow \hat{m}$ 方差比 AMISE 最优大 $\Rightarrow$ 区间更宽。这是换取**覆盖率正确**的代价——「**效率 vs 诚实 (honest)**」的权衡。

方差的插入法估计

方差公式回顾:

$$V(x_0) = \frac{R(K)\sigma^2(x_0)}{f_X(x_0)}.$$

三个待估量:

1. $R(K) = \int K^2(u)du$ ——**已知** (核函数选定后是常数) ;
2. $f_X(x_0)$ ——用 KDE $\hat{f}_X(x_0)$ 估计;
3. $\sigma^2(x_0) = E[(Y - m(X))^2 | X = x_0]$ ——用**局部残差平方**估计。
 $\sigma^2(x_0)$ 的**局部残差估计量**:

$$\hat{\sigma}^2(x_0) = \frac{\sum_{i=1}^n K_h(x_0 - X_i)[Y_i - \hat{m}(X_i)]^2}{\sum_{i=1}^n K_h(x_0 - X_i)}.$$

逐点置信区间 (渐近)

$$CI_{1-\alpha}(x_0) = \hat{m}(x_0) \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{R}(K)\hat{\sigma}^2(x_0)}{nh\hat{f}_X(x_0)}}.$$

均匀置信带 (Uniform Confidence Bands)

逐点区间只保证单点覆盖。要同时覆盖曲线 $m(\cdot)$ 在整个区间上的值，需要均匀置信带。

Bickel–Rosenblatt (1973) 极值型定理：在适当条件下，对内点区间 $[a, b]$,

$$P\left(\sqrt{2 \log h^{-1}} \left[\max_{x \in [a, b]} \frac{|\hat{m}(x) - m(x)|}{\sqrt{V(x)/(nh)}} - d_n \right] \leq z\right) \rightarrow e^{-2e^{-z}},$$

其中 $d_n = \sqrt{2 \log h^{-1}} + \text{常数}$ 。

均匀置信带：

$$m(x) \in \hat{m}(x) \pm c_{\alpha}^{\text{unif}} \sqrt{\hat{V}(x)/(nh)}, \quad \forall x \in [a, b],$$

其中 c_{α}^{unif} 基于极值分布，**比逐点 $z_{\alpha/2}$ 大**。

实务问题：极值分布收敛极慢，实务中覆盖率常偏离名义水平。**推荐：**使用 Wild Bootstrap 直接模拟均匀分布（下页）。

Wild Bootstrap 的动机

传统 Bootstrap 的问题 (重抽样 (X_i, Y_i)) :

- ▶ 经典残差 Bootstrap 假设误差**同方差**——违反时失效;
- ▶ 对**条件异方差**数据, 重抽残差的分布与真实条件分布不匹配;
- ▶ 非参数回归的**偏误**需要特殊处理。

Wild Bootstrap (Wu 1986; Liu 1988; Mammen 1993)

给定样本 $\{(X_i, Y_i)\}$ 与残差 $\hat{u}_i = Y_i - \hat{m}(X_i)$, 生成**自助样本**:

$$Y_i^* = \hat{m}(X_i) + \hat{u}_i \cdot v_i, \quad v_i \stackrel{\text{iid}}{\sim} F_v,$$

其中 v_i 的分布 F_v 满足: $E[v] = 0$, $E[v^2] = 1$, $E[v^3] = 0$ 。

常见选择:

- ▶ **Mammen 两点分布**: $v = -(\sqrt{5} - 1)/2$ w.p. $(\sqrt{5} + 1)/(2\sqrt{5})$; $v = (\sqrt{5} + 1)/2$ o.w.
- ▶ **Rademacher**: $v = \pm 1$ 各 $1/2$ 概率 (但 $E[v^3] = 0$, 可用于 2 阶矩问题) ;
- ▶ **正态**: $v \sim \mathcal{N}(0, 1)$ ——简单但 $E[v^3] = 0$ 。

Wild Bootstrap 逐点/均匀区间算法

输入： 样本 $\{(X_i, Y_i)\}$, 窗宽 h (可欠平滑或偏误校正), 自助次数 B (通常 999)。

1. 用原样本计算 $\hat{m}(x)$ 和残差 $\hat{u}_i = Y_i - \hat{m}(X_i)$;
2. 对 $b = 1, 2, \dots, B$ 重复:
 - 2.1 抽取 $v_i^{(b)} \stackrel{\text{iid}}{\sim} F_v$;
 - 2.2 生成 $Y_i^{*(b)} = \hat{m}(X_i) + \hat{u}_i v_i^{(b)}$;
 - 2.3 用自助样本 $\{(X_i, Y_i^{*(b)})\}$ 计算 $\hat{m}^{*(b)}(x)$;
3. **逐点区间：** $\hat{m}(x) \pm q_{\alpha/2, 1-\alpha/2} \{\hat{m}^{*(b)}(x) - \hat{m}(x)\}_{b=1}^B$;
4. **均匀区间：**

$$T^{*(b)} = \max_{x \in [a, b]} \frac{|\hat{m}^{*(b)}(x) - \hat{m}(x)|}{\sqrt{\hat{V}(x)/(nh)}},$$

取 $(1 - \alpha)$ 分位数 c_α^* , 构造 $\hat{m}(x) \pm c_\alpha^* \sqrt{\hat{V}(x)/(nh)}$.

定理 6 (Wild Bootstrap 一致性, Härdle–Mammen 1993) : 在标准非参数回归假设下,

$$\sup_t \left| P^* \left(\sqrt{nh}(\hat{m}^* - \hat{m}) \leq t \mid \text{样本} \right) - P \left(\sqrt{nh}(\hat{m} - m) \leq t \right) \right| \xrightarrow{P} 0.$$

即**自助分布与真分布渐近相同**——基于自助分位数的区间渐近有效。

为什么用 Wild 而非标准 Bootstrap?

1. **保留条件异方差**—— v_i 乘以**残差**而非重抽残差, 故 $\text{Var}(Y_i^* | X_i) = \hat{u}_i^2 \approx \sigma^2(X_i)$;
2. $E[v^3] = 1$ 的作用——保证**偏误的二阶项**也被自助复制, 实现「二阶精确」;
3. **高维/非参数适应性**——不要求误差同分布, 适用于异方差复杂数据结构。

► 证明

Calonico–Cattaneo–Titiunik (CCT, 2014) 稳健方案：

双重窗宽偏误校正

用**更大的辅助窗宽** $b > h$ 构造偏误估计：

$$\hat{B}(x_0) = \hat{m}_b^{(2)}(x_0) \cdot \frac{h^2 \kappa_2}{2},$$

其中 $\hat{m}_b^{(2)}$ 是带宽 b 的**局部二次估计**（估计 m'' ）。偏误校正估计量：

$$\hat{m}_{bc}(x_0) = \hat{m}_h(x_0) - \hat{B}(x_0).$$

稳健方差要**考虑** $\hat{B}$ 的噪声：

$$\hat{V}_{rob}(x_0) = \hat{V}_h(x_0) + \text{Var}_{bc}(x_0).$$

优点：

- ▶ 可用 **MSE 最优窗宽**（不需欠平滑），保留效率；
- ▶ **覆盖率正确**到渐近二阶精度；
- ▶ **在 RDD 中已成行业标准**——rdrobust 包实现完整 CCT 方法；
- ▶ **扩展到导数估计**——Calonico 等 (2022) 推广至 m' 、 m'' 的稳健推断；
- ▶ **软件**：R/Stata 的 rdrobust, nprobust 包一键实现。

方法	窗宽要求	区间类型	优劣
欠平滑	$nh^5 \rightarrow 0$ ($h \ll n^{-1/5}$)	逐点 / 均匀	简单；效率损失
插入法	最优 $h \propto n^{-1/5}$	逐点	覆盖率偏离（偏误残留）
CCT 偏误校正	可用最优 h	逐点（稳健方差）	覆盖率正确；稍复杂
Wild Bootstrap	任意（含最优）	逐点 / 均匀	异方差稳健；计算贵

实务决策流程（Hansen Ch.19, Cattaneo 2024）：

- 1. 默认：CCT 偏误校正 + 稳健方差；
- 2. 需要均匀带或异方差严重：Wild Bootstrap；
- 3. 只做描述性分析：欠平滑 + 插入法方差（简单快捷）。

级数方法 (Series Methods)

出发点：若 $m(x)$ 属于某函数空间 $\mathcal{F}$ ，它可以被**基函数** $\{p_k(x)\}$ 的**线性组合**逼近：

$$m(x) \approx \sum_{k=0}^K c_k p_k(x), \quad K \rightarrow \infty \text{ 时近似误差} \rightarrow 0.$$

常见基函数：

- ▶ **幂级数 (Power Series):** $p_k(x) = x^k$ ——简单但数值病态（高阶幂相关性高）；
- ▶ **Fourier 基:** $p_k(x) = \sin(k\pi x), \cos(k\pi x)$ ——周期函数逼近；
- ▶ **多项式正交基:** Legendre、Chebyshev、Hermite——数值稳定；
- ▶ **样条 (Splines):** B-spline、自然样条——局部支撑，节点灵活；
- ▶ **小波 (Wavelets):** Haar、Daubechies——多尺度分析。

关键参数：项数 K ——核方法中的「窗宽」的类比。 K 太小偏误大， K 太大方差大。

级数估计量 (Sieve / Series Estimator)

选定基 $\{p_k\}_{k=0}^K$, 定义 $n \times (K+1)$ 设计矩阵

$$\mathbf{P} = \begin{pmatrix} p_0(X_1) & p_1(X_1) & \cdots & p_K(X_1) \\ \vdots & \vdots & & \vdots \\ p_0(X_n) & p_1(X_n) & \cdots & p_K(X_n) \end{pmatrix}.$$

OLS:

$$\hat{\mathbf{c}} = (\mathbf{P}'\mathbf{P})^{-1}\mathbf{P}'\mathbf{Y}, \quad \hat{m}(x) = \sum_{k=0}^K \hat{c}_k p_k(x) = \mathbf{p}(x)'\hat{\mathbf{c}}.$$

优势（相比核方法）：

- ▶ 计算简单——只是一次 OLS；
- ▶ 全局光滑——无需逐点迭代；
- ▶ 高维自然推广——张量积基 $p_{k_1}(x_1) \cdots p_{k_d}(x_d)$ ；
- ▶ 标准工具箱——t 检验、F 检验、VCE 都可用。

劣势：项数 K 选择复杂、基函数选择影响大、局部性差。

Fourier 基 (周期函数, $[0, 2\pi]$)

$$p_{2k-1}(x) = \sin(kx), \quad p_{2k}(x) = \cos(kx), \quad k = 1, 2, \dots$$

正交性: $\int_0^{2\pi} \sin(kx) \sin(jx) dx = \pi \delta_{jk} \quad (k \neq 0)$ 。

幂级数 (支撑任意)

$$p_k(x) = x^k, \quad k = 0, 1, 2, \dots, K.$$

幂级数的数值缺陷: 设计矩阵 P 的条件数随 K 指数级增长—— $(P'P)^{-1}$ 数值不稳定。

解决方案:

- ▶ 先**标准化** x 到 $[-1, 1]$;
- ▶ 用**正交多项式** (Chebyshev、Legendre) 代替原始幂次;
- ▶ 使用样条而非多项式——**局部基函数**避免全局相关性。

Hermite 多项式 (Probabilists' Convention)

Hermite 多项式 $H_k(x)$ 定义为：

$$H_k(x) = (-1)^k \phi(x)^{-1} \frac{d^k}{dx^k} \phi(x),$$

其中 $\phi(x) = (2\pi)^{-1/2} \exp(-x^2/2)$ 是标准正态密度。

前几阶： $H_0(x) = 1$, $H_1(x) = x$, $H_2(x) = x^2 - 1$, $H_3(x) = x^3 - 3x$ 。

正交性 (以 ϕ 为权)：

$$\int_{-\infty}^{\infty} H_j(x) H_k(x) \phi(x) dx = k! \delta_{jk}.$$

Hermite 基的优势 (Zhou §4.4) :

- ▶ **支撑 $\mathbb{R}$** ——适合**无界变量** (收入、资产等) ;
- ▶ **对正态权测度正交**——系数估计方差解析;
- ▶ **密度估计**: 若真实密度 $f = \phi \cdot \exp(\sum c_k H_k)$, Hermite 级数**保证非负性**;
- ▶ **Gallant–Nychka (1987) SNP 方法**: 用 Hermite 基做准则函数估计半参数模型;
- ▶ **Fenton–Gallant (1996)**: Hermite 级数可近似任意连续密度。

B-样条 (B-splines)

给定节点序列 $\xi_0 < \xi_1 < \dots < \xi_J$, d 阶 B-样条基 $B_{k,d}(x)$ 由 Cox-de Boor 递推定义:

$$B_{k,0}(x) = \mathbb{1}\{x \in [\xi_k, \xi_{k+1})\},$$

$$B_{k,d}(x) = \frac{x - \xi_k}{\xi_{k+d} - \xi_k} B_{k,d-1}(x) + \frac{\xi_{k+d+1} - x}{\xi_{k+d+1} - \xi_{k+1}} B_{k+1,d-1}(x).$$

特点:

- ▶ **局部支撑**—— $B_{k,d}$ 仅在 $d + 2$ 个相邻节点区间内非零 $\Rightarrow$ 设计矩阵**带状** (稀疏), 计算 $O(n)$ 而非 $O(nK)$;
- ▶ **光滑度**—— d 阶 B-样条是 $d - 1$ 阶连续可导 ($d = 3$ 最常用 = 三次样条);
- ▶ **形状灵活**——节点可**等距**或**分位数**等样本密度分布。

实务推荐: 三次 B-样条 ($d = 3$) + 分位数节点是**级数方法首选**——兼顾光滑度、局部性、计算速度。R 包 `splines::bs()`。

项数 K 选择: Mallows C_L 准则

目标: 最小化 $\text{APE}(K) = E[(Y - \hat{m}_K(X))^2]$ 。

Mallows C_L 准则 (Mallows 1973)

$$C_L(K) = \text{SSR}(K) + 2K\hat{\sigma}^2, \quad \text{SSR}(K) = \sum_{i=1}^n [Y_i - \hat{m}_K(X_i)]^2.$$

其中 $\hat{\sigma}^2$ 是**全局**残差方差 (通常用最大 K 的模型估计)。

$$\hat{K}_{\text{Mallows}} = \arg \min_K C_L(K).$$

直觉: 第一项 SSR 衡量**拟合优度** ($K \uparrow$ 递减), 第二项 $2K\hat{\sigma}^2$ 惩罚**复杂度**。

K 选择: C_L 与 AIC/BIC 的关系

相关准则:

- ▶ **AIC**: $SSR(K) + 2K\hat{\sigma}^2$ (与 C_L 几乎相同) ;
- ▶ **BIC**: $SSR(K) + \log(n) \cdot K\hat{\sigma}^2$ (更重惩罚 $\Rightarrow$ 更小 $K \Rightarrow$ 一致选择「真」模型) ;
- ▶ **选 AIC 做预测, 选 BIC 做解释**——经验法则。

C_L 近似无偏地估计 APE——**最优的 K 使 APE 最小**。在高斯误差下, C_L 、AIC 与 Cross-Validation 渐近等价。

项数 K 选择: GCV 与 LOOCV

Leave-One-Out CV:

$$CV(K) = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{m}_{K,-i}(X_i)]^2 = \frac{1}{n} \sum_{i=1}^n \left[\frac{Y_i - \hat{m}_K(X_i)}{1 - h_{ii}(K)} \right]^2,$$

其中 $h_{ii}(K)$ 是投影矩阵 $\mathbf{H} = \mathbf{P}(\mathbf{P}'\mathbf{P})^{-1}\mathbf{P}'$ 的第 i 对角元。

关键简化: 对线性平滑器, LOOCV 不需要重复拟合——由杠杆值 h_{ii} 直接计算。

广义交叉鉴定 (GCV, Craven & Wahba 1979)

$$GCV(K) = \frac{1}{n} \sum_{i=1}^n \left[\frac{Y_i - \hat{m}_K(X_i)}{1 - \text{tr}(\mathbf{H})/n} \right]^2 = \frac{SSR(K)/n}{[1 - (K+1)/n]^2}.$$

GCV vs. LOOCV: GCV 把每个 h_{ii} 替换为平均值 $(K+1)/n$ ——更稳定、不受异常点影响; 两者渐近等价。GCV 是级数方法的实务首选。

级数估计的偏误与方差

偏误 (近似误差) :

$$\text{Bias}(x) = E[\hat{m}_K(x)] - m(x) = - \underbrace{(m(x) - m_K^*(x))}_{\text{近似误差}} + O(K/n),$$

其中 m_K^* 是 m 在前 K 阶基函数空间中的**最佳投影**。若 m 属于 s 阶 Sobolev 空间:

$$|m(x) - m_K^*(x)| = O(K^{-s/d}).$$

方差:

$$\text{Var}[\hat{m}_K(x)] = O\left(\frac{K}{n}\right).$$

MSE 平衡: $K^{-2s/d} + K/n = \min \Rightarrow K^* \propto n^{d/(2s+d)}$, $\text{MSE} = O(n^{-2s/(2s+d)})$ 。

与核方法对比:

- ▶ 核方法: $\text{MSE}^* = O(n^{-4/(4+d)})$ (假设 $s = 2$) ;
- ▶ 级数方法: $\text{MSE}^* = O(n^{-2s/(2s+d)})$ ——**若 s 大 (m 很光滑) , 级数方法更快;**
- ▶ 级数方法通过光滑性**换取更快收敛率**—— $s = \infty$ 时接近 n^{-1} (近参数率) 。

定理 7 (级数估计 CLT, Newey 1997) : 在 $K \rightarrow \infty$, $K/n \rightarrow 0$, 近似条件成立下,

$$\sqrt{\frac{n}{K}} \cdot \frac{\hat{m}_K(x) - m(x) - \text{近似偏误}}{s_K(x)} \xrightarrow{d} \mathcal{N}(0, 1),$$

其中 $s_K^2(x) = p(x)'(P'P)^{-1}P'\Omega P(P'P)^{-1}p(x) \cdot \sigma^2$ 。

异方差稳健方差：直接用Eicker-White 三明治

$$\hat{s}_K^2(x) = p(x)'(P'P)^{-1} \left[\sum_i \hat{u}_i^2 p(X_i) p(X_i)' \right] (P'P)^{-1} p(x).$$

实务意义：级数估计在 (x, K) 给定时就是**普通 OLS**——所有 OLS 推断工具 (t、F、Var、Cluster SE) **直接适用**。这是级数方法相比核方法的最大实用优势。

核方法 vs. 级数方法：系统对比

维度	核方法 (NW / LL)	级数方法
基本形式	局部加权平均	基函数展开的 OLS
光滑参数	窗宽 h	项数 K
计算复杂度	$O(n^2)$ (每点 $O(n)$)	$O(nK)$ (一次 OLS)
局部性	强 (局部加权)	取决于基 (B-样条: 强; 多项式: 弱)
边界性质	NW 差; LL 好	多项式差; 样条好
导数估计	需 $LP(p \geq r + 1)$	自动 (对 p_k 求导)
多维推广	乘积核, 维数诅咒	张量积基, 维数诅咒
渐近方差	$R(K)\sigma^2/(nhf)$	三明治公式
推断工具	CLT + Wild Bootstrap	OLS 全套工具
软件	R: np, locpol; Stata: lpoly	R: splines, mgcv; Stata: npregress

选哪一个? Hansen 2022 建议: 级数法用于多元、带控制变量的回归 ($d \geq 2$) ; 核法用于一维、重视边界的应用 (如 RDD) 。

五点核心:

1. **级数方法是非参数的 OLS**——把无穷维问题化约为有限维线性回归;
2. **基函数选择**按支撑 ($\mathbb{R}$: Hermite; $[a, b]$: Legendre/Chebyshev; 一般: B-样条) ;
3. **项数 K**通过 GCV、Mallows C_L 或 BIC 选择;
4. **收敛率**取决于 m 的光滑阶 s : $n^{-2s/(2s+d)}$;
5. **推断**可直接借用 OLS 工具 (t , F , 三明治 VCE, Cluster SE) 。

方法论定位: 级数方法与核方法**互为补充**——它们的渐近性质相当, 但实务表现在不同问题中各有优势。Zhou Xianbo (§4.6): 「**核方法看局部, 级数方法看全局; 实证中先看局部结构, 再选估计方法。**」

混合数据、离散核与条件分布

离散核函数 (Aitchison–Aitken)

问题：若 X 包含**离散变量**（如教育水平、职业代码），核 $K((x - X_i)/h)$ 不再有意义—— $h \rightarrow 0$ 时只有 $X_i = x$ 的观测进入，**退化为 cell-mean 估计**。

Aitchison–Aitken 离散核 (1976)

对有 c 个类别的名义变量 $X^d \in \{0, 1, \dots, c - 1\}$ ：

$$L(X_i^d, x^d; \lambda) = \begin{cases} 1 - \lambda & \text{if } X_i^d = x^d, \\ \lambda/(c - 1) & \text{if } X_i^d \neq x^d. \end{cases}$$

参数 $\lambda \in [0, (c - 1)/c]$ 。 $\lambda = 0 \Rightarrow$ cell-mean； $\lambda = (c - 1)/c \Rightarrow$ 全局均值。

有序离散变量 (Ordered)： 使用**带距离的核**：

$$L_{\text{ord}}(X_i^d, x^d; \lambda) = \lambda^{|X_i^d - x^d|}.$$

λ **类似连续核的窗宽**——通过交叉验证选择。这**自动**在 cell-mean (λ 小) 与 pooling (λ 大) 之间插值。

混合数据乘积核

$X = (X^c, X^d)$, $X^c \in \mathbb{R}^{d_c}$ 连续, $X^d \in \mathcal{D}^{d_d}$ 离散:

$$\mathcal{K}(X_i, x; \mathbf{h}, \lambda) = \prod_{\ell=1}^{d_c} \frac{1}{h_\ell} K\left(\frac{X_i^{c,\ell} - x^{c,\ell}}{h_\ell}\right) \cdot \prod_{j=1}^{d_d} L(X_i^{d,j}, x^{d,j}; \lambda_j).$$

混合数据 NW 估计量:

$$\hat{m}(x) = \frac{\sum_i \mathcal{K}(X_i, x; \cdot) Y_i}{\sum_i \mathcal{K}(X_i, x; \cdot)}.$$

Li & Racine (2007) 的关键洞见: 通过 LSCV 同时选 $(\mathbf{h}, \lambda)$, 得到**自动变量选择**能力:

- ▶ 若 $X^{c,\ell}$ 与 Y 无关 $\Rightarrow$ 最优 h_ℓ 会发散到 ∞ (相当于 pooling, 该变量「无效」);
- ▶ 若 $X^{d,j}$ 与 Y 无关 $\Rightarrow$ 最优 $\lambda_j \rightarrow (c-1)/c$ (该变量「无效」)。

结果: LSCV 选择窗宽 $\equiv$ 非参数变量筛选——**免费的变量重要性排序**。

混合数据窗宽选择的实用意义

Hall, Li, Racine (2007) 变量选择理论： 设 $\mathcal{S}^*$ 是与 Y 真正相关的变量集合， $\mathcal{S}^c$ 是无关变量。在适当条件下：

$$\text{对 } j \in \mathcal{S}^* : \hat{h}_j \propto n^{-1/(4+d^*)} \rightarrow 0,$$

$$\text{对 } j \in \mathcal{S}^c : \hat{h}_j \rightarrow \infty \text{ (依概率).}$$

即**LSCV** 自动将无关变量「平滑掉」。

实务优势：

- ▶ 不必事先确定「控制变量清单」——LSCV 给出客观筛选；
- ▶ 对**高维**问题 ($d = 10 \sim 20$) 特别有用——「有效维度」 $d^* \ll d$ ；
- ▶ **自动交互效应**——离散变量之间的交互由乘积核天然捕获；
- ▶ 可与参数结构结合（部分线性、单指标）——S3 会见到。

软件实现： R 包 np——`npreg(y ~ x1 + x2 + xd1 + xd2, data=data)` 自动做 LSCV 混合核窗宽选择。

Li & Racine 条件 CDF 估计量

目标：估计 $F(y | x) = P(Y \leq y | X = x)$ 。

$$\hat{F}(y | x) = \frac{\sum_{i=1}^n K_h(x - X_i) \mathbb{1}\{Y_i \leq y\}}{\sum_{i=1}^n K_h(x - X_i)}.$$

解读：同 NW，但把「 Y_i 」替换为**指示函数** $\mathbb{1}\{Y_i \leq y\}$ 。在 Y 二元 ($Y \in \{0, 1\}$) 情形下：

$$\hat{F}(0 | x) = \hat{P}(Y = 0 | X = x), \quad \hat{F}(1 | x) = 1,$$

即条件 CDF 估计恰好给出二元选择的条件概率——这是 NW 在 $Y \in \{0, 1\}$ 时的直接应用。

双窗宽: Li & Racine 推荐在 y 方向也引入窗宽 (光滑版 CDF) :

$$\hat{F}_{h_1, h_2}(y | x) = \frac{\sum_i K_{h_1}(x - X_i) G_{h_2}(y - Y_i)}{\sum_i K_{h_1}(x - X_i)},$$

其中 G 是积分核 (如 $G(u) = \int_{-\infty}^u K(v)dv$)。提高 y 方向光滑度 $\Rightarrow$ 二阶连续可导 $\hat{F}$ 。

条件 CDF 的大样本性质 (Li-Racine 定理 6.1, 6.2)

定理 8 (Li & Racine 2007, Thm 6.1) : 在正则性条件下, 对光滑化条件 CDF,

$$\sqrt{nh_1} [\hat{F}(y | x) - F(y | x) - \text{偏误}] \xrightarrow{d} \mathcal{N}(0, V_F(y, x)),$$

其中 $V_F(y, x) = R(K)F(y|x)[1 - F(y|x)]/f_X(x)$ 。

定理 9 (Li & Racine 2007, Thm 6.2) : 对任意有界连续泛函 ψ ,

$$\hat{\tau} = \int \psi(y) d\hat{F}(y | x), \quad \sqrt{nh_1}(\hat{\tau} - \tau) \xrightarrow{d} \mathcal{N}(0, V_\tau).$$

适用于: **条件分位数** $\hat{q}_\alpha(x) = \hat{F}^{-1}(\alpha | x)$, **条件矩** $E[g(Y)|X = x]$ 。

二元选择应用: $\hat{P}(Y = 1 | X = x) = 1 - \hat{F}(0 | x)$ ——所有关于 CDF 的非参数推断工具直接用于二元选择。

规格检验与二元选择的非参数应用

参数模型检验的核心问题：

$$H_0 : m(x) = m_{\theta}(x) \text{ 对某 } \theta \quad \text{vs.} \quad H_1 : m(x) \neq m_{\theta}(x) \quad \forall \theta.$$

在二元选择语境： $H_0 : P(Y = 1|X = x) = \Phi(x'\beta)$ (Probit 正确) 。

基本思路： 构造一个距离指标衡量「参数模型 vs. 非参数估计」：

$$T_n = \int [\hat{m}_{NW}(x) - m_{\hat{\theta}}(x)]^2 w(x) dx.$$

在 H_0 下 $T_n \rightarrow 0$ (参数一致) ； 在 H_1 下 T_n 有正的极限。

技术障碍： T_n 的极限分布**退化** (两项都是非参数估计 $\rightarrow$ 慢收敛) ——需要特殊重新标准化。
两种经典检验：

1. **Härdle–Mammen (1993)**——基于平方差分，用 Wild Bootstrap 近似分布；
2. **Li–Zheng (1996, 1998)**——基于**条件矩** $E[u g(X)] = 0$ ，自然退化项消去。

Härdle–Mammen 检验统计量

$$T_n^{\text{HM}} = \int [\hat{m}_{\text{NW}}(x) - K_h * m_{\hat{\theta}}(x)]^2 \hat{f}_X(x)^2 w(x) dx,$$

其中 $K_h * m_{\hat{\theta}}(x) = \int K_h(x - u)m_{\hat{\theta}}(u)du$ 是平滑化的参数模型（必须！）。

为什么要平滑参数模型？不平滑则 $\hat{m}_{\text{NW}} - m_{\hat{\theta}}$ 的偏误项相互不消，测试失效。

定理 10 (Härdle–Mammen 1993) : 在 H_0 下,

$$nh^{d/2}(T_n^{\text{HM}} - \mu_n) \xrightarrow{d} \mathcal{N}(0, V_0),$$

但 μ_n, V_0 依赖未知 $\sigma^2(x), f_X(x)$ ——**实务中 Härdle–Mammen 建议 Wild Bootstrap.**

► 证明

Wild Bootstrap 近似（关键步骤）：

1. 生成 $Y_i^* = m_{\hat{\theta}}(X_i) + \hat{u}_i v_i$ （注意：**用参数模型而非 NW**作为中心——这是 H_0 下的正确重抽样）；
2. 对每个自助样本计算 $T_n^{HM,*(b)}$ ；
3. p 值 = $B^{-1} \sum_b \mathbb{1}\{T_n^{HM,*(b)} \geq T_n^{HM}\}$ 。

为什么 Wild Bootstrap 有效： v_i 的三阶矩 $E[v^3] = 1$ 保证自助分布复制二阶精度；中心用 $m_{\hat{\theta}}$ 保证在 H_0 下抽样合法。详见 §8。

Li-Zheng 统计量 (Li 1996, Zheng 1996)

$$T_n^{LZ} = \frac{1}{n(n-1)h^{d/2}} \sum_i \sum_{j \neq i} \hat{u}_i \hat{u}_j K\left(\frac{X_i - X_j}{h}\right),$$

其中 $\hat{u}_i = Y_i - m_{\hat{\theta}}(X_i)$ 是**参数残差**。

直觉：若 H_0 成立， $\hat{u}_i$ 与 X_i 独立 $\Rightarrow E[\hat{u}_i \hat{u}_j K((X_i - X_j)/h)] \rightarrow 0$ ；若 H_1 成立， $\hat{u}_i$ 与 X_i 相关 $\Rightarrow$ 相邻残差有**同向偏误** $\Rightarrow T_n^{LZ}$ 有正偏倚。

定理 11 (Li 1996) : 在 H_0 下,

$$T_n^{LZ} / \hat{\Omega}_n \xrightarrow{d} \mathcal{N}(0, 1),$$

其中 $\hat{\Omega}_n^2 = \frac{2}{n^2(n-1)^2h^d} \sum_{i \neq j} \hat{u}_i^2 \hat{u}_j^2 K^2((X_i - X_j)/h)$ 是一致方差估计。

Li-Zheng 的优势: 不涉及 $\hat{m}_{NW}$ 的显式计算——**直接基于条件矩** $E[u|X] = 0$ 。结构简单、无需选择 $\hat{m}$ 的窗宽（只需 h 用于权重核），渐近分布解析。

两种检验的权衡：

	Härdle–Mammen	Li–Zheng
构造基础	比较 $\hat{m}_{NW}$ 与 $m_{\hat{\theta}}$	条件矩 $E[u X] = 0$
非参数估计	需要 $\hat{m}_{NW}$	不需要
临界值	Wild Bootstrap	渐近 $\mathcal{N}(0, 1)$
窗宽	$\hat{m}$ 和权重核两个	仅权重核
计算	贵（自助模拟）	快（闭式）
功效	强，尤其对局部偏离	中等，对特定备择偏弱

Zhou (§3.6) 实务建议：

1. **默认**使用 Li-Zheng（快、标准正态）；
2. 若**怀疑特定形式偏离**（如遗漏非线性项），用 Härdle-Mammen + Wild Bootstrap（功效更高）；
3. 两者**都通过** $\Rightarrow$ 参数模型未被数据拒绝；一个拒绝 $\Rightarrow$ 报告两个结果并讨论差异。

非参数估计 $P(Y = 1|X = x)$: 定义

核心应用（回到本讲主线）： 用 NW 或 LL 估计二元选择中的条件概率。

非参数二元选择估计量

$$\hat{P}(Y = 1 | X = x) = \hat{m}_{NW}(x) = \frac{\sum_{i=1}^n K_h(x - X_i) Y_i}{\sum_{i=1}^n K_h(x - X_i)},$$

或**局部线性**版本：

$$\hat{P}_{LL}(Y = 1 | X = x) = \hat{\beta}_0(x) \text{ from LL regression.}$$

关键性质:

- ▶ **NW 自动** $\in [0, 1]$ ——凸组合, 估计值天然有效概率;
- ▶ **LL 可能** $\notin [0, 1]$ ——需截断或改用 **local logit** (Tibshirani & Hastie 1987);
- ▶ **边际效应** $\hat{ME}_j(x) = \partial \hat{P} / \partial x_j$ 可通过 LL 的 $\hat{\beta}_j$ 或数值微分计算;
- ▶ **异质性可视化**——画 $\hat{P}(x)$ 曲线直接显示概率随 X 的变化。

非参数 vs. 参数二元选择：系统对比

方面	参数方法 (Probit/Logit)	非参数方法 (NW/LL)
模型设定	$P(Y = 1 X) = \Phi(x'\beta)$ 或 $\Lambda(x'\beta)$	$P(Y = 1 X) = m(x)$
形状灵活性	S 形、单调	任意光滑形状
估计	MLE, $\sqrt{n}$ 率	加权平均, $\sqrt{nh}$ 率
识别	函数形式 + 参数识别	光滑性 + 矩条件
边际效应	$\phi(x'\hat{\beta})\hat{\beta}_j$ (APE/PEA)	$\hat{\beta}_j^{LL}(x)$ (LL 局部斜率, 逐点导数)
推断	SE _j 由 Fisher 信息	Wild Bootstrap 或欠平滑
维数诅咒	无	严重 ($d \geq 3$ 难处理)
异常点	稳健 (MLE 压缩)	局部敏感
外推	可到支撑外 (但依赖形式)	不可 (需数据支持)

实务混合策略：

1. 先用 NW/LL 绘制 $\hat{P}(x)$ ——探索形状；
2. 若形状与 Φ 或 Λ 吻合——用参数方法报告结果；
3. 若形状明显偏离——考虑半参数方法（S3：单指标、Klein-Spady、平滑最大得分）；
4. 若维数过高——一定要引入结构（Probit as benchmark, 非参数 as robustness check）。

非参数边际效应

$$ME_j(x) = \frac{\partial P(Y = 1 | X = x)}{\partial x_j} = \frac{\partial m(x)}{\partial x_j}.$$

逐点估计（局部线性）： 运行 $p = 1$ 局部多项式，取 j 维的斜率系数：

$$\hat{ME}_j(x) = \hat{\beta}_j(x).$$

平均效应 (Average Derivative)：

$$\widehat{AME}_j = \frac{1}{n} \sum_{i=1}^n \hat{ME}_j(X_i).$$

平均导数估计量的惊人性质：

$$\sqrt{n}(\widehat{AME}_j - AME_j) \xrightarrow{d} \mathcal{N}(0, V).$$

即使 $\widehat{ME}(x)$ 收敛率慢 ($\sqrt{nh}$)，其对 X 积分的平均值恢复到参数率 $\sqrt{n}$ ！

解释：空间平均消除了非参数偏差——就像 $\sqrt{n}$ -consistent 的 OLS 估计量。Powell–Stock–Stoker (1989) 用此思想构造半参数估计量 (S3 将详细讨论)。

三大瓶颈：

1. **维数诅咒**—— $d \geq 3$ 时收敛率已不可接受。经济实证中常有 $d = 10 \sim 20$ 控制变量；
2. **边界偏误**——许多应用中感兴趣区域在 X 分布尾部（最低收入者、最高年龄段、政策阈值）；
3. **推断复杂**——偏误不消失，需 Wild Bootstrap 或 CCT，实务门槛高。

这些局限驱动了半参数方法的发展：

半参数方法的共同思想（S3 预告）：在参数结构与非参数灵活性之间寻求**中间地带**。

- ▶ **单指标模型**——保留 $x'\beta$ 线性指标，释放链接函数：**维数从 d 降到 1**；
- ▶ **Ichimura (1993) SLS**——基于非参数 NW 的两步半参数估计；
- ▶ **Klein-Spady (1993)**——半参数 MLE，达到信息下界；
- ▶ **Manski (1975) 最大得分**——**完全释放误差分布**，但 $n^{1/3}$ 收敛率；
- ▶ **Horowitz (1992) 平滑最大得分**—— $n^{2/5}$ 率改进。

检验 Probit 设定正确性

问题：研究者估计了 Probit 模型 $P(Y = 1|X) = \Phi(X'\beta)$ ，要检验链接函数 Φ 是否正确。

Li-Zheng 检验步骤：

1. 用 MLE 估计 $\hat{\beta}$ ，得残差 $\hat{u}_i = Y_i - \Phi(X_i'\hat{\beta})$ ；
2. 选权重核窗宽 h （通常 $h = c\hat{\sigma}_X n^{-1/(4+d)}$ ）；
3. 计算 $T_n^{LZ} = \frac{1}{n(n-1)h^{d/2}} \sum_{i \neq j} \hat{u}_i \hat{u}_j K((X_i - X_j)/h)$ ；
4. 与 $\hat{\Omega}_n$ 标准化： $t\text{-stat} = T_n^{LZ} / \hat{\Omega}_n$ ；
5. **单尾检验：**若 $t > z_{0.95} = 1.645$ ，拒绝 H_0 （Probit 设定）。

若拒绝：

- ▶ 考虑 Logit（简单替代）或非参数替代；
- ▶ 进入 S3 的单指标/Klein-Spady 方法寻找更灵活的设定。

总结与 S3 预告

方法	模型	主要参数	收敛率	典型应用
EDF	$\hat{F}_n(x)$	无	$\sqrt{n}$	分布函数估计
直方图	桶内频率	桶宽 h	$n^{-1/3}$	探索性分析
KDE	$\hat{f}_h(x) = \frac{1}{nh} \sum K_h$	窗宽 h	$n^{-2/5}$	密度估计
NW 核回归	$\frac{\sum K_h Y_i}{\sum K_h}$	h	$n^{-2/5}$	一维回归
Local Linear	WLS with $(X_i - x)$	h	$n^{-2/5}$	RDD, 内点 + 边界
Local Poly(p)	WLS 到 p 阶	h, p	$n^{-2/5}$ 或更快	导数估计
级数方法	$\sum_k c_k p_k(x)$	项数 K	$n^{-2s/(2s+d)}$	多维回归
离散/混合核	$L \cdot K$ 乘积	h, λ	同核方法	离散协变量
条件 CDF	NW for $\mathbb{1}\{Y \leq y\}$	h_1, h_2	$n^{-2/5}$	条件分位数
规格检验 (LZ)	$\frac{1}{n(n-1)h^{d/2}} \sum \hat{u} \hat{u} K$	h	渐近 $N(0, 1)$	参数检验

一句话总结：所有非参数估计的核心都是「局部 + 光滑 + 权衡」——局部信息构造估计，光滑参数控制局部大小，偏误-方差权衡给出最优参数。

参数 vs. 半参数 vs. 非参数:

	参数 (S1)	非参数 (S2)	半参数 (S3)
模型	$P(Y = 1 X) = \Phi(x'\beta)$	$P(Y = 1 X) = m(x)$	$P(Y = 1 X) = G(x'\beta)$
未知量	$\beta \in \mathbb{R}^k$	$m \in \mathcal{F}$	$\beta \in \mathbb{R}^k, G \in \mathcal{G}$
$\hat{\beta}$ 率	$\sqrt{n}$	N/A	$\sqrt{n}$
$\hat{m}$ (或 $\hat{G}$) 率	——	$n^{-2/(4+d)}$	$n^{-2/5}$ (1 维 G)
设定风险	高 (形式错即不一致)	低	低
维数诅咒	无	严重	轻 ($\hat{G}$ 只需 1 维)
典型方法	MLE、IV Probit	NW、LL、级数	Ichimura, KS, 最大得分

策略进阶:

S1 参数 $\xrightarrow{\text{释放 } G}$ S3 半参数 $\xrightarrow{\text{释放 } x'\beta}$ S2 非参数

实务中最常用**S3 半参数**——保留最重要的参数结构 (线性指标), 释放次重要的结构 (链接函数)。

S3 核心方法预览:

1. 单指标模型 (Single-Index Model)

$$E[Y|X = x] = G(x'\beta), \quad G(\cdot) \text{ 未知.}$$

2. Ichimura (1993) 半参数最小二乘 (SLS)——两步法:

- ▶ Step 1: 对每个 β , 用 NW 估计 $\hat{G}_\beta(\cdot)$;
- ▶ Step 2: 求 $\hat{\beta} = \arg \min_\beta \sum [Y_i - \hat{G}_\beta(X_i'\beta)]^2$.

3. Klein–Spady (1993) 半参数 MLE——达到半参数效率下界。

4. Manski (1975) 最大得分估计量——只需中位数独立, $n^{1/3}$ 率。

5. Horowitz (1992) 平滑最大得分——改进到 $n^{2/5}$ 率。

衔接点: S3 将频繁使用本讲的核密度估计、NW 回归、Li–Zheng 检验作为组件——本讲打下的基础是 S3 一切方法的必要工具。

谢谢!

Thank You

下讲 (LectureS3) 预告

二元选择模型：半参数方法

Ichimura SLS · Klein–Spady MLE · 最大得分 · 平滑最大得分

Binary Choice Models: Semiparametric Methods

Jia Chengye | SUFE School of Economics | Spring 2026

附录 B.1: 条件期望的最优性

命题: $m(x) = E[Y|X = x]$ 最小化 $E[(Y - g(X))^2]$ 。

证明: 对任意可测 g ,

$$\begin{aligned} E[(Y - g(X))^2] &= E\{[(Y - m(X)) + (m(X) - g(X))]^2\} \\ &= E[(Y - m(X))^2] + 2E\{[Y - m(X)][m(X) - g(X)]\} + E[(m(X) - g(X))^2]. \end{aligned}$$

关键: 交叉项为零——由 LIE,

$$E\{[Y - m(X)][m(X) - g(X)]\} = E\{E[Y - m(X)|X][m(X) - g(X)]\} = E\{0 \cdot \dots\} = 0.$$

故 $E[(Y - g(X))^2] = E[(Y - m(X))^2] + E[(m(X) - g(X))^2] \geq E[(Y - m(X))^2]$, 等号当且仅当 $g \equiv m$ 几乎处处。□

[◀ 返回主文](#)

附录 B.2: Epanechnikov 核最优性

命题: 在 $\int K = 1$ 、 $\int uK = 0$ 、 $\int u^2 K = \kappa_2$ 固定下, $K_{\text{Ep}}^*(u) = \frac{3}{4}(1 - u^2)\mathbb{1}\{|u| \leq 1\}$ 最小化 $R(K) = \int K^2$ 。

证明 (变分法) : 用拉格朗日乘子构造

$$\mathcal{L}[K] = \int K^2 - \lambda_0 \int K - \lambda_2 \int u^2 K.$$

一阶条件: $2K(u) = \lambda_0 + \lambda_2 u^2$, 即 $K(u) = a + bu^2$ (在某区间上非负)。

求解乘子: 设支撑为 $[-c, c]$, $K(u) = a + bu^2$ 且 $K(\pm c) = 0 \Rightarrow a = -bc^2$ 。代入约束 $\int K = 1$, $\int u^2 K = \kappa_2 = 1/5$, 解得 $c = 1$, $a = 3/4$, $b = -3/4$:

$$K^*(u) = \frac{3}{4}(1 - u^2)\mathbb{1}\{|u| \leq 1\}. \quad \square$$

[◀ 返回主文](#)

附录 B.3: KDE 偏误详细推导

起点:

$$E[\hat{f}_h(x)] = \int \frac{1}{h} K\left(\frac{x-u}{h}\right) f(u) du.$$

换元 $v = (x - u)/h$, $u = x - hv$, $du = -h dv$:

$$E[\hat{f}_h(x)] = \int K(v) f(x - hv) dv.$$

Taylor 展开 $f(x - hv) = f(x) - hvf'(x) + \frac{h^2 v^2}{2} f''(x) - \frac{h^3 v^3}{6} f'''(x) + O(h^4)$:

$$\begin{aligned} E[\hat{f}_h(x)] &= f(x) \int K - hf'(x) \int vK + \frac{h^2}{2} f''(x) \int v^2 K \\ &\quad - \frac{h^3}{6} f'''(x) \int v^3 K + O(h^4). \end{aligned}$$

用核条件: $\int K = 1$; $\int vK = 0$ (对称); $\int v^2 K = \kappa_2$; $\int v^3 K = 0$ (对称):

$$E[\hat{f}_h(x)] = f(x) + \frac{h^2 \kappa_2}{2} f''(x) + O(h^4).$$

故 Bias = $\frac{h^2 \kappa_2}{2} f''(x) + O(h^4)$ 。□

附录 B.4: NW 偏误 Taylor 展开

记 $\varphi(u) = m(u)f_X(u)$ 。分子 $E[\hat{m}_1(x)] = \int K(v)\varphi(x-hv)dv$ 展开:

$$E[\hat{m}_1(x)] = \varphi(x) + \frac{h^2\kappa_2}{2}\varphi''(x) + O(h^4).$$

由 $\varphi'' = m''f_X + 2m'f'_X + mf_X''$:

$$E[\hat{m}_1(x)] = m(x)f_X(x) + \frac{h^2\kappa_2}{2}[m''f_X + 2m'f'_X + mf_X''] + O(h^4).$$

分母: $E[\hat{f}_X(x)] = f_X(x) + \frac{h^2\kappa_2}{2}f_X''(x) + O(h^4)$.

比率的一阶 Taylor 展开: $\hat{m} = \hat{m}_1/\hat{f}_X \approx \hat{m}_1/f_X - \hat{m}_1(\hat{f}_X - f_X)/f_X^2 + \dots$

取期望并代入:

$$\text{Bias}[\hat{m}_{\text{NW}}(x)] = \frac{h^2\kappa_2}{2} \cdot \frac{m''(x)f_X(x) + 2m'(x)f'_X(x) + m(x)f_X''(x) - m(x)f_X''(x)}{f_X(x)}.$$

化简: mf_X'' 项抵消 (来自 φ'' 减去 m 倍的 $\hat{f}_X$ 偏误):

$$\text{Bias}[\hat{m}_{\text{NW}}(x)] = \frac{h^2\kappa_2}{2} \left[m''(x) + 2\frac{m'(x)f'_X(x)}{f_X(x)} \right] + o(h^2). \quad \square$$

附录 B.5: NW 渐近正态性

策略: 用「分子-分母 + Slutsky」分解。

Step 1: 令 $Z_{n,i} = \frac{1}{h} K\left(\frac{x-X_i}{h}\right) [Y_i - m(x)]$ 。则

$$\sqrt{nh}[\hat{m}_{NW}(x) - m(x)] = \frac{\frac{1}{\sqrt{nh}} \sum_i Z_{n,i}}{\hat{f}_X(x)}.$$

Step 2: 对分子应用 Lindeberg CLT (三角序列 CLT)。计算 $\text{Var}(Z_{n,i})$:

$$h \cdot \text{Var}(Z_{n,i}) \rightarrow f_X(x) \sigma^2(x) R(K) \quad (h \rightarrow 0).$$

并验证 Lindeberg 条件 $\sum \text{Var}(Z)^{-1} E[Z^2 \mathbf{1}\{|Z| > \epsilon \sqrt{n}\}] \rightarrow 0$ (利用 $E[|Y|^{2+\delta} | X] < \infty$)。

Step 3: $\hat{f}_X(x) \xrightarrow{P} f_X(x)$ (LLN), 由 Slutsky:

$$\sqrt{nh}[\hat{m}_{NW}(x) - m(x) - B_{NW}(x)h^2] \xrightarrow{d} \mathcal{N}\left(0, \frac{R(K)\sigma^2(x)}{f_X(x)}\right). \quad \square$$

附录 B.6: 局部线性渐近正态性

矩阵形式: $\hat{\beta}(x) = (\mathbf{X}'_x \mathbf{W}_x \mathbf{X}_x)^{-1} \mathbf{X}'_x \mathbf{W}_x \mathbf{Y}$ 。

关键引理 (S_j 的渐近行为) :

$$S_j(x) = \frac{1}{n} \sum_i K_h(x - X_i)(X_i - x)^j = f_X(x) h^j \mu_j + h^{j+1} \mu_{j+1} f'_X(x) + O_p(h^{j+2}),$$

其中 $\mu_j = \int v^j K(v) dv$ ($\mu_0 = 1, \mu_1 = 0, \mu_2 = \kappa_2$) 。

主要结论 (Fan & Gijbels 1996, Thm 3.1) :

$$\sqrt{nh} \left[\hat{\beta}_0(x) - m(x) - \frac{h^2 \kappa_2}{2} m''(x) \right] \xrightarrow{d} \mathcal{N} \left(0, \frac{R(K) \sigma^2(x)}{f_X(x)} \right).$$

关键观察: 偏误**不含设计密度项**—— f'_X 通过 LL 的「斜率项」被吸收。

证明梗概: 展开 $(\mathbf{X}'_x \mathbf{W}_x \mathbf{X}_x)^{-1}$ 到二阶, $\mathbf{e}'_0$ 投影抽出第 0 分量, f'_X 项在分子与 $(X_i - x)$ 项交互后相消。□

[◀ 返回主文](#)

附录 B.7: AMISE 最优窗宽推导

AMISE:

$$\text{AMISE}(h) = \frac{h^4}{4} \kappa_2^2 R(f'') + \frac{R(K)}{nh}.$$

对 h 求导:

$$\frac{d \text{AMISE}}{dh} = h^3 \kappa_2^2 R(f'') - \frac{R(K)}{nh^2} = 0.$$

解得:

$$h^5 = \frac{R(K)}{\kappa_2^2 R(f'') n}, \quad \Rightarrow \quad h^* = \left[\frac{R(K)}{\kappa_2^2 R(f'')} \right]^{1/5} n^{-1/5}.$$

代入 AMISE:

$$\text{AMISE}(h^*) = \frac{h^{*4}}{4} \kappa_2^2 R(f'') + \frac{R(K)}{nh^*} = \frac{5}{4} [\kappa_2^2 R(f'')]^{1/5} R(K)^{4/5} n^{-4/5}.$$

二阶条件: $\frac{d^2 \text{AMISE}}{dh^2} > 0$ —— h^* 是全局最小。□

$n^{-4/5}$ 的下界性质: Stone (1980) 证明这是**二阶光滑密度估计的最小最大率**——任何估计量都不能渐近超过该率。

附录 B.8: NW 相合性证明

命题: 在 (NW-1)–(NW-6) 下, $\hat{m}_{NW}(x) \xrightarrow{P} m(x)$ 。

证明: 通过 $MSE \rightarrow 0$ 。

$$MSE[\hat{m}_{NW}(x)] = \text{Bias}^2 + \text{Var}.$$

已证:

$$\text{Bias} = O(h^2), \quad \text{Var} = O(1/nh).$$

条件: $h \rightarrow 0$, $nh \rightarrow \infty$ 。故

$$MSE = O(h^4) + O(1/nh) \rightarrow 0.$$

由 Chebyshev 不等式: $\hat{m}_{NW}(x) \xrightarrow{L^2} m(x) \Rightarrow \hat{m}_{NW}(x) \xrightarrow{P} m(x)$ 。□

推广到均匀相合: 在紧集 $\mathcal{X}_0 \subset \{x : f_X(x) \geq \epsilon\}$ 上,

$$\sup_{x \in \mathcal{X}_0} |\hat{m}_{NW}(x) - m(x)| = O_p\left(\sqrt{\frac{\log n}{nh}}\right) + O(h^2).$$

证明需用到 Bernstein 型不等式 + 核函数 Lipschitz 性——超出本讲范围, 见 Einmahl & Mason (2005)。

附录 B.9: Wild Bootstrap 一致性

目标: 证明自助分布与真分布渐近相同。

Step 1: 条件分布恒等式

$$Y_i^* - \hat{m}(X_i) = \hat{u}_i v_i.$$

由 $E[v_i] = 0$, $E[v_i^2] = 1$, $E[v_i^3] = 1$ 和独立性:

$$E^*[Y_i^* | X_i] = \hat{m}(X_i), \quad \text{Var}^*[Y_i^* | X_i] = \hat{u}_i^2 \xrightarrow{p} \sigma^2(X_i).$$

Step 2: 自助分布的 CLT 把 Lindeberg CLT 应用于自助样本:

$$\sqrt{nh}(\hat{m}^*(x) - \hat{m}(x)) \mid \text{样本} \xrightarrow{d} \mathcal{N}(0, V(x)) \text{ 依概率.}$$

Step 3: 匹配偏误 自助的偏误来自 $E^*[\hat{m}^*(x) - \hat{m}(x)] = (\hat{m} \text{ 依 } X_i \text{ 的函数平滑}) \approx B(x)h^2$ ——复制了真实偏误。

关键: $E[v^3] = 1$ 保证 Edgeworth 展开的三阶项也匹配——二阶精确性。□

[← 返回主文](#)

附录 B.10: 级数估计渐近正态性

命题: (Newey 1997) $\sqrt{n/K}[\hat{m}_K(x) - m(x) - b_K(x)]/s_K(x) \xrightarrow{d} \mathcal{N}(0, 1)$.

证明梗概 (三步):

Step 1: 分解

$$\hat{m}_K(x) - m(x) = p(x)'(\mathbf{P}'\mathbf{P})^{-1}\mathbf{P}'\mathbf{Y} - m(x) = \underbrace{A_n}_{\text{随机}} + \underbrace{b_K(x)}_{\text{近似误差}}.$$

Step 2: A_n 的 CLT

$$A_n = p(x)'(\mathbf{P}'\mathbf{P})^{-1}\mathbf{P}'\mathbf{u} = \sum_i \omega_{n,i} u_i,$$

其中 $\omega_{n,i} = p(x)'(\mathbf{P}'\mathbf{P})^{-1}p(X_i)$ 。

由 Lindeberg CLT (需 $\max_i \omega_{n,i}^2 / \sum_i \omega_{n,i}^2 \rightarrow 0$) , $A_n/s_K(x) \xrightarrow{d} \mathcal{N}(0, 1)$ 。

Step 3: 近似误差可忽略 若 $K \rightarrow \infty$ 且 $\sqrt{n/K} \cdot b_K(x) \rightarrow 0$ (欠平滑条件) , 则 Slutsky 给出最终结果。□

推广: 异方差 sandwich 方差 $\hat{s}_K^2(x)$ 的构造与 OLS 完全相同——级数方法可直接套用参数 VCE 工具。

附录 B.11: 条件 CDF 渐近正态性 (Li–Racine Thm 6.1)

目标: 证 $\sqrt{nh_1}[\hat{F}(y|x) - F(y|x) - \text{偏误}] \xrightarrow{d} \mathcal{N}(0, V_F)$ 。

类比 NW: 把 Y_i 换为 $\mathbb{1}\{Y_i \leq y\}$, 此时

$$E[\mathbb{1}\{Y \leq y\}|X = x] = F(y|x), \quad \text{Var}[\mathbb{1}\{Y \leq y\}|X = x] = F(y|x)[1 - F(y|x)].$$

直接套用 NW CLT 结果:

$$\sqrt{nh_1}[\hat{F}(y|x) - F(y|x) - \text{偏误}] \xrightarrow{d} \mathcal{N}\left(0, \frac{R(K)F(y|x)[1 - F(y|x)]}{f_X(x)}\right).$$

偏误项: $\frac{h_1^2 \kappa_2}{2} [\partial^2 F / \partial x^2 + 2(\partial F / \partial x)(f'_X / f_X)]$ (与 NW 相同结构)。

Thm 6.2 推广: 对任意泛函 $\tau = \int \psi(y) dF(y|x)$,

$$\sqrt{nh_1}(\hat{\tau} - \tau) \xrightarrow{d} \mathcal{N}(0, V_\tau),$$

$V_\tau = \int \int \psi(y)\psi(y') dV_F(y, y', x)$ ——证明用**泛函 delta 方法**。□

附录 B.12: Härdle–Mammen 检验渐近分布

命题: 在 $H_0: m(x) = m_\theta(x)$ 下,

$$nh^{d/2}(T_n^{\text{HM}} - \mu_n) \xrightarrow{d} \mathcal{N}(0, V_0).$$

证明骨架:

Step 1: 分解 T_n^{HM}

$$\begin{aligned} T_n^{\text{HM}} &= \int [\hat{m}_{\text{NW}}(x) - (K_h * \hat{m}_{\hat{\theta}})(x)]^2 \hat{f}_X(x)^2 w(x) dx \\ &= \int \underbrace{[\hat{m}_{\text{NW}}(x) - (K_h * m)(x)]^2}_{\text{只含噪声 } u} \hat{f}_X^2 w dx + O_p(\text{参数率}). \end{aligned}$$

关键: 参数误差 $\hat{\theta} - \theta_0$ 以 $\sqrt{n}$ 速度收敛, 而非参数项以 $\sqrt{nh^d}$ 速度收敛——**非参数项主导**。

Step 2: 二阶 U 统计量表示 T_n^{HM} 可近似为退化二阶 U 统计量 $\sum_{i \neq j} u_i u_j K_{2h}((X_i - X_j)/2)$, 应用 Hall (1984) 的退化 U 统计量 CLT:

$$nh^{d/2} T_n^{\text{HM}} \xrightarrow{d} \mathcal{N}(\mu_\infty, V_0).$$

Step 3: Wild Bootstrap 一致——模拟 H_0 下的重抽样, p 值合法。□