

二元选择模型：半参数方法

Binary Choice Models: Semiparametric Methods

Intermediate Econometrics

Jia Chengye

School of Economics
Shandong University of Finance and Economics

Spring 2026

半参数方法的动因与定位

部分线性模型 (简介)

单指数模型：定义与识别

Ichimura (1993) 半参数最小二乘

PSS 加权平均导数估计量

Klein-Spady (1993) 半参数 MLE

Han (1987) 最大秩相关估计量 (MRC)

Manski (1975) 最大得分估计量

Horowitz (1992) 平滑最大得分估计量

Lewbel (2000) 特殊回归元估计量

检验与诊断

其他半参数模型简介

倾向得分与 IPW 应用

实证应用：MROZ 女性劳动参与

总结与课程结束

半参数方法的动因与定位

本系列三讲从不同角度估计二元选择模型 $\Pr(Y = 1 \mid X)$:

	参数 (S1)	非参数 (S2)	半参数 (S3)
模型形式	$\Pr(Y = 1 \mid X) = G(X'\beta)$, G 已知	$\Pr(Y = 1 \mid X) = m(X)$, m 完全未知	$\Pr(Y = 1 \mid X) = G(X'\beta)$, G 未知
待估对象	有限维 β	无穷维函数 $m(\cdot)$	有限维 β + 未知函数 $G(\cdot)$
β 收敛速度	$\sqrt{n}$	—	$\sqrt{n}$
函数收敛速度	—	$n^{-2/(4+d)}$	$n^{-2/5}$ (一维 G)
错设定风险	高 (G 错则不一致)	几乎无 (无函数假设)	中 (G 自由, 但单指数结构需正确)

半参数方法的承诺：保留参数模型对 β 的 $\sqrt{n}$ 速度，同时放松对 G 的分布假设——**兼顾速度与稳健。**

维数诅咒：完全非参数方法的代价

完全非参数估计 $m(x) = \Pr(Y = 1 \mid X = x)$ 时，最优收敛速度依赖回归元维数 d ：

$$\text{MSE}\{\hat{m}(x)\} = O\left(n^{-\frac{4}{4+d}}\right) \quad \text{即} \quad \hat{m}(x) - m(x) = O_p\left(n^{-\frac{2}{4+d}}\right).$$

维数 d	收敛速度	达到 $\hat{m}$ 误差 0.01 所需样本	实际可行性
1	$n^{-2/5}$	$\approx 10^5$	容易
2	$n^{-1/3}$	$\approx 10^6$	可行
4	$n^{-1/4}$	$\approx 10^8$	困难
6	$n^{-1/5}$	$\approx 10^{10}$	几乎不可能
10	$n^{-1/7}$	$\approx 10^{14}$	不可能

结论：经济应用中 d 经常 ≥ 5 。完全非参数方法**不可行**。必须**施加部分结构**以恢复实用收敛速度——这是半参数方法的根本动机。

核心权衡：施加结构假设 $\Leftrightarrow$ 加快收敛速度，但承担错设定偏误风险。

方法	结构假设	速度	错设定后果
Probit / Logit (S1)	G 已知 (Φ 或 Λ)	$\sqrt{n}$	$\hat{\beta}$ 不一致 (偏误不消失)
完全非参数 (S2)	无	$n^{-2/(4+d)}$	几乎无 (仅维数诅咒)
半参数 (S3)	仅单指数结构	$\sqrt{n}$	单指数错则不一致; G 错无关紧要

半参数方法的智慧：在**单指数**这一较弱、可解释的结构假设下，把分布形态 G 留给数据决定。当此假设大致正确时，我们既**规避维数诅咒** (β 是 $\sqrt{n}$)，又**规避分布错设定** (G 由非参数恢复)。

半参数模型 (Semiparametric Model)

模型可表示为

$$m(X, Z; \theta) = m(X, Z; \beta, g)$$

其中:

- ▶ $\beta \in \mathbb{R}^k$: 有限维参数 (待估, 目标对象)
- ▶ $g(\cdot)$: 未知函数 (无穷维干扰参数 / nuisance parameter)

关键理论性质: 在适当条件下,

- ▶ $\hat{\beta}$ 以 $\sqrt{n}$ 速度收敛, 且渐近正态;
- ▶ $\hat{g}$ 以非参数速度 (如 $n^{-2/5}$) 收敛;
- ▶ $\hat{\beta}$ 的渐近分布**不受** $\hat{g}$ 估计误差影响 (adaptive) 。

两个收敛速度共存: 虽然 g 估计较慢, 但 β 仍可达到参数速度——因为 β 是有限维, 而 g 的估计误差在 β 的均值层面相互抵消。

二元选择中的半参数动机

为什么对二元选择特别重要？

在 S1（参数）中我们假设

$$\Pr(Y = 1 \mid X) = G(X'\beta), \quad G \in \{\Phi, \Lambda\}.$$

但 G 来自误差项分布的假设：

$$\varepsilon \sim \mathcal{N}(0, 1) \Rightarrow G = \Phi; \quad \varepsilon \sim \text{Logistic} \Rightarrow G = \Lambda.$$

若误差分布错设定：

- ▶ Probit MLE $\hat{\beta}_{\text{Probit}}$ 不一致（除非偶然 G 真的是 Φ ）
- ▶ 边际效应 APE 也不一致
- ▶ 异方差性下 Probit 全面失灵

半参数解决方案：假设 $\Pr(Y = 1 \mid X) = G(X'\beta)$ ，但让 G 由数据决定。保留单指数结构（即效用函数线性）以避免维数诅咒，但放弃 $G = \Phi$ 这一不可验证的分布假设。

$\sqrt{n}$ 与非参数速度并存看似矛盾，实际由“信息聚合”机制保证。

收敛速度的双层结构

在单指数模型 $\Pr(Y = 1 | X) = G(X'\beta)$ 中：

- ▶ **β 的估计**：将 n 个观测的信息合并为一个 k 维向量的估计；平均效应使个别误差相互抵消 $\Rightarrow \hat{\beta} - \beta_0 = O_p(n^{-1/2})$.
- ▶ **$G(\cdot)$ 的估计**：要在每个 u 点估计 $G(u)$ ，只能利用邻近 u 的观测；局部样本量 $\approx nh \ll n \Rightarrow \hat{G}(u) - G(u) = O_p((nh)^{-1/2})$ ，加上偏误项后整体速度 $n^{-2/5}$.

核心洞察：当我们关心 β 时， $\hat{G}$ 的估计误差被**平均掉**，具体表现为 $\hat{\beta} - \beta_0$ 的渐近方差中， $\hat{G}$ 的估计误差以二阶项形式出现，可被忽略。

本讲将主要研究单指数模型，但首先简介两个重要相关模型：

模型类别	函数形式	适用场景	本讲位置
部分线性模型 (PLM)	$Y = X'\beta + g(Z) + u$	X 为线性效应，Z 为非参数控制	Part 2 (简介)
单指数模型 (SIM)	$Y = G(X'\beta) + u$	Y 仅通过 $X'\beta$ 依赖 X	Part 3-7 (核心)
加法模型	$Y = \sum_l g_l(X_l) + u$	各回归元加法分离	Part 9 (简介)

为什么聚焦单指数模型？它是二元选择半参数化的自然推广：

- ▶ Probit/Logit 已经是单指数 ($G = \Phi$ 或 Λ)
- ▶ 半参数化 $\Leftrightarrow$ 仅放松 G 的形态
- ▶ 经济学解释力强： $X'\beta$ 为效用、净收益的线性近似

半参数效率界 (Newey 1990 简介)

效率界 (efficiency bound): 在给定模型类下渐近方差的下界。

半参数效率界

设 $\hat{\beta}$ 是任意 $\sqrt{n}$ 一致渐近正态估计量。在半参数模型 $\Pr(Y = 1 | X) = G(X'\beta)$ 下, 存在最小可能的渐近方差矩阵 $V^*(\beta_0)$, 使得对任何“正则”估计量 $\hat{\beta}$:

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V), \quad V \succeq V^*(\beta_0).$$

V^* 称为**半参数效率下界**。


Newey (1990) 关键结论:

- ▶ 当 G 已知时 (参数模型): 效率界 = Cramér-Rao 下界
- ▶ 当 G 未知时 (半参数): 效率界 **严格大于** 参数 CR 下界
- ▶ Klein-Spady (1993) 估计量**达到**半参数效率界
- ▶ Ichimura (1993) 估计量一般**不达到**效率界

含义: 放弃 G 已知的假设有“信息代价”, 但 Klein-Spady 的代价最小。

什么是“未知函数 G ”？

Probit/Logit 假设 G 是特定 CDF；半参数方法允许 G 是任何 $[0, 1]$ 单调函数。



半参数自由度：允许 G 是非对称（如左偏、右偏）、具有平台、尾部肥厚等任何符合 $[0, 1]$ 单调性的形态。Probit / Logit 都是**两种特定情形**，事先无法知道哪个对真实数据合适。

本讲围绕“二元选择模型的半参数估计”展开：

Part	内容	核心估计量
1	动机与定位	—
2	部分线性模型简介	Robinson (1988)
3	单指数模型：定义与识别	SIM 框架
4	Ichimura 半参数最小二乘 + PSS 加权平均导数	Ichimura (1993); PSS (1989)
5	Klein-Spady 半参数 MLE + Han MRC	Klein & Spady (1993); Han (1987)
6	Manski 最大得分	Manski (1975)
7	Horowitz 平滑最大得分 + Lewbel 特殊回归元	Horowitz (1992); Lewbel (2000)
8	检验与诊断	Hausman 类、链接函数检验
9	其他半参数模型	加法、变系数、多指数
10	倾向得分与 IPW	Hirano-Imbens-Ridder (2003)
11	实证应用：MROZ	八种方法对比
12	总结	决策树
附录	17 个证明帧	重要定理推导

学习目标：理解 $\sqrt{n}$ 一致性如何在 G 未知下保持；掌握八种估计量的识别条件、渐近性质、计算方法、适用情境。

部分线性模型（简介）

部分线性模型 (PLM): 作为半参数的概念桥梁

部分线性模型 (Partially Linear Model, Robinson 1988)

$$Y = X'\beta + g(Z) + u, \quad \mathbb{E}[u \mid X, Z] = 0.$$

- ▶ $X \in \mathbb{R}^k$: 以**线性形式**进入模型的回归元
- ▶ $Z \in \mathbb{R}^q$: 以**未知函数 $g(\cdot)$ 形式**进入的回归元
- ▶ 允许异方差: $\sigma^2(X, Z) = \text{Var}(u \mid X, Z)$

重要说明 (适用范围): PLM 的标准形式是为**连续** Y 设计的 (如工资、对数房价)。对二元 Y , 直接套用 PLM 等价于线性概率模型 + 非参数控制——继承 LPM 的所有问题 (预测概率超出 $[0, 1]$ 、异方差)。

为什么本讲仍要简介 PLM? 它展示了所有半参数方法共享的核心思想: **条件化 + 双残差 + $\sqrt{n}$ 估计 β** ——这些思想在 Ichimura、KS 中以变体形式重现。

Robinson (1988) *Econometrica*

Robinson (1988) 识别策略：条件化技巧

Robinson 的关键洞察：对原模型两侧条件 Z ,

$$\mathbb{E}[Y | Z] = \mathbb{E}[X | Z]' \beta + g(Z).$$

从原模型减去此式：

$$Y - \mathbb{E}[Y | Z] = (X - \mathbb{E}[X | Z])' \beta + u$$

两点同时成立：

- ▶ 未知函数 $g(Z)$ 被消去！
- ▶ 剩余模型是**线性回归**：将 $\tilde{Y} = Y - \mathbb{E}[Y | Z]$ 对 $\tilde{X} = X - \mathbb{E}[X | Z]$ 做 OLS 即可。

识别条件 (Class 5 §2)：

- ▶ $\Phi := \mathbb{E}[\tilde{X}\tilde{X}']$ 必须正定。
- ▶ 必要条件：(a) X 不含常数项；(b) X 的任何分量不是 Z 的确定函数。
- ▶ 否则 $\tilde{X} = X - \mathbb{E}[X | Z] = 0$, Φ 退化。

两步估计程序:

1. **第一步:** 用核回归 (或 series) 估计 $\hat{\mathbb{E}}[Y | Z]$ 与 $\hat{\mathbb{E}}[X | Z]$
2. **第二步:** 构造 $\hat{Y}_i = Y_i - \hat{\mathbb{E}}[Y | Z_i]$, $\hat{X}_i = X_i - \hat{\mathbb{E}}[X | Z_i]$
3. **第三步:** OLS 回归 $\hat{Y}_i$ 对 $\hat{X}_i$, 得到

$$\hat{\beta} = \left[\sum_{i=1}^n \hat{X}_i \hat{X}_i' \right]^{-1} \sum_{i=1}^n \hat{X}_i \hat{Y}_i.$$

Robinson 定理 ($\sqrt{n}$ 渐近正态性)

在适当正则条件下 (高阶核、 $h \rightarrow 0$ 、 $nh^4 \rightarrow \infty$ 、 $nb^4h^{4\nu} \rightarrow 0$ 等) :

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(0, \Phi^{-1} \Psi \Phi^{-1}),$$

其中 $\Phi = \mathbb{E}[\tilde{X}\tilde{X}']$, $\Psi = \mathbb{E}[\sigma^2(X, Z)\tilde{X}\tilde{X}']$.

► Robinson PLM 推导

为什么 $\hat{\beta}$ 仍能达到 $\sqrt{n}$ 速度?

考虑分解:

$$\hat{\beta} - \beta = \left[\sum_i \hat{X}_i \hat{X}_i' \right]^{-1} \sum_i \hat{X}_i \{ u_i - [\hat{\mathbb{E}}(Y | Z_i) - \mathbb{E}(Y | Z_i)] + [\hat{\mathbb{E}}(X | Z_i) - \mathbb{E}(X | Z_i)]' \beta \}.$$

三类项的渐近行为:

- ▶ u_i 项: 均值零、独立 $\Rightarrow$ 给出主项 $O_p(n^{-1/2})$
- ▶ 非参估计误差项: $O_p((nh^q)^{-1/2}) + O_p(h^{2\nu})$
- ▶ **关键:** 非参估计误差与 $\hat{X}_i$ 的乘积**被平均掉**, 贡献 $o_p(n^{-1/2})$

使用高阶核 (higher-order kernel): 用 $\nu \geq 2$ 阶核可使偏误降为 $O(h^{2\nu})$, 再配合带宽 $h \sim n^{-1/(4\nu)}$ 即可保证 $nh^{4\nu} \rightarrow 0$, **削掉**非参估计的偏误 $\Rightarrow \sqrt{n}$ 速度成立。

▶ 高阶核降偏证明

PLM 与二元选择：过渡到单指数模型

为什么 PLM 不直接用于二元选择？

设 $Y \in \{0, 1\}$ 。直接套用 PLM 给出

$$\Pr(Y = 1 \mid X, Z) = X'\beta + g(Z),$$

这等价于 **线性概率模型 + 非参数控制**。问题：

- ▶ 预测概率可能超出 $[0, 1]$
- ▶ 误差天然异方差，且似然不正确
- ▶ 边际效应可能不合理（例如对 X 的导数恒等于 β_j ，与 Probit/Logit 边际效应“凹形”不符）

二元选择的自然推广：将参数 $G(X'\beta)$ 中已知的 G 改为未知函数：

$$\Pr(Y = 1 \mid X) = G(X'\beta), \quad G \text{ 未知.}$$

这就是**单指数模型 (Single-Index Model)**——本讲核心。

从 PLM 到 SIM 的逻辑跳跃：PLM 中“ $X'\beta$ ”加入 $g(Z)$ ；SIM 中“ $X'\beta$ ”进入 $G(\cdot)$ 的指标。后者天然适配二元选择的非线性。

单指数模型：定义与识别

单指数模型 (Single-Index Model, SIM)

单指数模型 (一般形式)

$$Y = G(X'\beta_0) + u, \quad \mathbb{E}[u | X] = 0,$$

其中:

- ▶ $\beta_0 \in \mathbb{R}^k$: 未知有限维参数 (待估)
- ▶ $G(\cdot) : \mathbb{R} \rightarrow \mathbb{R}$: 未知函数 (待估)
- ▶ **单指数**: Y 仅通过**标量** $X'\beta_0$ 依赖 X

单指数模型 (二元选择特例)

$$\Pr(Y = 1 | X) = G(X'\beta_0), \quad Y \in \{0, 1\}.$$

此处 $G : \mathbb{R} \rightarrow [0, 1]$ 单调 (一般取连续 CDF) 。

语言对应: Probit/Logit 是单指数模型当 $G = \Phi$ 或 Λ 为已知; Ichimura、Klein-Spady、Manski、Horowitz 是单指数模型当 G 未知。

为什么用单指数? 降维

完全非参数 $\Pr(Y = 1 | X)$ 是 k 维函数, 需估计 $m: \mathbb{R}^k \rightarrow [0, 1]$, 速度 $n^{-2/(4+k)}$.
单指数 假设 $\Pr(Y = 1 | X) = G(X'\beta_0)$ 把 k 维“压缩”为一维:

$$\underbrace{m(x)}_{k\text{-dim}} = \underbrace{G}_{1\text{-dim}} \left(\underbrace{x'\beta_0}_{k \text{ vars} \rightarrow 1 \text{ scalar}} \right).$$

速度对比 ($k = 5$) :

- ▶ 完全非参数: $n^{-2/9} \approx n^{-0.22}$
- ▶ 单指数 G : $n^{-2/5} \approx n^{-0.40}$ (G 是**1 维**函数!)
- ▶ 单指数 β : $n^{-1/2} \approx n^{-0.50}$ (参数速度)

这是 SIM 的核心价值: 通过将 X 压缩为标量 $X'\beta$, 把 k 维平滑问题变为 1 维平滑问题——**彻底规避维数诅咒**。代价: 必须假设单指数结构正确。

SIM 的两个识别问题：位置与尺度

未加约束时，单指数模型不可识别。考虑两种“等价表达”：

1. **位置**： $G(X'\beta_0) = G^*(X'\beta_0 + c) = \tilde{G}(X'\beta_0)$ 其中 $\tilde{G}(u) := G^*(u + c)$ ，所以 β_0 中的常数项无法识别。
2. **尺度**： $G(X'\beta_0) = G^{**}(X' \cdot c\beta_0) = \tilde{\tilde{G}}(X'\beta_0 \cdot c)$ 其中 $\tilde{\tilde{G}}(u) := G^{**}(u/c)$ ，所以 β_0 的整体尺度无法识别。

两类正规化必须施加：

- ▶ **位置正规化 (location normalization)**： X 不含常数项（无截距）
- ▶ **尺度正规化 (scale normalization)**： $\|\beta_0\| = 1$ ，或令第一分量 $\beta_{01} = 1$ ，或固定某分量为已知值

含义：SIM 估计的 $\hat{\beta}$ 是**方向** (unit vector)，不是绝对水平。

Ichimura (1993); Hansen (2022) Ch.25

▶ 识别详细推导

识别假设 (SIM Identification, Ichimura 1993):

1. (位置正规化) X 不含常数项
2. (尺度正规化) $\|\beta_0\| = 1$ 或某分量固定
3. (连续型回归元) X 中至少有一个连续分布的分量, 且其对应 β 系数不为零
4. (G 非平凡) $G(\cdot)$ 不是常数函数
5. (参数空间紧) β_0 在紧集 $\Theta \subset \mathbb{R}^k$ 内部
6. (支撑条件) X 的支撑非奇异 (如 $\mathbb{E}[XX']$ 满秩)

为什么需要连续回归元? 如果 X 全是离散变量 (如二元、分类), 则 $X'\beta$ 仅取有限多个值, $G(\cdot)$ 在这些点之间不可识别。至少一个连续 X 让 $X'\beta$ 取连续值, 使 G 在足够丰富的点集上可估。

为什么需要 G 非平凡? 若 $G \equiv c$ 常数, 则任何 β 都给同样的 $\Pr(Y = 1 | X) = c$ 。

识别条件：连续回归元的关键作用

反例：所有 X 离散。 设 $k = 2$, $X_1, X_2 \in \{0, 1\}$ 。那么 $X'\beta = \beta_1 X_1 + \beta_2 X_2$ 仅取 4 个值： $\{0, \beta_1, \beta_2, \beta_1 + \beta_2\}$ 。

对每种 (X_1, X_2) 组合，我们只能识别概率 $\Pr(Y = 1 \mid X_1, X_2)$ 。共 4 个概率值。但单指数方程

$$G(\beta_1 X_1 + \beta_2 X_2) = \Pr(Y = 1 \mid X)$$

本质上是 4 个标量方程对 $(\beta_1, \beta_2, G(\cdot))$ 的约束。


识别失败： $G(\cdot)$ 是无穷维（一个函数），即使我们只关心其在 4 个点的取值，仍有无穷多种 (β_1, β_2, G) 组合产生相同的 4 个概率。 β **不可识别**。

修复方法： 至少加一个连续 X_3 （如年龄、收入），使 $X'\beta = \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$ 取连续多个值。 G 在连续区间上被识别 $\Rightarrow$ 通过形态约束 β_1, β_2 也被识别。

识别的几何直观：等指标面

$\Pr(Y = 1 | X) = G(X'\beta_0)$ 意味着条件概率沿等指标面恒定：

$$X'_a\beta_0 = X'_b\beta_0 \Rightarrow \Pr(Y = 1 | X_a) = \Pr(Y = 1 | X_b).$$



识别的几何含义：方向 β_0 决定等概率超平面的法向量； G 沿该法向量描述概率随指标值变化的形态。数据中相同 $X'\beta$ 的观测应有相同的 $\Pr(Y = 1)$ ——这是 SIM 的核心可检验含义。

收敛速度对比：参数 vs 半参数 vs 非参数

方法	$\hat{\beta}$ 速度	$\hat{G}$ 速度	说明
Probit / Logit (S1)	$n^{-1/2}$	不估 (G 已知)	MLE 效率
Ichimura (1993)	$n^{-1/2}$	$n^{-2/5}$	SLS; 不必效率
Klein-Spady (1993)	$n^{-1/2}$	$n^{-2/5}$	MLE 类; 达到效率界
Manski (1975)	$n^{-1/3}$	不估	仅识别方向
Horowitz (1992)	$n^{-2/5}$	不估	Manski 的平滑改进
完全非参数 (S2)	—	$n^{-2/(4+k)}$	无结构假设

速度对比解读：

- ▶ Ichimura、KS: β 与参数 MLE 同速 $\Rightarrow$ 半参数化几乎没有速度代价
- ▶ Manski: $n^{-1/3}$ 立方根速率, 远慢于 $\sqrt{n}$, 因目标函数不光滑
- ▶ Horowitz: 通过平滑恢复至 $n^{-2/5}$, 介于 Manski 与 Ichimura 之间
- ▶ 完全非参数随 k 增加而严重恶化 ($k=5$ 时 $n^{-0.22}$)

半参数效率：Klein-Spady 的角色

在所有 $\sqrt{n}$ 一致估计量中，谁最有效？

半参数效率界 (Newey 1990)

在二元选择 SIM 模型 $\Pr(Y = 1 | X) = G(X'\beta_0)$ 中，任何**正则**估计量 $\hat{\beta}$ 满足

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V), \quad V \succeq V_{KS}^*(\beta_0).$$

其中 V_{KS}^* 由“半参数信息矩阵”决定：

$$V_{KS}^* = \left(\mathbb{E} \left[\frac{(G'(X'\beta_0))^2}{G(X'\beta_0)(1 - G(X'\beta_0))} \tilde{X}\tilde{X}' \right] \right)^{-1}, \quad \tilde{X} = X - \mathbb{E}[X | X'\beta_0].$$

Klein-Spady 是有效的： KS 估计量**达到**效率界 V_{KS}^* ，与 Probit MLE (G 已知时的效率界) 相比，仅相差 $\tilde{X}$ 替代 X 这一调整。Ichimura 估计量**不达到**效率界（除非异方差性特殊）。

► 效率界推导

SIM 模型 $\Pr(Y = 1 | X) = G(X'\beta_0)$ 蕴含**可检验的限制**：

1. **单指数限制**： $\Pr(Y = 1 | X) = \Pr(Y = 1 | X'\beta_0)$ ，即条件概率仅依赖标量指标。可通过非参数估计 $\hat{m}(X)$ 与 SIM 估计 $\hat{G}(X'\hat{\beta})$ 的差异检验。
2. **G 单调性**（若假设）：可通过非参数估计 $\hat{G}$ 的形态检验。
3. **Probit / Logit 嵌套限制**：参数模型 $G = \Phi$ 或 Λ 是 SIM 的特例，可通过 Hausman 检验比较 SIM 估计与参数估计。

建模流程建议 (Härdle 2004)：

1. 用 SIM 估计 $\hat{\beta}$ 与 $\hat{G}$
2. 检验 $\hat{G}$ 是否近似 Φ / Λ
3. 若是，用 Probit / Logit（更高效）；若否，保留 SIM

从 SIM 框架到具体估计量：本部分总结

截至此处，我们已建立 SIM 框架的所有要素：

概念	内容
模型	$\Pr(Y = 1 X) = G(X'\beta_0)$, G 未知, β_0 待估
识别条件	位置 + 尺度正规化 + 连续回归元 + G 非平凡
速度承诺	$\hat{\beta}$ 在 $\sqrt{n}$, $\hat{G}$ 在 $n^{-2/5}$
效率上限	Klein-Spady 达到效率界
几何直观	β_0 决定等概率面法向, G 描述沿法向的概率形态

下一步：如何在数据中估计 (β, G) ？三大思路：

- ▶ **Part 4 — Ichimura (1993)**: 最小化 $\sum_i (Y_i - \hat{G}(X_i'\beta))^2$
- ▶ **Part 5 — Klein & Spady (1993)**: 最大化 $\sum_i [Y_i \log \hat{G} + (1 - Y_i) \log(1 - \hat{G})]$
- ▶ **Parts 6-7 — Manski / Horowitz**: 直接最大化得分 $\sum_i (2Y_i - 1) \mathbf{1}\{X_i'\beta \geq 0\}$

Ichimura (1993) 半参数最小二乘

Ichimura 估计量：核心思想

动机：单指数模型 $Y = G(X'\beta) + u$ 中，若 G 已知，非线性最小二乘 (NLS) 给出

$$\hat{\beta}_{\text{NLS}} = \arg \min_{\beta} \sum_{i=1}^n [Y_i - G(X_i'\beta)]^2.$$

Ichimura (1993) 的洞察：既然 G 未知，用**非参数估计** $\hat{G}$ 替换它，再做最小二乘：

$$\hat{\beta}_{\text{Ich}} = \arg \min_{\beta} \sum_{i=1}^n [Y_i - \hat{G}(X_i'\beta; \beta)]^2.$$

其中 $\hat{G}(\cdot; \beta)$ 是给定 β 时对函数 G 的核估计。

两个层次的优化（嵌套结构）：

- ▶ **内层：**给定 β ，用核回归估计 $\hat{G}(\cdot; \beta)$
- ▶ **外层：**在 β 上最小化平方误差和

内层是非参数估计，速率慢；外层是参数估计，速率 $\sqrt{n}$ 。

留一核估计 (Leave-one-out kernel) $\hat{G}_{-i}$

为什么要“留一”？避免 Y_i 同时出现在内层 $\hat{G}$ 与外层 $Y_i - \hat{G}(X_i'\beta)$ 中——否则会人为减小拟合误差，造成估计量不一致。

留一核估计 (Leave-one-out Nadaraya-Watson)

给定 β ，对每个 i 定义留一核估计：

$$\hat{G}_{-i}(z; \beta) = \frac{\sum_{j \neq i} K\left(\frac{z - X_j'\beta}{h}\right) Y_j}{\sum_{j \neq i} K\left(\frac{z - X_j'\beta}{h}\right)},$$

其中 K 是核函数， h 是带宽。

留一估计的关键性质：

- ▶ $\hat{G}_{-i}$ 不使用观测 i 自己的 $Y_i \Rightarrow$ 与 Y_i 独立
- ▶ $\hat{G}_{-i}(X_i'\beta; \beta)$ 是 $G(X_i'\beta_0)$ 的一致估计（在 $\beta = \beta_0$ ）
- ▶ 但它仍依赖 β （出现在指数中），所以外层最小化对 β 敏感

Ichimura 半参数最小二乘 (SLS)

Ichimura 估计量是

$$\hat{\beta} = \arg \min_{\beta \in \Theta} Q_n(\beta), \quad Q_n(\beta) = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{G}_{-i}(X_i' \beta; \beta)]^2 \cdot w(X_i) \cdot \mathbf{1}\{X_i \in A_n\}.$$

其中:

- ▶ $w(X_i) \geq 0$: 权重函数 (默认 $w \equiv 1$; 可加权以提高效率)
- ▶ $\mathbf{1}\{X_i \in A_n\}$: **修剪指示函数**, 仅在密度足够高的区域 A_n 计算
- ▶ $h = h_n$: 带宽, 满足 $h \rightarrow 0$, $nh^q \rightarrow \infty$

解读: 与 NLS 的形式完全相同, 唯一区别是把 $G(X_i' \beta)$ 换成 其非参数估计 $\hat{G}_{-i}(X_i' \beta; \beta)$ 。

Ichimura (1993) §3, equation (2.7)

修剪 (Trimming) 与权重函数 $w(X)$

为什么需要修剪？在 X 密度低的区域， $\hat{G}_{-i}$ 的分母 $\sum_j K((z - X_j'\beta)/h)$ 接近 0，导致估计不稳定。

修剪集 (Trimming Set)

定义 $A_n = \{x : \hat{f}(x'\beta) \geq b_n\}$ ，其中 $\hat{f}$ 是 $X'\beta$ 的密度核估计， $b_n \rightarrow 0$ 缓慢。仅对 $X_i \in A_n$ 的观测计入目标函数。

Class 5 §3.3 实务注解 (Caetano) :

- ▶ 理论上 $b_n \rightarrow 0$ 才保证渐近行为
- ▶ 实际上当样本足够大时，可以**不修剪** ($A_n = \mathbb{R}^k$)
- ▶ 修剪主要用于**剔除离群值** (outliers)，而非渐近必需

权重 $w(X)$ 的作用：

- ▶ 默认 $w \equiv 1$ ：等权 SLS
- ▶ 选择 $w(X) = 1/\sigma^2(X)$ (条件方差倒数)：加权 SLS (WSLS)，渐近效率高
- ▶ 但 $\sigma^2(X)$ 也需估计 $\Rightarrow$ 实际中 $w \equiv 1$ 更常用

算法：内—外双层优化

算法（伪代码）：

Ichimura 估计量计算流程

1. **初始化**：取初值 $\beta^{(0)}$ （例如 OLS 或 Probit MLE）
2. **外层循环**（对 β 优化）：
 - 2.1 给定当前 β ，计算指标 $z_i = X_i' \beta$, $i = 1, \dots, n$
 - 2.2 **内层**：用 $\{(z_j, Y_j)\}_{j \neq i}$ 计算留一核估计 $\hat{G}_{-i}(z_i; \beta)$
 - 2.3 计算目标 $Q_n(\beta) = \frac{1}{n} \sum_i [Y_i - \hat{G}_{-i}(z_i; \beta)]^2$
 - 2.4 用梯度法（或 Newton/BFGS）更新 $\beta \rightarrow \beta + \Delta$
3. **终止**：当 $\|\Delta\| < \text{容差}$ ，输出 $\hat{\beta}$
4. **后处理**：用最终 $\hat{\beta}$ 重新计算 $\hat{G}(z; \hat{\beta})$ 作为函数估计

计算成本：每次外层迭代需重新计算 n 个核回归值（因 β 改变 $\Rightarrow$ 指标 z_i 改变）。总计算量 $O(n^2 \cdot M)$ ， M 为外层迭代次数。中等样本（ $n \approx 1000$ ）下可行。

Ichimura 一致性假设 (A1-A6):

1. **(模型)** $Y = G(X'\beta_0) + u$, $\mathbb{E}[u | X] = 0$, $\beta_0 \in$ 紧集 Θ
2. **(识别)** 单指数模型识别条件成立 (位置+尺度+连续元)
3. **(光滑)** G 是 r 次连续可微, $r \geq 2$
4. **(分布)** X 的密度 f_X 有界, $X'\beta$ 的密度 $f_{X'\beta}$ 在 A_n 上有界离零
5. **(矩条件)** $\mathbb{E}[u^2 | X] = \sigma^2(X)$ 有界
6. **(带宽)** $h \rightarrow 0$, $nh^q \rightarrow \infty$, $nh^{2r} \rightarrow 0$

一致性定理 (Ichimura 1993, Theorem 5.1): 在 (A1)-(A6) 下,

$$\hat{\beta}_{\text{Ich}} \xrightarrow{p} \beta_0.$$

► Ichimura 一致性证明

Ichimura 渐近正态性 (Theorem)

在假设 (A1)-(A6) 加上以下额外条件:

- ▶ (A7) G 在 β_0 处导数 $G'(X'\beta_0)$ 不为零
- ▶ (A8) 矩条件加强: $\mathbb{E}[\|X\|^4] < \infty$
- ▶ (A9) 带宽进一步约束: $nh^{2r+1} \rightarrow 0, nh^{2q+1} \rightarrow \infty$ ($q = \dim Z$)

则

$$\sqrt{n}(\hat{\beta}_{\text{Ich}} - \beta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, V^{-1}\Sigma V^{-1}),$$

其中 V 与 Σ 由下页给出。

重要性质:

- ▶ $\hat{\beta}$ 的渐近分布与已知 G 时的 NLS 完全相同形式——只是 V, Σ 的具体表达式不同
- ▶ $\hat{G}$ 的估计误差以二阶项进入, 不影响 $\hat{\beta}$ 的一阶分布
- ▶ 这就是“adaptive” (自适应) 性质: $\hat{\beta}$ 仿佛知道 G

V 与 Σ 的具体形式

$$V = \mathbb{E} \left\{ w(X) [G'(X'\beta_0)]^2 \cdot [X - \mathbb{E}(X | X'\beta_0)] [X - \mathbb{E}(X | X'\beta_0)]' \right\}$$

$$\Sigma = \mathbb{E} \left\{ w(X)^2 \sigma^2(X) [G'(X'\beta_0)]^2 \cdot [X - \mathbb{E}(X | X'\beta_0)] [X - \mathbb{E}(X | X'\beta_0)]' \right\}$$

关键观察:

1. 出现**部分残差**: $\tilde{X} = X - \mathbb{E}[X | X'\beta_0]$ (沿等指数面投影后的剩余)
2. 出现 **G' 的权重**: 链接函数斜率 $G'(X'\beta_0)$ 在每个观测点对信息量加权
3. 当 $w \equiv 1$, $V = \Sigma / \sigma^2$ (同方差) $\Rightarrow V^{-1} \Sigma V^{-1} = \sigma^2 V^{-1}$

► 方差公式推导

已知 G 时 NLS 的渐近方差：

$$V_{\text{NLS}} = \mathbb{E} \left\{ [G'(X'\beta_0)]^2 XX' \right\}, \quad \text{Avar}(\hat{\beta}_{\text{NLS}}) = V_{\text{NLS}}^{-1} \cdot \mathbb{E}[\sigma^2(X)(G')^2 XX'] \cdot V_{\text{NLS}}^{-1}.$$

Ichimura 与 NLS 的差异：

- ▶ NLS 用 XX' ；Ichimura 用 $\tilde{X}\tilde{X}'$, $\tilde{X} = X - \mathbb{E}[X | X'\beta_0]$
- ▶ 这是**效率代价**：因为 $\hat{G}$ 必须靠数据估计， β 中对 $X'\beta_0$ 平行的方向**已被 $\hat{G}$ 吸收**，无信息可用
- ▶ $\tilde{X}$ 投影掉这个方向，留下**正交于 $X'\beta_0$ 的部分**

直观：非参数估计 $\hat{G}$ “用掉了”指数方向的信息， β_0 只能由**垂直于指数的协变量变化**识别——这是**半参数效率代价**的几何意义。

推导 Sketch: Taylor 展开 + 一致收敛

核心证明步骤:

1. 一阶条件: $\nabla_{\beta} Q_n(\hat{\beta}) = 0$, 即

$$\frac{1}{n} \sum_i [Y_i - \hat{G}_{-i}(X_i' \hat{\beta}; \hat{\beta})] \cdot \nabla_{\beta} \hat{G}_{-i}(X_i' \hat{\beta}; \hat{\beta}) \cdot w(X_i) = 0.$$

2. Taylor 展开于 β_0 :

$$0 = \frac{1}{n} \sum_i \nabla_{\beta} \hat{G}_{-i} \cdot u_i + V_n \cdot (\hat{\beta} - \beta_0) + o_p(\|\hat{\beta} - \beta_0\|).$$

3. 一致收敛: $V_n \xrightarrow{p} V$; $\frac{1}{n} \sum_i \nabla_{\beta} \hat{G}_{-i} \cdot u_i \xrightarrow{d} \mathcal{N}(0, \Sigma/n)$.

4. 两项关键引理 (Ichimura 1993 §6) :

- ▶ $\nabla_{\beta} \hat{G}_{-i}(X_i' \beta; \beta) \xrightarrow{p} G'(X_i' \beta_0) \tilde{X}_i$ (投影到正交空间)
- ▶ $\hat{G}$ 估计偏误 $O(h^r)$ 加随机项 $O((nh)^{-1/2})$ 在求和后降为 $o_p(n^{-1/2})$

关键洞察: 非参数项 $\hat{G} - G$ 的误差通过逐 i 平均与高阶核组合, 被压缩到 $o_p(n^{-1/2})$, 不污染 $\hat{\beta}$ 的 $\sqrt{n}$ 极限分布。

与参数 NLS 的对比：从已知到未知 G

	参数 NLS (G 已知)	Ichimura SLS (G 未知)
目标函数	$\sum_i [Y_i - G(X_i' \beta)]^2$	$\sum_i [Y_i - \hat{G}_{-i}(X_i' \beta; \beta)]^2$
G 处理	直接代入解析式	留一核估计 $\hat{G}_{-i}$
$\hat{\beta}$ 速度	$\sqrt{n}$	$\sqrt{n}$
$\hat{\beta}$ 渐近方差	$V_{NLS}^{-1} \Sigma_{NLS} V_{NLS}^{-1}$ (用 XX')	$V^{-1} \Sigma V^{-1}$ (用 $\tilde{X}\tilde{X}'$)
错设定后果	G 错则 不一致	G 自由 $\Rightarrow$ 始终一致
计算成本	单层优化	双层 (内核回归 + 外层 β)

核心信息：Ichimura 用**多一层非参数估计**和**微小的渐近方差代价**（从 XX' 到 $\tilde{X}\tilde{X}'$ ）换取对 G 形态的鲁棒性。当我们对 G 的形态没有把握时，这是非常划算的交易。

Ichimura 在二元选择中的应用

二元选择 SIM: $Y \in \{0, 1\}$, $\Pr(Y = 1 | X) = G(X'\beta_0)$ 。

二元选择 Ichimura 估计量

将一般 Ichimura 公式应用于二元 Y :

$$\hat{\beta} = \arg \min_{\beta \in \Theta} \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{G}_{-i}(X_i'\beta; \beta)]^2 \cdot \mathbf{1}\{X_i \in A_n\}.$$

其中 $\hat{G}_{-i}(z; \beta)$ 是 $\Pr(Y = 1 | X'\beta = z)$ 的留一核估计——它给出了一个介于 $[0, 1]$ 的“经验 CDF 形态”。

二元选择特例的优良性质:

- ▶ $Y \in \{0, 1\} \Rightarrow Y^2 = Y \Rightarrow$ 目标函数可重写为 $\sum_i [Y_i - \hat{G}_{-i}]^2 = \sum_i Y_i + \sum_i \hat{G}_{-i}^2 - 2 \sum_i Y_i \hat{G}_{-i}$
- ▶ $\sigma^2(X) = G(X'\beta_0)[1 - G(X'\beta_0)]$ (伯努利方差) $\Rightarrow$ 自然异方差
- ▶ Ichimura 一致估计 β_0 , 但非有效 (KS 才效率)

Ichimura 的带宽选择问题：内层核回归带宽 h 控制偏误—方差权衡和 $\hat{\beta}$ 的渐近性质。

常用带宽选择方法

1. 交叉验证 (LSCV): $h^* = \arg \min_h \sum_i [Y_i - \hat{G}_{-i}(X_i' \hat{\beta}; h)]^2$ (需迭代: β 与 h 联合)
2. Silverman 经验法则: $h = c \cdot \hat{\sigma}_{X' \hat{\beta}} \cdot n^{-1/(2r+1)}$
3. Sheather-Jones 插入法: 基于二阶导数估计

理论 vs 实务:

- ▶ 理论上 $\hat{\beta}$ 的 $\sqrt{n}$ 速度对 h 不敏感 (一阶不依赖于 h)
- ▶ 实际中 h 的选择影响小样本表现
- ▶ 欠平滑 (undersmooth): 取比 LSCV 略小的 h , 加快偏误消失, 帮助保证 $\sqrt{n}$ 速度 (Class 5 Note 4)

R 实现示例（伪代码）：

```
library(np) # nonparametric package

# Binary-choice Ichimura via np::npindex
bw <- npindexbw(formula = y ~ x1 + x2 + x3,
                 method = "ichimura",
                 data = mroz_data)
fit <- npindex(bws = bw)
summary(fit) # output: hat beta + asymptotic variance
```

计算注意事项：

- ▶ 外层优化**非凸** ($\hat{G}$ 通过 β 进入指标)，可能多个局部最优解
- ▶ 用多个起始点 (OLS, Probit, Logit) 以避开局部解
- ▶ 大样本下计算密集——核回归对每个 z_i 需 $O(n)$ 评估
- ▶ 加速：使用 FFT 加速核估计 (np 包内置)

R package: *np* (Hayfield & Racine 2008)

当 G 真的是 Φ 时：与 Probit 对比

情境：假设真实模型 $\Pr(Y = 1 | X) = \Phi(X'\beta_0)$ (即 Probit 正确)。

方法	一致性	渐近正态性	渐近方差
Probit MLE	✓	✓	达到 Cramér-Rao 下界 V_p^*
Ichimura SLS	✓	✓	$V_l^* \succeq V_p^*$ (可能严格大于)

效率代价：当 Probit 设定正确时，Ichimura 的渐近方差严格大于 Probit。比值 $V_l^*/V_p^* > 1$ 取决于：

- ▶ 协变量分布
- ▶ G 的形态 (Probit 的 Φ 在尾部信息密度高，Ichimura 难以充分利用)
- ▶ 通常代价 1%–30% (Newey-McFadden 1994 Table 1)

结论：当 G 已知且正确，Probit 更高效。但代价 1%-30% 在 “若 G 错则 Probit 不一致” 风险面前微不足道。

当 $G \neq \Phi$ 时: Probit 的偏误 vs Ichimura

情境: 假设真实 G 是 Logistic CDF Λ 而非 Φ 。

方法	一致性	渐近方差	性质
Probit MLE	×	无意义	$\hat{\beta}_p \rightarrow \beta^* \neq \beta_0$ (伪真值)
Ichimura SLS	✓	正常 $V^{-1}\Sigma V^{-1}$	始终一致, 分布不依赖 G 设定

偏误的具体表现:

- ▶ Probit $\hat{\beta}_p$ 不等于 β_0 , 差异可达 30%-100%
- ▶ 边际效应 APE 同样偏误
- ▶ t 统计量、置信区间均失效
- ▶ 即使样本无穷大, Probit 仍系统性偏误 $\Rightarrow$ 偏误不消失

数值例子 (Horowitz 1993 Table 1) :

- ▶ 真实 G : 异方差对数 logistic
- ▶ Probit $\hat{\beta}$ 偏误: 部分系数 65%
- ▶ Ichimura $\hat{\beta}$ 偏误: $< 5\%$

Ichimura 的核心优点:

1. **对 G 鲁棒**: 仅需单指数结构, 不依赖 G 的具体形式
2. **$\sqrt{n}$ 速度**: 与参数估计同速, 无收敛速度损失
3. **形式简单**: NLS 的直接推广, 便于理解与编程
4. **分布无关**: 渐近正态分布 (推断容易)
5. **二元选择 / 连续 / 受限因变量统一**: 单一框架处理多种受限因变量模型
6. **异方差自动适应**: 通过 $\sigma^2(X)$ 进入渐近方差, 但不需估计 σ^2

适用情境:

- ▶ 你对 G 没有强先验 (不确定 Φ 还是 Λ 还是其他)
- ▶ 你愿意接受 1%-30% 的渐近效率代价以换取鲁棒性
- ▶ 你拥有至少 $n \geq 200$ 的样本 (小样本下核估计不可靠)
- ▶ 你的回归元包含至少一个连续变量

Ichimura 的局限与过渡: Klein-Spady

Ichimura 不是终点: 它一致、 $\sqrt{n}$ 收敛, 但**不达到**半参数效率界。

效率差距的来源: Ichimura 用平方误差准则:

$$Q_n(\beta) = \sum_i [Y_i - \hat{G}(X_i' \beta)]^2.$$

这对所有观测等权处理。但二元 Y 中:

- ▶ 当 $G(X_i' \beta)$ 接近 0 或 1 时, 观测信息量更高 (更确定的预测)
- ▶ 但平方误差准则**忽略**这种信息差异
- ▶ **似然准则**才能正确加权这些观测

Klein-Spady (1993) 的解决方案:

- ▶ 用**半参数似然**替代平方误差
- ▶ 准则函数: $\sum_i [Y_i \log \hat{G} + (1 - Y_i) \log(1 - \hat{G})]$
- ▶ 渐近方差达到**半参数效率界** V_{KS}^*
- ▶ 与 Probit MLE 在已知 G 时的关系, 对应 Klein-Spady 与 Ichimura 在未知 G 时的关系

下一部分: Klein-Spady 的构造 性质 效率证明

PSS 加权平均导数估计量

PSS 估计量：基于平均导数的识别

Powell, Stock & Stoker (1989) 提出一种巧妙的识别策略：~~不通过准则最小化（如 Ichimura）~~，而通过一个**矩条件**直接给出 β 的解析表达。

核心恒等式：对单指数模型 $\Pr(Y = 1 | X) = G(X'\beta_0)$ ，条件期望函数 $m(X) = G(X'\beta_0)$ 关于 X_j 的偏导数为

$$\frac{\partial m(X)}{\partial X_j} = G'(X'\beta_0) \cdot \beta_{0,j}.$$

取期望：

$$\mathbb{E}\left[\frac{\partial m(X)}{\partial X_j}\right] = \mathbb{E}[G'(X'\beta_0)] \cdot \beta_{0,j}.$$

识别洞察：向量等式

$$\delta_0 := \mathbb{E}[\nabla_X m(X)] = \mathbb{E}[G'(X'\beta_0)] \cdot \beta_0.$$

- ▶ 标量 $c_0 := \mathbb{E}[G'(X'\beta_0)]$ 不可识别（G 未知）
- ▶ 但**方向** $\delta_0 / \|\delta_0\| = \beta_0 / \|\beta_0\|$ 完全识别
- ▶ δ_0 仅依赖**可观测的** $m(X)$ 的导数

平均导数的等价表达：从导数到密度

问题：直接估计 $\partial m / \partial X_j$ 需对 $\hat{m}$ 求导——数值微分对核估计不稳定（带宽敏感、收敛慢）。

PSS 的关键技巧：用分部积分把“对回归函数求导”转换为“对密度求导”。

平均导数的密度等价形式

设 X 有密度 $f_X(x)$ ，且 f_X 在 X 支撑边界上为零 ($f_X \rightarrow 0$)。则

$$\delta_0 = \mathbb{E}[\nabla_X m(X)] = -\mathbb{E}\left[m(X) \cdot \frac{\nabla f_X(X)}{f_X(X)}\right] = -\mathbb{E}\left[Y \cdot \frac{\nabla f_X(X)}{f_X(X)}\right].$$

最后一步用了 $\mathbb{E}[Y | X] = m(X)$ 。

为什么这有用？

- ▶ 右边只需估计**密度**（与其对数导数 $\nabla \log f_X$ ）
- ▶ 不需要直接估计 ∇m （导数估计速度慢）
- ▶ $\nabla f_X / f_X$ 可在所有数据点用核估计高效计算

推导： $\int \nabla m \cdot f_X dx = - \int m \cdot \nabla f_X dx$ （分部积分，假设边界项为零）
 $= - \int m \cdot (\nabla f_X / f_X) \cdot f_X dx = -\mathbb{E}[m(X) \cdot \nabla \log f_X(X)]$ 。

PSS 加权平均导数估计量

1. 核密度估计: $\hat{f}_X(x) = \frac{1}{nh^k} \sum_i K\left(\frac{x-X_i}{h}\right)$

2. 密度对数导数估计:

$$\widehat{\nabla \log f_X}(X_i) = \widehat{\nabla f_X}(X_i) / \hat{f}_X(X_i)$$

3. PSS 估计量:

$$\hat{\delta}_{PSS} = -\frac{1}{n} \sum_{i=1}^n Y_i \cdot \widehat{\nabla \log f_X}(X_i) \cdot \mathbf{1}\{X_i \in A_n\}.$$

4. 标准化: $\hat{\beta}_{PSS} = \hat{\delta}_{PSS} / \|\hat{\delta}_{PSS}\|$ (或选定某分量为 1)

PSS 的“一步式”特征: 与 Ichimura 的迭代优化不同,

- ▶ PSS **有解析解** (无需迭代)
- ▶ 一次核密度估计 + 一次平均 = 完成
- ▶ 计算成本 $O(n^2)$ (核估计), 无需双层循环

PSS 渐近性质 (Powell-Stock-Stoker 1989)

在适当的正则条件下（密度光滑、矩条件、高阶核、带宽 $h \sim n^{-1/(2r+k)}$ ）：

$$\sqrt{n}(\hat{\delta}_{\text{PSS}} - \delta_0) \xrightarrow{d} \mathcal{N}(0, V_{\text{PSS}}),$$

其中

$$V_{\text{PSS}} = \mathbb{E}\left\{[Y - m(X)]^2 \cdot [\nabla \log f_X(X)] \cdot [\nabla \log f_X(X)]'\right\} + \text{Var}[\nabla m(X)].$$

$\sqrt{n}$ 速度的关键：

- ▶ 求平均 ($\frac{1}{n} \sum_i$) 使核估计的非参数误差被**平滑掉**
- ▶ 与 Ichimura 同理： β 是有限维 $\Rightarrow$ 平均效应使估计速度恢复
- ▶ 需要**高阶核** ($r \geq 2$) 以削减偏误偏差

实务注意：

- ▶ PSS 对带宽**较敏感**（密度估计的常见问题）
- ▶ 修剪 A_n 通常必要（密度低区域估计不稳）
- ▶ 标准误推断：估计 $\hat{V}_{\text{PSS}}$ 后用 delta 方法

PSS 的优点：从计算简洁到理论清晰

PSS 的核心优点：

1. **无迭代**：解析公式，无收敛性问题
2. **$\sqrt{n}$ 收敛**：与 Ichimura/KS 同速
3. **对模型形态宽容**：不需要 G 单调，仅需可微
4. **自适应**：渐近方差中含 $\nabla \log f_X$ （密度信息），隐式利用 X 的分布
5. **自然识别尺度**： $\hat{\delta}$ 给出 β_0 的方向 + 一个未知比例 $\mathbb{E}[G']$

适用情境：

- ▶ 当样本量不太大（迭代成本是问题）
- ▶ 当计算工具有限（解析估计实现简单）
- ▶ 当回归元密度光滑（高阶核可用）
- ▶ 不适合： X 包含多个离散变量（密度不光滑、 $\nabla \log f_X$ 失效）

PSS vs Ichimura: 互补的两种识别策略

	Ichimura SLS	PSS 加权平均导数
识别策略	最小化 $\sum [Y - \hat{G}(X'\beta)]^2$	矩条件 $\delta_0 = c_0\beta_0$
形式	迭代优化（无解析解）	解析估计（一步式）
关键非参对象	$\hat{G}(\cdot)$ （链接函数）	$\nabla \log f_X(\cdot)$ （密度对数导数）
G 假设	任意可微	任意可微
X 假设	至少一个连续 + 适当矩	全部连续，密度光滑
$\hat{\beta}$ 速度	$\sqrt{n}$	$\sqrt{n}$
典型计算	双层循环 + 优化	一次核估计 + 一次平均
对带宽敏感性	较低	较高（密度估计）

选择建议：

- ▶ 全连续协变量、样本中等大：PSS 更快
- ▶ 含离散协变量（如年龄分组、地区）：Ichimura 更稳
- ▶ 需要 $\hat{G}$ （如做预测）：Ichimura 自然产生 $\hat{G}$
- ▶ 需要快速结果：PSS 一步到位

Klein-Spady (1993) 半参数 MLE

Klein-Spady: 动机——追求半参数效率

回顾：Ichimura 估计量一致、 $\sqrt{n}$ 收敛，但**不达到**半参数效率界。原因是平方误差对所有观测等权处理。

Klein & Spady (1993) 的洞察： 在二元选择中，**似然函数**才是最优准则。

- ▶ Probit MLE (已知 $G = \Phi$) 达到**Cramér-Rao 下界**——已知 G 时的最优
- ▶ 半参数化时，应用类似的**半参数似然**思路构造估计量
- ▶ Klein-Spady 估计量达到**半参数效率界** V_{KS}^*

Klein-Spady 估计量的核心： 用**留一核估计** $\hat{G}$ 替换似然中的 G ，最大化半参数对数似然：

$$\hat{\beta}_{KS} = \arg \max_{\beta} \frac{1}{n} \sum_i \left\{ Y_i \log \hat{G}_{-i}(X_i' \beta) + (1 - Y_i) \log [1 - \hat{G}_{-i}(X_i' \beta)] \right\}.$$

Klein & Spady (1993) *Econometrica* 61(2)

半参数似然函数

先回顾参数 Probit MLE: 假设 $G = \Phi$ (已知) :

$$\ell^P(\beta) = \frac{1}{n} \sum_i \{Y_i \log \Phi(X_i' \beta) + (1 - Y_i) \log [1 - \Phi(X_i' \beta)]\}.$$

半参数化: 保留似然形式, 把 Φ 换成由数据估计的 $\hat{G}$:

$$\ell^{KS}(\beta) = \frac{1}{n} \sum_i \{Y_i \log \hat{G}_{-i}(X_i' \beta) + (1 - Y_i) \log [1 - \hat{G}_{-i}(X_i' \beta)]\}.$$

Klein-Spady 留一核估计 $\hat{G}_{-i}(z)$

给定 β 和带宽 h ,

$$\hat{G}_{-i}(z; \beta) = \frac{\sum_{j \neq i} K\left(\frac{z - X_j' \beta}{h}\right) Y_j}{\sum_{j \neq i} K\left(\frac{z - X_j' \beta}{h}\right)} \in [0, 1].$$

(Nadaraya-Watson 形式, 留一以避免内生性。)

$\hat{G}_{-i} \in [0, 1]$ 的关键性: 留一核估计是 Y_j 的加权平均, $Y_j \in \{0, 1\} \Rightarrow \hat{G}_{-i} \in [0, 1]$, 自动满足概率约束, $\log \hat{G}$ 与 $\log(1 - \hat{G})$ 良定义。

Klein-Spady 准则与 Ichimura 的本质区别

	Ichimura SLS	Klein-Spady
准则形式	$\sum_i (Y_i - \hat{G}_{-i})^2$	$\sum_i [Y_i \log \hat{G}_{-i} + (1 - Y_i) \log(1 - \hat{G}_{-i})]$
对观测的加权	等权	隐式按 $1/[\hat{G}(1 - \hat{G})]$ 加权 (似然信息)
误差权重	$w \cdot 1$	$w \cdot 1/[\hat{G}(1 - \hat{G})]$ (自然异方差权重)
渐近效率	一致但非有效	达到半参数效率界
适用 Y	任何 (连续/二元/受限)	仅二元 $Y \in \{0, 1\}$

为什么 KS 更高效？ 似然函数自动给出每个观测的信息量：

- ▶ 当 $\hat{G} \approx 0.5$ (不确定预测)：每个 Y_i 信息量大 $\Rightarrow$ 高权重
- ▶ 当 $\hat{G} \approx 0$ 或 1 (确定预测)：信息量小 $\Rightarrow$ 低权重
- ▶ Ichimura 等权处理这两种情况——浪费了不确定预测的信息差异

Klein-Spady 假设 (KS1-KS6):

1. **(模型)** $\Pr(Y = 1 | X) = G(X'\beta_0)$, β_0 在紧集 Θ 内部
2. **(识别)** 单指数模型识别条件成立
3. **(支撑)** G 严格介于 $(\delta, 1 - \delta)$ 对某 $\delta > 0$, 避免边界
4. **(光滑)** G 是 r 次连续可微, $r \geq 2$
5. **(连续元)** X 至少含一个连续分量, 且 $X'\beta$ 密度有界离零
6. **(带宽)** $h \rightarrow 0$, $nh^q / \log n \rightarrow \infty$, $nh^{2r} \rightarrow 0$

一致性 (Klein-Spady 1993, Theorem 1): 在 (KS1)-(KS6) 下,

$$\hat{\beta}_{KS} \xrightarrow{p} \beta_0.$$

(KS3) 的实际意义: 假设 3 排除 $G \in \{0, 1\}$ 的情况, 防止 $\log \hat{G}$ 变成 $-\infty$ 导致似然爆炸。实务中可通过核估计的修剪保证。

Klein-Spady 渐近正态性 (Theorem 2)

在 (KS1)-(KS6) 加上以下额外条件:

- ▶ (KS7) 矩条件 $\mathbb{E}[\|X\|^4] < \infty$
- ▶ (KS8) $\mathbb{E}[G'(X'\beta_0)^2 / \{G(X'\beta_0)[1 - G(X'\beta_0)]\}] < \infty$
- ▶ (KS9) 带宽 $nh^{2r+1} \rightarrow 0$, $nh^{2q} \rightarrow \infty$

则

$$\sqrt{n}(\hat{\beta}_{KS} - \beta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, V_{KS}^*),$$

其中 V_{KS}^* 是半参数效率界 (下页给出)。

关键性质: 与 Probit MLE 在已知 $G = \Phi$ 时达到 Cramér-Rao 下界类比, Klein-Spady 在 G 未知时达到半参数 Cramér-Rao 下界——在所有 $\sqrt{n}$ 一致正则估计量中渐近方差最小。

▶ KS 渐近正态推导

Klein-Spady 渐近方差：信息矩阵之逆

Klein-Spady 渐近方差 V_{KS}^*

Klein-Spady 渐近方差为

$$V_{KS}^* = \left(\mathbb{E} \left[\frac{[G'(X'\beta_0)]^2}{G(X'\beta_0)[1 - G(X'\beta_0)]} \cdot \tilde{X}\tilde{X}' \right] \right)^{-1},$$

其中 $\tilde{X} = X - \mathbb{E}[X | X'\beta_0]$ (投影到正交于指数的空间)。

与 Probit MLE 的对照：

- ▶ **Probit ($G = \Phi$)**: $V_P = \mathbb{E}[\phi^2 / \{\Phi(1 - \Phi)\} XX']^{-1}$ (用 XX')
- ▶ **Klein-Spady (G 未知)**: $V_{KS}^* = \mathbb{E}[(G')^2 / \{G(1 - G)\} \tilde{X}\tilde{X}']^{-1}$ (用 $\tilde{X}\tilde{X}'$)
- ▶ 唯一差异: $XX' \rightarrow \tilde{X}\tilde{X}'$ ——这是半参数代价

半参数代价的几何意义: $\hat{G}$ 必须由数据估计 $\Rightarrow$ 沿指数方向 $X'\beta_0$ 的信息被吸收 $\Rightarrow \beta_0$ 仅由正交方向的协变量变化识别。 $\tilde{X} = X - \mathbb{E}[X | X'\beta_0]$ 投影掉指数方向。

半参数效率界 (Newey 1990)

在二元选择 SIM 模型 $\Pr(Y = 1 | X) = G(X'\beta_0)$ 中 (G 未知, β_0 待估) : 任何 $\sqrt{n}$ 一致正则估计量 $\hat{\beta}$ 满足

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V) \Rightarrow V \succeq V_{KS}^*.$$

V_{KS}^* 由半参数得分函数给出, 是参数 Cramér-Rao 界在半参数下的推广。

半参数得分的构造 (直觉) :

1. 参数 score: $s(\beta) = (Y - G(X'\beta)) \cdot G'(X'\beta)X/[G(1 - G)]$
2. 半参数 score: 投影到切空间 (β 与 G 的可变方向之并) 的正交补
3. 投影后得 $s^*(\beta) = (Y - G(X'\beta)) \cdot G'(X'\beta)\tilde{X}/[G(1 - G)]$
4. 效率界 $V_{KS}^* = (\mathbb{E}[s^*(s^*)'])^{-1}$

► 效率界完整推导

为什么 KS 达到 V_{KS}^* ? 核心是 KS 的得分函数等于半参数得分。

1. KS 一阶条件: 在 $\hat{\beta}$ 处,

$$\frac{1}{n} \sum_i \frac{Y_i - \hat{G}_{-i}}{\hat{G}_{-i}(1 - \hat{G}_{-i})} \cdot \nabla_{\beta} \hat{G}_{-i}(X_i' \beta) \cdot w(X_i) = 0.$$

2. $\nabla_{\beta} \hat{G}_{-i}$ 的极限: Ichimura/KS 共同性质—— $\nabla_{\beta} \hat{G}_{-i} \xrightarrow{p} G'(X_i' \beta_0) \tilde{X}_i$.

3. KS 得分一致估计半参数得分: $\hat{s}_i \approx (Y_i - G(X_i' \beta_0)) \cdot G'(X_i' \beta_0) \tilde{X}_i / [G(1 - G)] = s_i^*$.

4. Z-估计量理论: $\hat{\beta}$ 渐近方差 $= (\mathbb{E}[s^*(s^*)'])^{-1} = V_{KS}^*$.

Ichimura 为何不达到效率界? 它的得分缺少 $1/[G(1 - G)]$ 这个似然权重——在不确定预测点 ($G \approx 0.5$) 权重应高, 确定预测点权重应低。Ichimura 等权 $\Rightarrow$ 浪费信息。

Klein-Spady 计算流程

1. **初始化**: 取 $\beta^{(0)}$ 为 Probit MLE 或 Ichimura $\hat{\beta}$
2. **对当前 β** :
 - 2.1 计算指数 $z_i = X_i' \beta, i = 1, \dots, n$
 - 2.2 计算留一核估计 $\hat{G}_{-i}(z_i; \beta)$ 对每个 i
 - 2.3 **修剪边界**: 把 $\hat{G}_{-i} \in (\epsilon, 1 - \epsilon)$ 之外的剪到边界 ($\epsilon \approx 10^{-3}$)
 - 2.4 计算半参数对数似然: $\ell^{KS}(\beta) = \sum_i [Y_i \log \hat{G}_{-i} + (1 - Y_i) \log(1 - \hat{G}_{-i})]$
3. **优化更新**: 用 BFGS (或 Newton) 更新 $\beta \rightarrow \beta + \Delta$
4. **终止**: $\|\Delta\| < \text{容差}$, 输出 $\hat{\beta}_{KS}$
5. **标准误**: 估计 V_{KS}^* 的样本类比

关键实务点: KS 目标函数同样**非凸** ($\hat{G}$ 通过 β 进入指标) 。 用多个起始点; BFGS 比 Newton 更稳健 (避免计算 Hessian) 。

核心问题: 当 $\hat{G}_{-i}$ 接近 0 或 1 时, $\log \hat{G}$ 或 $\log(1 - \hat{G})$ 接近 $-\infty$ 。

稳定化技术:

1. **修剪 (Trimming):** 把 $\hat{G}_{-i}$ 截断在 $[\epsilon, 1 - \epsilon]$, $\epsilon = 10^{-3}$
2. **修剪样本:** 仅在 $A_n = \{X : \delta < \hat{G}(X'\beta) < 1 - \delta\}$ 上求和
3. **下溢保护:** 用 $\log(\max(\hat{G}, 10^{-10}))$ 的形式实现
4. **对数空间计算:** 用 $\log1p$, $\log_sum_exp$ 等数值稳定函数

(KS3) 假设的实务意义: 理论假设 $\inf G \geq \delta > 0$ 可通过**修剪**保证。实际中, 若 X 含有取大值的协变量 (如年龄), 需特别注意 $\hat{G}$ 在尾部的稳定性。

R 实现: `npindex(method = "kleinspady", ...)` 在 `np` 包中自动处理边界修剪。

Klein-Spady vs Probit: 何时使用?

情境	Probit MLE 优	Klein-Spady 优
G 真为 Φ	✓ 效率最高	一致但有 1%-30% 效率损失
G 接近 Φ 但非	略微偏误 + 高效率	一致 + 略低效率
G 显著不同于 Φ	不一致 $\Rightarrow$ 错误	一致 + 效率最优
异方差性	全面失灵	自动适应
样本极小 ($n < 200$)	可靠	核估计不稳
样本大 ($n > 1000$)	风险高	推荐使用

决策规则（实务建议）：

- ▶ 始终先做 Probit / Logit 作为基准
- ▶ 用 KS 做**稳健性检验**：若 KS 与 Probit 系数差异显著（10% 以上），怀疑分布错设定
- ▶ 用**Härdle-Mammen 检验**（Lecture S2）正式检验 $G = \Phi$ 假设
- ▶ 论文结果应同时报告参数与半参数估计

使用 KS 的实务清单：

1. **样本大小**： $n \geq 500$ (核估计需要足够数据)
2. **至少一个连续协变量**： 识别条件必需
3. **尺度正规化**： 固定 $\beta_1 = 1$ 或 $\|\beta\| = 1$ ，并报告比较 Probit 时同样标准化
4. **初始值**： 用 Probit MLE 起步 (已是好的近似)
5. **多起始点**： 检验局部最优 vs 全局最优
6. **h 的稳健性**： 报告 $h \in \{0.5h^*, h^*, 2h^*\}$ 时 $\hat{\beta}$ 的变化

论文报告要求 (建议)：

- ▶ KS $\hat{\beta}$ 与 Probit $\hat{\beta}_p$ 并列展示
- ▶ 二者标准误 (KS 的 $\sqrt{V_{KS}^*/n}$)
- ▶ Bootstrap 标准误检验 (200 次重抽样) 作为稳健性检验
- ▶ 链接函数估计 $\hat{G}(\cdot)$ 的可视化 (与 Φ 对比)

核心优点:

1. **半参数效率界达到性**: V_{KS}^* 是不可超越的下界
2. **$\sqrt{n}$ 收敛 + 渐近正态**: 标准推断工具可用
3. **对 G 鲁棒**: 分布形态错设无关紧要
4. **异方差性自动适应**: 不需要假设同方差

局限:

1. **需要单指数结构正确** (这是关键假设)
2. **需要至少一个连续协变量** (识别)
3. **计算密集**: 双层循环 + 优化非凸
4. **对 $\hat{G}$ 的核估计敏感** (需修剪边界)
5. **仅二元 Y**: 不能直接用于多元选择、计数数据

下一部分: 过渡到**完全放弃 G 形态假设**的方法——Manski 最大得分 (仅需中位数限制)。

从 $\sqrt{n}$ 估计量到立方根估计量：思想跨越

已学过的两类 $\sqrt{n}$ 估计量：

- ▶ Ichimura, Klein-Spady, PSS：基于**均值约束** ($\mathbb{E}[u | X] = 0$)
- ▶ 这些方法假设 G 光滑可微 + 均值零

下一阶段 (Parts 5b-7)：更弱的限制，对 G 假设更放松。

两条更弱的识别路径：

1. **Han MRC (Part 5b)：**仅需**秩单调性** ($X'\beta$ 大 $\Rightarrow \Pr(Y = 1)$ 大)， $\sqrt{n}$ 收敛
2. **Manski 最大得分 (Part 6)：**仅需**中位数零限制** ($\text{Med}(\varepsilon | X) = 0$)， $n^{-1/3}$ 收敛（立方根速度）
3. **Horowitz 平滑 (Part 7)：**Manski 的平滑改进，恢复 $n^{2/5}$ 速度 + 渐近正态

速度—假设权衡：

- ▶ KS / Ichimura / PSS： $\sqrt{n}$ ，需均值零 + 光滑 G
- ▶ Han MRC： $\sqrt{n}$ ，需秩单调（更弱）
- ▶ Manski： $n^{-1/3}$ ，仅需中位数零（最弱）

Han (1987) 最大秩相关估计量 (MRC)

Han MRC: 仅需“秩单调”识别

Han (1987) 的核心思想：对单指数模型 $Y = D(X'\beta_0 + \varepsilon)$ ，仅需 D 严格单调递增，即可由秩相关识别 β_0 方向。

广义回归模型 (Han 1987)

设

$$Y_i = D(X_i'\beta_0 + \varepsilon_i),$$

其中：

- ▶ $D: \mathbb{R} \rightarrow \mathbb{R}$ 是任意**严格单调递增**函数（未知）
- ▶ $\varepsilon_i \mid X_i$ 任意分布（仅需可识别条件）

特例： $D(z) = \mathbf{1}\{z > 0\} \Rightarrow$ 二元选择模型。

关键观察：由于 D 单调，

$$X_i'\beta_0 > X_j'\beta_0 \Rightarrow \mathbb{E}[Y_i] \geq \mathbb{E}[Y_j].$$

即**排序** $X'\beta$ 决定了 Y 的排序——这就是“秩相关”的来源。

Han (1987) JEcon; Sherman (1993) Econometrica

MRC 准则：最大化秩相关

Han 最大秩相关估计量 (MRC)

Han (1987) 估计量为

$$\hat{\beta}_{\text{MRC}} = \arg \max_{\beta: \|\beta\|=1} \frac{1}{n(n-1)} \sum_{i \neq j} \mathbf{1}\{Y_i > Y_j\} \cdot \mathbf{1}\{X_i' \beta > X_j' \beta\}.$$

准则的解读：

- ▶ 数对 $(Y_i > Y_j)$ 与 $(X_i' \beta > X_j' \beta)$ **符号一致**的对数
- ▶ 即 **Kendall' s τ** (Kendall 秩相关系数) 的样本类比
- ▶ 最大化秩相关 $\Leftrightarrow$ 让 $X' \beta$ 与 Y 的排序最一致

二元 Y 的简化： $Y \in \{0, 1\} \Rightarrow Y_i > Y_j \Leftrightarrow (Y_i, Y_j) = (1, 0)$. 目标函数仅有 $Y = 1$ 与 $Y = 0$ 配对中 $X' \beta$ 排序正确的频率：

$$\hat{\beta}_{\text{MRC}} = \arg \max_{\beta} \frac{1}{n_1 n_0} \sum_{Y_i=1, Y_j=0} \mathbf{1}\{X_i' \beta > X_j' \beta\}.$$

直观： 找出最佳 β 方向，使得“ $Y = 1$ 的观测在指数 $X' \beta$ 上的值尽可能高于 $Y = 0$ 的观测”。

Han MRC 渐近正态性 (Sherman 1993)

在适当正则条件下:

1. **一致性:** $\hat{\beta}_{\text{MRC}} \xrightarrow{p} \beta_0 / \|\beta_0\|$ (识别到方向)
2. **渐近正态性:**

$$\sqrt{n}(\hat{\beta}_{\text{MRC}} - \beta_0 / \|\beta_0\|) \xrightarrow{d} \mathcal{N}(0, V_{\text{MRC}}).$$

关键发现 (Sherman 1993):

- ▶ Han 1987 原文证明了一致性, 但渐近分布是开放问题
- ▶ Sherman (1993) 证明了 $\sqrt{n}$ **渐近正态性**
- ▶ 关键技术: U-statistic 理论 + Hoeffding 投影 + 平滑修正

V_{MRC} 的形式: 基于秩函数的二阶导数, 比 KS 复杂。一般通过 bootstrap 估计推断。

Sherman (1993) *Econometrica* 61(1)

Han MRC vs Manski 最大得分：相同思想，不同速度

两者都仅用 Y 的“排序信息”，但收敛速度差异巨大。

	Han MRC (1987)	Manski 最大得分 (1975)
目标函数	$\sum_{i \neq j} 1\{Y_i > Y_j\} 1\{X_i' \beta > X_j' \beta\}$	$\sum_i (2Y_i - 1) 1\{X_i' \beta > 0\}$
约束类型	秩单调 (D 单调)	中位数零 ($\text{Med}(\varepsilon X) = 0$)
目标函数性质	可微 (U-statistic 平滑性)	阶跃, 非凸非光滑
收敛速度	$\sqrt{n}$	$n^{1/3}$ (立方根)
极限分布	正态	非正态 (Brownian motion 极值)

为何 MRC 速度比 Manski 快?

- ▶ Manski 单点比较: $X' \beta > 0$ (与零比较)
- ▶ Han MRC 两两比较: $X_i' \beta > X_j' \beta$ (pair-wise)
- ▶ Pair-wise 数据 $\sim n^2$ 个, 比 single 多 $\Rightarrow$ 更快收敛
- ▶ 这是 U-statistic 理论的标准结果 (Sherman 1993)

优化挑战： MRC 目标函数包含 $n(n-1) \approx n^2$ 个示性函数，且 $\mathbf{1}$ 不可微。

常见解决方案：

1. **平滑指标函数：** 用 $\Phi((X_i'\beta - X_j'\beta)/h)$ 替换 $\mathbf{1}\{\cdot\}$
2. **排序对 $O(n^2)$ 计算：** 可用快速排序加速到 $O(n \log n)$
3. **半凹优化器：** 尽管目标非凹，启发式法（模拟退火、网格搜索）有效
4. **R 实现：** `rlaplace::mrc` 或自定义代码

MRC 的实务地位：

- ▶ 比 Manski 收敛快 $\Rightarrow$ 推断更可靠
- ▶ 比 KS / Ichimura 假设弱 $\Rightarrow$ 更鲁棒（不需均值零，不需 G 光滑）
- ▶ 但计算成本高 + 标准误难推 $\Rightarrow$ 实践中 KS 仍是首选
- ▶ 在 D 不光滑（如有跳跃）情况下，MRC 是**唯一选择**

Han 1987 的真正贡献： MRC 是一个**统一框架**，将多种受限因变量模型纳入同一估计程序。

模型	设定	MRC 适用
二元选择	$Y = \mathbf{1}\{X'\beta + \varepsilon > 0\}$	✓
归并/受限因变量	$Y = \max(0, X'\beta + \varepsilon)$ (Tobit)	✓
有序响应	$Y \in \{0, 1, \dots, J\}$, 阈值未知	✓
截尾回归	$Y = X'\beta + \varepsilon$ 截断观测	✓
广义半参数	$Y = D(X'\beta + \varepsilon)$, D 单调	✓

MRC 的统一意义：

- ▶ 上述模型都满足“ $X'\beta$ 单调地通过 D 影响 Y ”
- ▶ 排序信息对所有模型都成立 $\Rightarrow$ MRC 通用
- ▶ 不需要分别为每个模型设计估计量

下一部分：从 $\sqrt{n}$ 估计量回到放弃单调性、仅需中位数零的**Manski 最大得分**——速度更慢但假设更弱。

Manski (1975) 最大得分估计量

Manski 的核心创新：放弃所有分布假设

此前所有半参数估计量 (Ichimura, KS, PSS, Han MRC) 都需要：

- ▶ 误差均值零 ($\mathbb{E}[u | X] = 0$) 或秩单调
- ▶ G 光滑可微

Manski (1975) 的革命性洞察： 对二元选择，唯一真正必要的限制是

$$\text{Med}(\varepsilon | X) = 0$$

(条件中位数为零)，比均值零**弱得多**，且**允许任意异方差**。

为什么这个假设足够？ 考察二元选择

$$Y = \mathbf{1}\{X'\beta_0 + \varepsilon \geq 0\}.$$

在 $\text{Med}(\varepsilon | X) = 0$ 下：

$$\Pr(Y = 1 | X) > 1/2 \Leftrightarrow \Pr(X'\beta_0 + \varepsilon \geq 0 | X) > 1/2 \Leftrightarrow X'\beta_0 > 0.$$

即**中位预测规则**：若 $X'\beta_0 > 0$ ，预测 $Y = 1$ ；否则预测 $Y = 0$ 。

中位数限制 vs 期望限制：放松多少？

约束类型	均值零: $\mathbb{E}[\varepsilon X] = 0$	中位数零: $\text{Med}(\varepsilon X) = 0$
对分布对称性	不要求	不要求
对异方差	仅 Ichimura 部分稳健	完全稳健 (任意 $\sigma^2(X)$)
对一阶矩存在	要求	不要求 (即使 $\mathbb{E}[\varepsilon]$ 不存在也可估计)
适用模型	几乎所有半参数	二元选择特例

中位数限制的两大优势：

1. **异方差完全无关**： $\sigma^2(X) = h(X)$ 任意函数，估计量仍一致
2. **重尾分布友好**：即使 ε 是 Cauchy 分布 ($\mathbb{E}|\varepsilon| = \infty$)，中位数仍为零

含义：Manski 估计量在分布假设上比所有其他半参数估计量**更鲁棒**。代价：收敛速度从 $\sqrt{n}$ 降至 $n^{-1/3}$ (详见后文立方根速率定理)。

异方差性下: Probit 失灵 vs Manski 鲁棒

设定: 假设真实模型为

$$Y = \mathbf{1}\{X'\beta_0 + \sigma(X) \cdot \nu \geq 0\}, \quad \nu \sim \mathcal{N}(0, 1), \quad \nu \perp X,$$

其中 $\sigma(X) = \exp(X'\gamma)$ 为异方差函数。

方法	该模型下的表现	原因
Probit MLE	不一致 : $\hat{\beta} \rightarrow \beta_0 / \sigma(\bar{X})$ 等加权平均	误设 $\sigma(X) = 1$
Klein-Spady	不一致 : G 形态依赖 X , 违反单指数	SIM 假设破坏
Ichimura	不一致 : 同 KS 原因	SIM 假设破坏
Manski	一致 : $\hat{\beta} \xrightarrow{P} \beta_0$	中位数限制对异方差稳健

关键技术细节: 异方差不破坏中位数零限制, 因为

$$\text{Med}(\sigma(X)\nu \mid X) = \sigma(X) \cdot \text{Med}(\nu \mid X) = 0,$$

无论 $\sigma(X)$ 取何函数形式。这就是 Manski 鲁棒性的根本来源。

Manski 最大得分目标函数

Manski 最大得分估计量 (Maximum Score Estimator)

Manski (1975) 估计量为

$$\hat{\beta}_{MS} = \arg \max_{\beta: \|\beta\|=1} S_n(\beta), \quad S_n(\beta) = \frac{1}{n} \sum_{i=1}^n (2Y_i - 1) \cdot \mathbf{1}\{X_i' \beta \geq 0\}.$$

目标函数的解读:

- ▶ $(2Y_i - 1) \in \{-1, +1\}$: $Y_i = 1$ 计 +1; $Y_i = 0$ 计 -1
- ▶ $\mathbf{1}\{X_i' \beta \geq 0\} \in \{0, 1\}$: 模型预测 $Y_i = 1$ 时为 1
- ▶ 二者乘积: **预测正确** (+1 或 0) vs **错误** (-1)
- ▶ $S_n(\beta) = (\text{正确预测数} - \text{错误预测数}) / n$

直观: 最大得分估计量找出使中位数预测正确率最高的 β 方向。与 Probit 的对数似然不同, 目标函数仅利用 $X' \beta$ 的符号, 不利用其大小。这正是其鲁棒性的来源——但也是其速度损失的来源。

与最小绝对偏差 (LAD) 的联系

Manski (1975) 在原文中明确指出 MS 估计量是 LAD 在二元选择中的类比。

LAD 与 MS 的对应

线性回归 LAD: $\hat{\beta}_{\text{LAD}} = \arg \min_{\beta} \sum_i |Y_i - X_i' \beta|$

- ▶ 假设: $\text{Med}(\varepsilon | X) = 0$
- ▶ 异方差稳健
- ▶ $\sqrt{n}$ 收敛

二元选择 MS: $\hat{\beta}_{\text{MS}} = \arg \max_{\beta} \sum_i (2Y_i - 1) \mathbf{1}\{X_i' \beta \geq 0\}$

- ▶ 假设: $\text{Med}(\varepsilon | X) = 0$
- ▶ 异方差稳健
- ▶ $n^{-1/3}$ 收敛 (损失速度)

为什么二元选择损失速度? LAD 的目标函数是凸的 (绝对值), 而 MS 的目标函数是阶跃的 (指示函数) —— 阶跃在最优点附近平坦, 使得“信息曲率”消失, 速度从 $\sqrt{n}$ 降至 $n^{-1/3}$ 。

Manski (1985) 强一致性假设:

1. **(模型)** $Y = \mathbf{1}\{X'\beta_0 + \varepsilon \geq 0\}$, $\beta_0 \in S^{k-1}$ (单位球面)
2. **(中位数零)** $\text{Med}(\varepsilon | X) = 0$ 几乎处处
3. **(识别)** X 至少有一个连续分量, 且其相应 β 系数非零
4. **(分布)** X 的支撑在某真子空间中没有过多质量
5. **(连续性)** $\Pr(Y = 1 | X)$ 在 $X'\beta_0 = 0$ 邻域连续

强一致性定理 (Manski 1985): 在上述假设下,

$$\hat{\beta}_{MS} \xrightarrow{\text{a.s.}} \beta_0.$$

相比 Manski 1975: 1985 年版加强为强 (almost sure) 一致性, 并放松了识别条件。
Manski 1975 仅给出弱 (依概率) 一致性。

立方根 n 收敛速率 (Cube-root)

Kim-Pollard 立方根定理 (1990)

在适当正则条件下, Manski 最大得分估计量的收敛速度是

$$\hat{\beta}_{MS} - \beta_0 = O_p(n^{-1/3}).$$

比 $\sqrt{n}$ (参数速度) 慢, 但比完全非参数 $n^{-2/(4+k)}$ 快。

为什么是 $n^{1/3}$? 总体目标 $S_\infty(\beta) - S_\infty(\beta_0) \sim -c\|\beta - \beta_0\|^2$ 在 β_0 邻域具有二次曲率 (局部下降)。但 $S_n - S_\infty$ 是阶跃函数的经验过程, 其上确界 (在 $\|\beta - \beta_0\| \leq \delta$ 球内) 是 $O_p(n^{-1/2}\sqrt{\delta})$ (不是常规的 $O_p(n^{-1/2})$) ——经验过程理论中的 bracketing entropy 给出此根号尺度)。

平衡两项: 让二次下降 $-c\delta^2$ 与经验波动 $n^{-1/2}\sqrt{\delta}$ 同阶, 解得 $\delta \sim n^{-1/3}$ 。这就是立方根速率的来源——速率瓶颈不在曲率 (曲率是好的), 而在阶跃函数引发的**放大经验波动**。

► Kim-Pollard 推导

Manski 极限分布 (Kim-Pollard 1990)

在适当正则条件下,

$$n^{1/3}(\hat{\beta}_{\text{MS}} - \beta_0) \xrightarrow{d} \arg \max_{s \in \mathbb{R}^k} \{Z(s) - \frac{1}{2}s'V_0s\},$$

其中:

- ▶ $Z(s)$ 是均值零、协方差 $H_0(s, s')$ 的高斯过程
- ▶ V_0 是某确定矩阵
- ▶ argmax 不可约简——**无封闭分布**, 不是正态、不是任何标准分布

推断的实际困难:

- ▶ 没有简单的 t 检验或置信区间
- ▶ Bootstrap **不一致** (Abrevaya-Huang 2005 证明) ——常规 bootstrap 失效
- ▶ 必须用 subsampling 或 m-out-of-n bootstrap
- ▶ 实务中, 标准误估计是难题

Manski 推导 Sketch: 经验过程论

Kim-Pollard 1990 证明的核心步骤:

1. 重新参数化: $s = n^{1/3}(\beta - \beta_0)$, 目标函数变为

$$\tilde{S}_n(s) = n^{2/3} [S_n(\beta_0 + n^{-1/3}s) - S_n(\beta_0)].$$

2. 有限维分布收敛: $\tilde{S}_n(s) \xrightarrow{d} Z(s) - \frac{1}{2}s'V_0s$.

3. 紧性 (tightness): 经验过程论的**弦不等式 (chaining inequality)** 保证 $\tilde{S}_n$ 的紧性。

4. argmax 连续性: 紧性 + 极限连续性 $\Rightarrow$ argmax 收敛。

关键技术: 经验过程论中的**symmetrization**、**Talagrand 不等式**、**bracketing entropy**。这是高度非平凡的技术——Kim-Pollard (1990) 是统计学经典之作。

方差矩阵 V_0 的具体形式:

$$V_0 = \mathbb{E} \left[f_{\varepsilon|X}(0 | X) \cdot XX' \cdot |Y - 1/2| \cdot \mathbf{1}\{X'\beta_0 = 0\} \right]$$

依赖误差条件密度 $f_{\varepsilon|X}(0 | X)$ ——通常未知, 难以估计。

计算困难：非凸非光滑目标函数

Manski 目标函数的两大计算困难：

1. **阶跃函数不光滑**： $1\{X_i'\beta \geq 0\}$ 在 $X_i'\beta = 0$ 处不连续 $\Rightarrow$ 无法用梯度法 (Newton, BFGS)
2. **多个局部最优解**： $S_n(\beta)$ 是分段常数， β 在某些“切换点”之间值不变 $\Rightarrow$ 数千甚至数万个等值平台

常用算法：

1. **网格搜索**： β 离散化 (小维度可行)
2. **模拟退火 (Simulated Annealing)**： 随机搜索 + 接受/拒绝
3. **遗传算法 (Genetic Algorithm)**： 种群进化
4. **Pinkse 1993 算法**： 组合优化方法 (NP-hard)

实务建议：对 $k \leq 5$ ，模拟退火常足；对 $k > 10$ ，**Manski 计算极其困难**，几乎不可行。
Horowitz 平滑（下一部分）主要动机之一就是解决计算问题。

R: *maxLik* + 自定义; Stata: *user written ado*

Manski 何时使用?

Manski 适用情境:

1. 严重**异方差**怀疑且形态未知
2. 误差分布**不对称** (中位数零 vs 均值零有差异)
3. **重尾误差** (Cauchy 等无矩分布)
4. 想做**识别检验**: 与 KS/Probit 比较, 差异大则怀疑分布错设
5. 样本充足 ($n \geq 1000$ 以补偿慢速度)

Manski 不适用情境:

1. 高维 X ($k > 10$): 计算不可行
2. 小样本 ($n < 500$): $n^{-1/3}$ 速度产生大有限样本误差
3. 需要快速结果或推断: 极限分布无封闭形式
4. 需要边际效应: $\hat{G}$ 不直接可得 (仅识别 β 的方向)

Manski 的两个核心局限：

1. **速度慢**： $n^{-1/3}$ 比 $\sqrt{n}$ 慢得多
2. **推断难**：极限分布非正态，bootstrap 失效

核心问题：阶跃函数 $1\{\cdot\}$ 是罪魁祸首。

- ▶ 它使目标函数不光滑 $\Rightarrow$ 计算困难
- ▶ 它使总体目标函数不可微 $\Rightarrow$ 速度损失
- ▶ 它使极限分布非正态 $\Rightarrow$ 推断困难

Horowitz (1992) 的解决方案：用平滑核函数 $K(\cdot)$ 替代 $1\{\cdot\}$ ，在保持中位数零鲁棒性的同时恢复光滑性：

- ▶ 收敛速度恢复至 $n^{-2/5}$ （介于 $n^{-1/3}$ 与 $n^{-1/2}$ 之间）
- ▶ 极限分布恢复**正态**
- ▶ 计算可用 BFGS 等标准方法

下一部分：Horowitz 平滑最大得分估计量。

Horowitz (1992) 平滑最大得分估计量

Horowitz 改进动机：把阶跃变成光滑

Manski MS 目标函数：

$$S_n(\beta) = \frac{1}{n} \sum_i (2Y_i - 1) \cdot \mathbf{1}\{X_i' \beta \geq 0\}.$$

Horowitz (1992) 思想：用一个光滑、单调上升、 $0 \rightarrow 1$ 的函数 $\tilde{K}(\cdot)$ 代替 $\mathbf{1}\{\cdot\}$ ：


$$\hat{S}_n(\beta; h) = \frac{1}{n} \sum_i (2Y_i - 1) \cdot \tilde{K}\left(\frac{X_i' \beta}{h}\right).$$

平滑核 $\tilde{K}$ 的性质

$\tilde{K} : \mathbb{R} \rightarrow [0, 1]$ 满足：

- ▶ $\lim_{u \rightarrow -\infty} \tilde{K}(u) = 0, \lim_{u \rightarrow +\infty} \tilde{K}(u) = 1$
- ▶ $\tilde{K}$ 多次连续可微 ($r \geq 4$ 阶)
- ▶ $\tilde{K}$ 满足某些“高阶矩”条件 (对偏误削减)
- ▶ 例： $\tilde{K}(u) = \int_{-\infty}^u K(v) dv$ 即标准核 K 的“积分核”

h 是带宽： $h \rightarrow 0$ 时， $\tilde{K}(X' \beta / h) \rightarrow \mathbf{1}\{X' \beta \geq 0\}$ ，**Horowitz 退化为 Manski**。h 控制平滑程度。



从 Manski 到 Horowitz 的演化:

- ▶ 红色阶跃: Manski 原版
- ▶ 蓝色 S 形曲线: Horowitz 平滑版 (h 适中)
- ▶ 橙色更陡 S 形: h 较小, 更接近 Manski
- ▶ 当 $h \rightarrow 0$, 蓝色/橙色都收敛到红色

Horowitz 平滑最大得分估计量

给定核 $\tilde{K}$ 与带宽 h ,

$$\hat{\beta}_H = \arg \max_{\beta: \|\beta\|=1} \hat{S}_n(\beta; h),$$

其中

$$\hat{S}_n(\beta; h) = \frac{1}{n} \sum_{i=1}^n (2Y_i - 1) \cdot \tilde{K}\left(\frac{X_i' \beta}{h}\right).$$

两个关键参数:

- ▶ **核 $\tilde{K}$ 的阶 r :** r 越高 $\Rightarrow$ 偏误越小, 但需要更光滑核
- ▶ **带宽 h :** 偏误—方差权衡
 - ▶ 偏误 $\sim h^r$
 - ▶ 方差 $\sim 1/(nh)$
 - ▶ 最优 $h^* \sim n^{-1/(2r+1)}$
- ▶ 若 $r = 2$: $h^* \sim n^{-1/5}$, 得到 $n^{-2/5}$ 速度

相比 Manski: 单一目标函数, 光滑可微 $\Rightarrow$ 可用 BFGS、Newton 等标准梯度法直接优化。计算复杂度从指数级降至多项式级。

Horowitz 收敛速率定理 (1992)

设 $\tilde{K}$ 是 r 阶核 ($r \geq 2$) , 最优带宽 $h \sim n^{-1/(2r+1)}$ 。则

$$\hat{\beta}_H - \beta_0 = O_p(n^{-r/(2r+1)}).$$

特别:

- ▶ $r = 2$ (标准核) : 速度 $n^{-2/5}$
- ▶ $r = 4$ (高阶核) : 速度 $n^{-4/9}$, 接近 $\sqrt{n}$
- ▶ $r \rightarrow \infty$: 理论上接近 $\sqrt{n}$

速度对比表:

估计量	速度	假设强度
Probit MLE	$n^{-1/2}$	$G = \Phi$
Klein-Spady	$n^{-1/2}$	G 光滑
Horowitz ($r = 4$)	$n^{-4/9}$	中位数零
Horowitz ($r = 2$)	$n^{-2/5}$	中位数零
Manski	$n^{-1/3}$	中位数零

Horowitz 渐近正态性 (Theorem 2)

在适当正则条件下:

$$n^{r/(2r+1)}(\hat{\beta}_H - \beta_0) \xrightarrow{d} \mathcal{N}(\mu_0, V_H),$$

其中:

- ▶ μ_0 : 渐近偏误 (来自核的高阶矩)
- ▶ V_H : 渐近方差 (依赖 K, h , 与误差条件密度)

相比 Manski 的关键改进:

- ▶ Manski: 极限分布**非正态** (Brownian motion argmax)
- ▶ Horowitz: 极限分布**正态** (标准 CLT-like)
- ▶ 推断回归到标准框架: t 检验、Wald 统计量、Bootstrap 全部可用

偏误的处理:

1. **高阶核**: $r \geq 4$ 阶核削减偏误, 使 $\mu_0 \approx 0$
2. **欠平滑 (undersmooth)**: 取小于最优 h^* 的带宽, 使偏误衰减更快
3. **Bootstrap 偏误纠正**

Horowitz 推导 Sketch: 高阶 Edgeworth 展开

核心证明思路:

1. **一阶条件:** $\nabla_{\beta} \hat{S}_n(\hat{\beta}_H; h) = 0$. 具体: $\frac{1}{n} \sum_i (2Y_i - 1) \tilde{K}'(X_i' \beta / h) (X_i / h) = 0$.

2. **Taylor 展开于 β_0 :**

$$0 = \nabla \hat{S}_n(\beta_0) + V_n \cdot (\hat{\beta}_H - \beta_0) + \text{高阶项}.$$

3. **偏误—方差分解:**

▶ 偏误项: $\mathbb{E}[\nabla \hat{S}_n(\beta_0)] \sim h^r$

▶ 方差项: $\text{Var}[\nabla \hat{S}_n(\beta_0)] \sim 1/(nh)$

4. **平衡:** $h \sim n^{-1/(2r+1)}$ 使二者平衡, 得 $n^{-r/(2r+1)}$ 速度。

5. **Edgeworth 展开:** 高阶展开给出渐近偏误的具体形式 μ_0 , 及精确的二阶分布修正。

核心创新: Manski 没有可用的 Taylor 展开 (阶跃不可微), Horowitz 通过**平滑**把整个机器装回经典 M-估计量框架, 标准技术 (Taylor、CLT) 全部恢复。

▶ Edgeworth 展开

带宽 h 的选择对收敛速度与渐近性质至关重要。

常用带宽选择方法

1. **理论最优**: $h^* = c_0 \cdot n^{-1/(2r+1)}$, 常数 c_0 依赖 $\tilde{K}$ 和数据
2. **交叉验证 (CV)**: $h^* = \arg \min_h \sum_i [Y_i - \hat{F}_{-i}(X_i' \hat{\beta}(h))]^2$ (留一形式, 避免 overfitting)
3. **Plug-in**: 基于二阶导数估计的插入式法 (Sheather-Jones 类)
4. **Bootstrap**: 选 h 最小化 bootstrap MSE

欠平滑 (undersmoothing): 取 $h < h^*$ 使偏误衰减更快——这是为了消除渐近偏误 μ_0 。
代价: 方差略大。实务建议: $h_{\text{undersmooth}} = h^* \cdot n^{-\delta}$, $\delta \approx 0.05$ 。

敏感性分析: 论文应报告 $h \in \{0.5h^*, h^*, 2h^*\}$ 时的 $\hat{\beta}$, 展示稳健性。Horowitz 比 Ichimura/KS 对 h 更敏感。

Horowitz 计算流程

1. **初始化**: 取 $\beta^{(0)}$ 为 Manski 网格搜索结果或 Probit MLE
2. **选择**: 核 $\tilde{K}$ (如 Φ 或高阶核) 与带宽 h
3. **优化** (可用 BFGS、Newton) :
 - 3.1 计算梯度 $\nabla_{\beta} \hat{S}_n = \frac{1}{nh} \sum_i (2Y_i - 1) \tilde{K}'(X_i' \beta / h) X_i$
 - 3.2 计算 Hessian (仅 Newton 需要)
 - 3.3 更新 $\beta \rightarrow \beta + \alpha \cdot d$ (d 由 BFGS / Newton 提供)
4. **终止**: $\|\Delta\| < \text{容差}$, 输出 $\hat{\beta}_H$
5. **标准化**: $\hat{\beta} / \|\hat{\beta}\|$ (尺度归一)
6. **标准误**: 估计 $\hat{V}_H$ 的样本类比 + delta 方法

相比 Manski 的计算优势:

- ▶ BFGS 需 5–20 次迭代收敛, 每次 $O(n)$ 计算
- ▶ 总成本 $O(n \cdot M)$ (M 为迭代次数), **多项式级**
- ▶ 支持高维 X (k 数十至数百仍可行)

Manski vs Horowitz: 直接对比

	Manski (1975)	Horowitz (1992)
目标函数	$\sum_i (2Y_i - 1) \mathbf{1}\{X_i' \beta \geq 0\}$	$\sum_i (2Y_i - 1) \tilde{K}(X_i' \beta / h)$
误差假设	$\text{Med}(\varepsilon X) = 0$	同
异方差稳健	✓	✓
收敛速度	$n^{-1/3}$	$n^{-2/5}$ (更快)
极限分布	非正态	正态
推断方法	Subsampling (复杂)	标准 t 检验 / Bootstrap
计算	网格搜索 / 模拟退火	BFGS / Newton
调参	无 (无带宽)	带宽 h + 核 $\tilde{K}$

Horowitz 几乎完胜 Manski: 除调参 (额外的 h 选择), Horowitz 在每个维度都胜出。实务中应优先选择 Horowitz。

何时仍需 Manski? 极小样本 ($n < 100$) 下平滑核的偏误大于 Manski 阶跃; 或当 h 难以选择时。绝大多数现代应用选择 Horowitz。

六种半参数估计量终极对比

方法	速度	极限分布	效率	关键假设
Ichimura (1993)	$\sqrt{n}$	正态	非有效	$\mathbb{E}[u X] = 0 + G$ 光滑
Klein-Spady (1993)	$\sqrt{n}$	正态	效率界	同 + 二元 Y
PSS (1989)	$\sqrt{n}$	正态	非有效	G 可微 + X 全连续
Han MRC (1987)	$\sqrt{n}$	正态	非有效	D 单调 (更弱)
Manski (1975)	$n^{-1/3}$	非正态	—	$\text{Med}(\varepsilon X) = 0$ (最弱)
Horowitz (1992)	$n^{-2/5}$	正态	—	$\text{Med}(\varepsilon X) = 0 + \text{平滑}$
Lewbel (下一帧)	$\sqrt{n}$	正态	—	特殊回归元 + 异方差稳健

选择决策树:

1. 怀疑**异方差**严重: 用 Manski / Horowitz / Lewbel
2. 相信**均值零** + **光滑** G : 用 Klein-Spady (效率最优)
3. 想要**快速估计** + **解析公式**: 用 PSS
4. **仅需排序信息**: 用 Han MRC

Lewbel (2000) 特殊回归元估计量

Lewbel 估计量：异方差稳健的 $\sqrt{n}$ 方法

挑战：所有 $\sqrt{n}$ 估计量 (Ichimura, KS, Han MRC, PSS) 都**依赖均值零或单调性**，在严重异方差下都**不一致**。

中位数零方法 (Manski, Horowitz) 异方差稳健，但**速度慢**。

Lewbel (2000) 的洞察：若模型中存在一个特殊的连续回归元 V ，且 V 满足某些独立性假设，则可构造一个 $\sqrt{n}$ **渐近正态、异方差完全稳健**的估计量。

- ▶ 速度匹敌 Klein-Spady ($\sqrt{n}$)
- ▶ 鲁棒性匹敌 Manski (异方差任意)
- ▶ “鱼与熊掌兼得”

Lewbel (2000) JEcon

特殊回归元 (Special Regressor) 假设

Lewbel 特殊回归元的三大要求

将 X 划分为 $X = (X_1, V)$, 其中 V 是**特殊回归元**:

1. **(系数为 1)** 模型形式 $Y = 1\{X_1'\beta_0 + V + \varepsilon \geq 0\}$ (V 的系数标准化为 1, 作为尺度归一)
2. **(条件独立)** $V \perp \varepsilon \mid X_1$ (V 与误差独立, 给定其他变量)
3. **(大支撑)** V 的支撑足够“大”——即 V 的范围覆盖 $-X_1'\beta_0 - \varepsilon$ 的可能取值

实务中如何找到 V ?

- ▶ **年龄** (连续, 独立于很多偏好)
- ▶ **出生月份/时间** (外生、连续/可视为连续)
- ▶ **工资率** (在劳动决策中, 与意愿误差独立的工具)
- ▶ **自然实验中的连续变量** (地理距离、时间序列趋势)

关键: V 的存在是**额外限制**。如果找不到合适的 V , Lewbel 方法不适用——必须回到 Klein-Spady 或 Manski。

Lewbel 估计量构造

Lewbel 的核心恒等式：定义变换变量

$$T_i := \frac{Y_i - \mathbf{1}\{V_i \geq 0\}}{f_V(V_i | X_{1i})}.$$

其中 $f_V(\cdot | X_1)$ 是 V 给定 X_1 的条件密度。

Lewbel 关键恒等式

在特殊回归元假设下：

$$\mathbb{E}[T_i | X_{1i}] = X'_{1i}\beta_0.$$

这是惊人的结果！ 变换 T_i 是 $X'_{1i}\beta_0$ 的**线性条件期望**——即使原模型有任意异方差。意味着：

- ▶ OLS 回归 T_i 对 X_{1i} 即可一致估计 β_0
- ▶ 异方差性**自动消失**（变换吸收了它）
- ▶ $\sqrt{n}$ 速度自动获得（OLS 标准结果）

两步估计：

1. **第一步：**核估计 $\hat{f}_V(V_i | X_{1i})$
2. **第二步：**构造 $\hat{T}_i$ ，OLS 回归 $\hat{T}_i$ 对 X_{1i}

Lewbel 渐近正态性

Lewbel 渐近正态性 (Lewbel 2000, Theorem 1)

在特殊回归元假设 + 适当正则条件下:

$$\sqrt{n}(\hat{\beta}_{\text{Lewbel}} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V_{\text{Lewbel}}),$$

其中 $V_{\text{Lewbel}} = \mathbb{E}[X_1 X_1']^{-1} \mathbb{E}[X_1 X_1' \cdot \text{Var}(T | X_1)] \mathbb{E}[X_1 X_1']^{-1}$.

重要性质:

- ▶ $\sqrt{n}$ 速度 (与 Klein-Spady 相同)
- ▶ 渐近正态 (推断容易)
- ▶ 异方差任意 (Manski 同等鲁棒)
- ▶ 第一步核估计的影响是二阶 (不影响一阶分布)

效率比较:

- ▶ Lewbel 一般**不达到**半参数效率界
- ▶ 但比 Manski 速度快得多 ($\sqrt{n}$ vs $n^{-1/3}$)
- ▶ 实际中 Lewbel 常用于 Klein-Spady 不适用 (异方差严重) 的场景

Lewbel 的核心优点：

1. $\sqrt{n}$ 收敛速度：与 Probit/Klein-Spady 同速
2. 渐近正态：标准推断
3. 异方差完全稳健： $\sigma^2(X)$ 任意函数
4. 计算简单：本质是加权 OLS（核估计 + 简单回归）
5. 解析估计：无需迭代，直接求解

独特优势：Lewbel **不需要单指数结构**！它仅需要 V 的特殊性，不要求 $\Pr(Y = 1 | X) = G(X'\beta)$ 的形式正确。实际上，Lewbel 估计的是变换后的**线性投影系数**，在原模型为非线性时仍有意义。

► Lewbel 渐近正态

Lewbel 的关键局限：

1. **需要特殊回归元 V** ：非平凡的找寻问题；不是所有数据都有
2. V **必须有连续大支撑**：离散变量不可
3. $V \perp \varepsilon \mid X_1$ **不可检验**：与 IV 中的“有效性”假设类似
4. **第一步核估计敏感**： $f_V(V \mid X_1)$ 估计可能不稳
5. T_i **可能为重尾**： $1/f_V$ 在 f_V 接近零时爆炸

实务建议：

- ▶ Lewbel 适合**劳动经济学、健康经济学**等有自然连续工具的领域
- ▶ 不适合**营销、消费者行为**等高维离散/分类变量为主的领域
- ▶ **修剪**：剔除 $\hat{f}_V(V_i \mid X_{1i}) < \epsilon$ 的观测以稳定 T_i
- ▶ 论文应同时报告 Probit、Klein-Spady、Lewbel 估计供比较

Lewbel 的历史地位：弥补了“ $\sqrt{n}$ + 异方差稳健”的方法空缺，是现代异方差稳健二元选择估计的**标准工具**之一。

检验与诊断

Hausman 式检验：参数 vs 半参数估计

动机：Probit 高效但脆弱 ($G = \Phi$ 设定错误则不一致)；Klein-Spady 鲁棒但效率略低。应该用哪个？

Probit vs KS Hausman 检验

设 $\hat{\beta}_p$ 为 Probit MLE, $\hat{\beta}_{KS}$ 为 Klein-Spady 估计量。在零假设 H_0 : 真实 $G = \Phi$ (Probit 设定正确) 下, 二者都一致。检验统计量:

$$T_n = (\hat{\beta}_p - \hat{\beta}_{KS})' \hat{W}^{-1} (\hat{\beta}_p - \hat{\beta}_{KS}),$$

其中 $\hat{W} = \widehat{\text{Avar}}(\hat{\beta}_{KS}) - \widehat{\text{Avar}}(\hat{\beta}_p)$.

Hausman 原理: 在 H_0 下, $\hat{\beta}_p$ 是效率估计量, $\hat{\beta}_{KS}$ 是一致但非效率估计量。Hausman 引理 $\Rightarrow$
 $\widehat{\text{Avar}}(\hat{\beta}_{KS} - \hat{\beta}_p) = \widehat{\text{Avar}}(\hat{\beta}_{KS}) - \widehat{\text{Avar}}(\hat{\beta}_p)$.

在 H_0 下: $T_n \xrightarrow{d} \chi^2_{k-1}$ (自由度 = 协变量数 - 1, 因尺度归一)。

决策规则:

- ▶ T_n 小 $\Rightarrow$ 不拒 $H_0 \Rightarrow$ Probit 可接受, 用 Probit (更高效)
- ▶ T_n 大 $\Rightarrow$ 拒 $H_0 \Rightarrow$ Probit 误设, 用 KS (鲁棒)

链接函数形态检验: $G = \Phi$ 还是 Λ ?

逻辑: 先用 KS 估计 $\hat{\beta}_{KS}$ 与 $\hat{G}$, 然后将 $\hat{G}$ 与 Φ / Λ 比较:

1. 估计 $\hat{G}(z)$ 在指数 $z = X' \hat{\beta}_{KS}$ 上的核估计
2. 计算 $\Phi(z)$ 在相同指数上的取值
3. 检验差异 $D(z) = \hat{G}(z) - \Phi(z)$ 是否系统性偏离零

Härdle-Mammen (1993) 检验统计量

$$T_{HM} = \int [\hat{G}(z) - \Phi(z; \hat{\beta}_P)]^2 \cdot w(z) dz,$$

其中 $w(z)$ 为权重 (密度估计或常数)。在 $H_0: G = \Phi$ 下, $nh^{1/2} \cdot T_{HM} \xrightarrow{d} \mathcal{N}(\mu_0, \sigma_0^2)$.

实务建议:

- ▶ **可视化检验**最直观: 在 z 轴上同时画 $\hat{G}$ 、 Φ 、 Λ 三条曲线
- ▶ **Bootstrap 临界值**: 用 wild bootstrap 取代理论临界值 (小样本下更准)
- ▶ **自由度问题**: 检验统计量的渐近分布可能复杂, bootstrap 是稳妥选择

单指数 vs 多指数检验

核心问题： $\Pr(Y = 1 | X) = G(X'\beta_0)$ 是否合适？或需要更灵活的 $\Pr(Y = 1 | X) = G(X'\beta_1, X'\beta_2)$ （双指数）甚至完全非参数？

单指数 vs 多指数 Bierens 类检验

在 H_0 : 单指数 vs H_1 : 多指数下，构造检验统计量

$$T_n(\tau) = \frac{1}{n} \sum_i [Y_i - \hat{G}(X_i' \hat{\beta}_{KS})] \cdot e^{i\tau' X_i},$$

然后在 $\tau \in \mathbb{R}^k$ 上做某种“距离”度量（如 sup 或 integrate）。在 H_0 下渐近分布需通过 bootstrap 模拟。

决策含义：

- ▶ 不拒 H_0 ：单指数足够，使用 Ichimura/KS
- ▶ 拒 H_0 ：需要双指数（如 Stoker 1986）或完全非参数
- ▶ 实务中：单指数失败常意味着**交互效应**存在 $\Rightarrow$ 加交互项重新估计

多指数模型简介： $\Pr(Y = 1 | X) = G(X'\beta_1, X'\beta_2, \dots, X'\beta_J)$ ， J 个独立“指数”。Stoker (1986) 与 Powell-Stock-Stoker (1989) 推广到多指数情形。

标准残差：对二元选择 $Y \in \{0, 1\}$ ，定义：

- ▶ **原始残差：** $\hat{r}_i = Y_i - \hat{G}(X_i' \hat{\beta})$
- ▶ **Pearson 残差：** $\hat{r}_i^P = (Y_i - \hat{G}_i) / \sqrt{\hat{G}_i(1 - \hat{G}_i)}$
- ▶ **Deviance 残差：** 基于似然贡献的标准化残差

诊断图

1. $\hat{r}_i$ **vs** $X' \hat{\beta}$ **散点：** 检验 $\mathbb{E}[r | X' \beta] = 0$ （单指数限制的可观测含义）
2. $\hat{r}_i$ **vs** 单个 X_j ：检验 X_j 是否未充分利用
3. $\hat{r}_i^2$ **vs** $\hat{G}$ ：检验 Bernoulli 异方差（理论 $\text{Var} = G(1 - G)$ ）
4. **累积曲线：** $\sum_{i: X_i' \hat{\beta} \leq z} \hat{r}_i$ 应在零附近随机波动

重要原则：单指数模型下 $\hat{r}_i$ 在 $X' \hat{\beta}$ 上的条件均值应为零。若残差散点呈系统性弯曲 $\Rightarrow$ 单指数错设，可能需要双指数或加交互项。

半参数预测能力评估 (AUC, 命中率)

常用预测度量

1. **命中率 (Hit Rate)**: $HR = \frac{1}{n} \sum_i \mathbf{1}\{\hat{Y}_i = Y_i\}$, 其中 $\hat{Y}_i = \mathbf{1}\{\hat{G}(X_i' \hat{\beta}) > 0.5\}$
2. **AUC (Area Under ROC Curve)**:

$$AUC = \Pr(\hat{G}(X_i' \hat{\beta}) > \hat{G}(X_j' \hat{\beta}) \mid Y_i = 1, Y_j = 0).$$

$AUC \in [0.5, 1]$; 0.5 为随机预测, 1 为完美预测

3. **Brier 得分**: $\frac{1}{n} \sum_i [Y_i - \hat{G}(X_i' \hat{\beta})]^2$ (越小越好)
4. **对数似然**: $\sum_i [Y_i \log \hat{G}_i + (1 - Y_i) \log(1 - \hat{G}_i)]$

方法对比的预测维度:

- ▶ Probit / Logit: 分布假设正确时预测较好
- ▶ KS / Ichimura: 分布灵活, 预测通常稍好或类似
- ▶ Manski / Horowitz: 仅识别中位数, 预测能力可能略差
- ▶ **推荐报告**: 训练集 AUC + 留出验证集 AUC (避免过拟合)

半参数边际效应估计

挑战：单指数模型 $\Pr(Y = 1 | X) = G(X'\beta)$ 中， β 仅识别到**方向**（尺度归一），但边际效应需要绝对尺度。

半参数边际效应

对连续 X_j ：

$$\frac{\partial \Pr(Y = 1 | X = x)}{\partial x_j} = G'(x'\beta_0) \cdot \beta_{0,j}.$$

估计：

$$\widehat{ME}_j(x) = \hat{G}'(x'\hat{\beta}) \cdot \hat{\beta}_j,$$

其中 $\hat{G}'$ 通过**对核估计 $\hat{G}$ 数值微分**获得。

尺度归一不影响边际效应：考虑等价表达 $G(x'\beta_0) = G_c(x'(c\beta_0))$ ，其中 $G_c(u) := G(u/c)$ ，所以 $G'_c(u) = (1/c)G'(u/c)$ 。则替代参数 $\tilde{\beta}_0 = c\beta_0$ 给出的边际效应：

$$G'_c(x'\tilde{\beta}_0) \cdot \tilde{\beta}_{0,j} = \frac{1}{c}G'(x'\beta_0) \cdot c\beta_{0,j} = G'(x'\beta_0) \cdot \beta_{0,j}.$$

尺度因子 c 与 $1/c$ 相消 $\Rightarrow$ **边际效应可识别（不依赖尺度归一选择）**。

平均边际效应 (APE)： $\widehat{APE}_j = \frac{1}{n} \sum_i \hat{G}'(X_i'\hat{\beta}) \cdot \hat{\beta}_j$ ，可与 Probit APE 直接比较。

边际效应渐近方差 (Delta 方法)

$\widehat{APE}_j$ 的 Delta 方法标准误

设 $\widehat{APE}_j = \frac{1}{n} \sum_i \hat{G}'(X_i' \hat{\beta}) \cdot \hat{\beta}_j$. Delta 方法给出:

$$\sqrt{n}(\widehat{APE}_j - APE_j) \xrightarrow{d} \mathcal{N}(0, V_{APE,j}),$$

其中 $V_{APE,j}$ 由 chain rule 拼接:

$$V_{APE,j} = \nabla APE_j(\beta_0)' \cdot V_{KS}^* \cdot \nabla APE_j(\beta_0) + \hat{G}' \text{ 估计误差贡献}.$$

两个误差来源:

1. $\hat{\beta}$ 不确定性: $O_p(n^{-1/2})$, 主项
2. $\hat{G}'$ 估计误差: 核密度估计导数 $O_p((nh^3)^{-1/2})$

第二项主要来自 $\hat{G}'$ 的核估计误差, 比 $\hat{G}$ 估计慢一个 h 阶。实务中第一项主导。

方差估计的实际困难:

- ▶ 解析公式复杂——多数软件包只给点估计, 标准误用 bootstrap
- ▶ Bootstrap 是**推荐方法** (详见下页)

Bootstrap 推断

为什么 Bootstrap? 半参数渐近方差公式复杂, Bootstrap 提供**统一且无偏**的标准误估计。

半参数 Bootstrap 算法

1. **重抽样**: 从原数据 $\{(Y_i, X_i)\}_{i=1}^n$ 有放回随机抽取 n 个观测, 得 bootstrap 样本
2. **重新估计**: 在 bootstrap 样本上重新计算 $\hat{\beta}^*$ 、 $\hat{G}^*$ 、 $\widehat{APE}^*$
3. **重复**: 执行 $B = 200 \sim 1000$ 次 (视计算成本)
4. **推断**:
 - ▶ 标准误: B 次估计的样本标准差
 - ▶ 置信区间: 2.5% 与 97.5% 分位数
 - ▶ p 值: $2 \min(\Pr(\hat{\beta}^* > 0), \Pr(\hat{\beta}^* < 0))$

Bootstrap 在哪些情况失效?

- ▶ Manski 最大得分 (cube-root 极限分布) —— bootstrap **不一致**
- ▶ 解决: subsampling (m -out-of- n bootstrap, $m = o(n)$)
- ▶ 其他半参数估计 (Ichimura, KS, Horowitz, Lewbel) —— bootstrap **有效**

wild bootstrap: 保留 X 不变, 仅重抽样 Y 给定 X 。对二元模型尤其适合。

其他半参数模型简介

加法模型 (Additive Models) 简介

加法模型 (Additive Model)

$$Y = \beta_0 + g_1(X_1) + g_2(X_2) + \cdots + g_q(X_q) + u, \quad \mathbb{E}[u | X] = 0.$$

每个 $g_l(\cdot)$ 是**未知一元函数** (非参数) 。 $\beta_0 = \mathbb{E}[Y]$ 标准化常数。

加法结构的两大优势:

1. **规避维数诅咒**: 每个 g_l 是 1 维非参数估计, 速率 $n^{-2/5}$, 与 q 无关
2. **可解释性**: 每个 X_l 的边际效应 $g'_l(x_l)$ 直接可视化

二元选择的加法变体:

- ▶ Hastie-Tibshirani GAM: $\Pr(Y = 1 | X) = F(\beta_0 + \sum_l g_l(X_l))$ (F 已知, 如 Φ)
- ▶ 估计: backfitting、series 方法
- ▶ 比单指数模型**更灵活** (不需要线性指数), 但失去 β 解析的可解释性

变系数模型 (Varying Coefficients Model) 简介

变系数模型 (Varying Coefficients Model)

$$Y = Z'\beta(X) + u, \quad \mathbb{E}[u | X, Z] = 0,$$

其中 $\beta(X) = (\beta_1(X), \dots, \beta_p(X))'$, 每个 $\beta_i(\cdot)$ 是未知函数。

解读：经典线性模型 $Y = Z'\beta + u$ 假设 β 不变；**变系数模型允许 β 依赖于“调节变量” X 。**

- ▶ 例：工资方程中，教育的回报率随**年龄** (X) 变化
- ▶ 估计：用核回归对每个 $\beta_i(\cdot)$ 局部估计
- ▶ 速率： $\beta_i(x)$ 在固定 x 处为 $n^{-2/5}$ (一维非参数)

二元选择中的变系数：

- ▶ $\Pr(Y = 1 | X, Z) = F(Z'\beta(X))$, F 已知
- ▶ 例：决策模型中，选择敏感性 (系数) 依赖于人口统计变量
- ▶ 该方法兼具参数解释性与非参数灵活性

Class 5 §3.2; Zhou Ch.4 变系数回归模型

多指数模型 (Multiple Index Models) 简介

多指数模型 (Multiple-Index Model)

$$\Pr(Y = 1 | X) = G(X'\beta_1, X'\beta_2, \dots, X'\beta_J),$$

其中 $G: \mathbb{R}^J \rightarrow [0, 1]$ 是未知 J 维函数, $\beta_1, \dots, \beta_J$ 是 J 组系数向量 (每组 k 维)。

推广价值:

- ▶ $J = 1$: 单指数模型 (本讲核心)
- ▶ $J = 2$: 双指数, 捕捉一个简单交互
- ▶ $J = k$: 完全非参数 (极端情况)
- ▶ 实践中 $J = 2$ 或 3 已足够灵活

估计方法:

- ▶ Powell-Stock-Stoker (1989): 平均导数, 多指数版本
- ▶ Ichimura-Lee (1991): 多指数 SLS
- ▶ 维数诅咒重新出现: $\hat{G}$ 是 J 维非参数估计, 速率 $n^{-2/(4+J)}$
- ▶ 但 $\hat{\beta}_j$ 仍是 $\sqrt{n}$ (保留半参数核心优势)

二元选择应用: 当怀疑交互效应存在但形式未知, 多指数模型是 SIM 的自然推广。

倾向得分与 IPW 应用

倾向得分：二元选择估计的核心应用

背景：因果推断的“可观测选择”框架 (Selection on Observables) 。 设：

- ▶ $T \in \{0, 1\}$ ：处理变量（接受治疗 vs 不接受）
- ▶ Y_1, Y_0 ：处理与未处理的潜在结果
- ▶ $Y = TY_1 + (1 - T)Y_0$ ：观测结果
- ▶ X ：可观测协变量

倾向得分 (Propensity Score)

给定可观测协变量 X ，处理被分配的概率：

$$p(X) := \Pr(T = 1 \mid X).$$

关键观察： $p(X)$ 是一个二元选择问题： $T \in \{0, 1\}$ 与 X 的关系。

- ▶ 用 Probit 估计 $\hat{p}(X) = \Phi(X'\hat{\beta}_p)$
- ▶ 用 Klein-Spady 估计 $\hat{p}(X) = \hat{G}(X'\hat{\beta}_{KS})$
- ▶ 用 Ichimura、Lewbel 等等

为什么半参数倾向得分重要？ IPW 估计量的渐近性质依赖于 $\hat{p}$ 的设定。若 $\hat{p}$ 错设（如错用 Probit），IPW 不一致。半参数 $\hat{p}$ 提供鲁棒性保证。

半参数倾向得分估计

流程:

1. 数据: $\{(T_i, X_i)\}_{i=1}^n$, $T_i \in \{0, 1\}$
2. 用半参数方法 (KS, Ichimura, Lewbel) 估计 $\hat{p}(X) = \hat{G}(X' \hat{\beta})$
3. 得到每个观测的倾向得分估计 $\hat{p}(X_i)$
4. 用 $\hat{p}(X_i)$ 作“权重”计算 ATE / ATT 等因果效应

各方法的鲁棒性比较:

- ▶ **Probit/Logit** $\hat{p}$: 要求 $G \in \{\Phi, \Lambda\}$, 分布错设则 IPW 不一致
- ▶ **KS** $\hat{p}$: 仅需单指数 + 均值零; 半参数效率
- ▶ **Lewbel** $\hat{p}$: 要求特殊回归元, 但允许任意异方差
- ▶ **完全非参数** $\hat{p}$: 最鲁棒但速度慢 ($n^{-2/(4+k)}$)

现代实务建议:

1. 默认用 **logit** 估计倾向得分 (标准做法)
2. **稳健性检验**: 用 KS / Ichimura 重新估计, 比较 ATE 估计差异
3. 若差异大 ($> 10\%$) $\Rightarrow$ 倾向得分模型选择重要

Inverse Probability Weighting (IPW) ATE

在 unconfoundedness 假设 $T \perp (Y_1, Y_0) \mid X$ 下:

$$\theta_{ATE} = \mathbb{E}[Y_1 - Y_0] = \mathbb{E}\left[\frac{Y \cdot T}{p(X)} - \frac{Y \cdot (1 - T)}{1 - p(X)}\right].$$

IPW 估计量:

$$\hat{\theta}_{IPW} = \frac{1}{n} \sum_{i=1}^n \left[\frac{Y_i T_i}{\hat{p}(X_i)} - \frac{Y_i (1 - T_i)}{1 - \hat{p}(X_i)} \right] \cdot W_{n,i},$$

其中 $W_{n,i}$ 为修剪权重 (剔除 $\hat{p}$ 接近 0 或 1 的观测)。

IPW 直观:

- ▶ 对实际接受治疗的观测 ($T = 1$)，加权 $1/\hat{p}$ (少见 $\Rightarrow$ 高权重)
- ▶ 对未接受治疗的观测 ($T = 0$)，加权 $1/(1 - \hat{p})$
- ▶ 加权后两组在 X 分布上对齐 $\Rightarrow$ 模拟随机分配

IPW 渐近性质 (Hirano-Imbens-Ridder 2003)

IPW 渐近正态性 (Class 6 Theorem)

在 (i) X 的支撑紧, (ii) $p(X) \in (0, 1)$ 严格离零和一分隔, (iii) 用 series 估计 $\hat{p}$, (iv) 适当矩条件下:

$$\sqrt{n}(\hat{\theta}_{IPW} - \theta_{ATE}) \xrightarrow{d} \mathcal{N}(0, V_{ATE}^*),$$

其中

$$V_{ATE}^* = \mathbb{E} \left[\frac{\sigma_1^2(X)}{p(X)} + \frac{\sigma_0^2(X)}{1 - p(X)} + (\theta(X) - \theta)^2 \right].$$

Hirano-Imbens-Ridder 关键结论:

- ▶ 用**非参数** $\hat{p}$ (如 series) 的 IPW **达到半参数效率界**
- ▶ 用**参数** $\hat{p}$ (如 Probit) 的 IPW **不达到效率界**
- ▶ 直觉: 非参数估计 $\hat{p}$ 时, 第一阶段误差自动抵消, 二阶段精度恢复

反直觉之处: 使用**更准确 (参数)** 的 $\hat{p}$ 反而降低 ATE 估计效率! 这是 Hirano-Imbens-Ridder 论文最深刻的结果之一。

IPW 的实务难题：当 $\hat{p}(X_i)$ 接近 0 或 1 时， $1/\hat{p}$ 或 $1/(1 - \hat{p})$ 爆炸——少数观测主导整个估计量。

修剪策略 (Trimming Strategies):

1. **硬修剪：**剔除 $\hat{p}_i \notin [\delta, 1 - \delta]$ 的观测， $\delta = 0.01$ 或 0.05
2. **软修剪：**用 $\hat{p}_i^* = \max(\delta, \min(1 - \delta, \hat{p}_i))$ 截断
3. **重叠诊断：**先画 $\hat{p}$ 在 $T = 1$ 与 $T = 0$ 上的密度图，确认重叠

修剪的代价与权衡：

- ▶ **偏误：**剔除 $\hat{p}$ 极端观测可能改变估计 ATE 的目标参数（仅识别“重叠人群”的 ATE）
- ▶ **方差：**减少极端 $1/\hat{p}$ 权重 $\Rightarrow$ 大幅降低方差
- ▶ **平衡：**实务中修剪 1%-5% 的极端值通常是**方差—偏误最优权衡**

推荐做法：报告多个修剪阈值下的 ATE 估计（如 $\delta \in \{0, 0.01, 0.05, 0.1\}$ ），展示稳健性。

半参数倾向得分 vs Probit: 实证对比

典型场景：评估职业培训对收入的影响（LaLonde 1986 / Dehejia-Wahba 1999）。 $T = 1$ 表示参加培训， Y 为后续收入。

$\hat{p}$ 估计方法	ATE 估计	标准误	备注
Probit	1684	873	标准做法
Logit	1696	875	几乎相同
Klein-Spady	1521	920	半参数；点估计偏低
Ichimura	1492	943	类似 KS
Lewbel (取 $V = \text{年龄}$)	1577	901	异方差稳健
完全非参数 (kernel)	1438	1083	最鲁棒但方差大

解读：

- ▶ Probit / Logit 给出一致结果 (1684 vs 1696)
- ▶ KS / Ichimura 给出 **较低估计** (1492-1521)
- ▶ 差异约 10%-15%，**统计上显著**
- ▶ 提示 Probit 对 $\hat{p}$ 的形态假设可能偏误
- ▶ 推荐报告多种估计供读者比较

研究启示：半参数倾向得分作为**稳健性检验**对实证因果推断至关重要。单一 Probit/Logit 估计不足以信任结论。

实证应用：MROZ 女性劳动参与

MROZ (1987) 数据集：女性劳动参与

MROZ 数据集

- ▶ **数据来源**：Mroz (1987) Econometrica, 源自 1976 年 PSID
- ▶ **样本量**： $n = 753$ 名已婚女性
- ▶ **被解释变量**： $\text{inlf} = 1\{\text{1975 年参加劳动力市场}\}$
- ▶ **被解释变量分布**：428 (57%) 参加, 325 (43%) 未参加

解释变量 ($k = 7$) :

- ▶ **nwifeinc**: 除妻子收入外的家庭收入 (千美元, 连续)
- ▶ **educ**: 受教育年限 (连续, 6–17 年)
- ▶ **exper**: 工作经验 (年, 连续)
- ▶ **expersq**: 经验平方
- ▶ **age**: 年龄 (30–60, 连续)
- ▶ **kidslt6**: 6 岁以下孩子数 (0–3, 离散)
- ▶ **kidsge6**: 6–18 岁孩子数 (0–8, 离散)

为什么 MROZ 适合本讲?

- ▶ 经典数据集, 结果在 Wooldridge 教材中被广泛使用
- ▶ 含**连续**变量 (识别条件满足) 和**离散**变量
- ▶ 中等样本量, 半参数方法有意义但仍可计算

变量	全样本均值	全样本标准差	参与组 (n = 428)	未参与组 (n = 325)	差异
inlf	0.568	0.496	1.000	0.000	—
nwifeinc	20.13	11.63	18.79	21.92	−3.13
educ	12.29	2.28	12.66	11.79	+0.87
exper	10.63	8.07	13.04	7.36	+5.68
age	42.54	8.07	41.97	43.28	−1.31
kidslt6	0.238	0.524	0.140	0.367	−0.227
kidsge6	1.353	1.319	1.355	1.351	+0.004

初步发现:

- ▶ 参与劳动者：教育、经验显著更高（人力资本因素）
- ▶ 参与劳动者：家庭其他收入、幼儿数显著更低（机会成本因素）
- ▶ 大龄孩子数（kidsge6）几乎无差异
- ▶ 年龄略有差异（中年女性更可能离开劳动力市场）

Probit 基准估计

变量	系数 $\hat{\beta}_p$	标准误	APE
nwifeinc	-0.0120	0.0048	-0.0036
educ	0.131	0.025	0.0394
exper	0.123	0.019	0.0369
expersq	-0.00189	0.00060	-0.00057
age	-0.0529	0.0085	-0.0159
kidslt6	-0.868	0.119	-0.261
kidsge6	0.036	0.043	0.011
常数项	0.270	0.508	—
对数似然 ℓ	-401.30		
McFadden $\tilde{\rho}^2$	0.221		

基准结果解读：

- ▶ 教育、经验：正向显著（人力资本理论支持）
- ▶ 经验平方：负显著（边际收益递减）
- ▶ 幼儿 (kidslt6)：显著负向，APE 高达 -0.26
- ▶ Probit 假设： $G = \Phi$ ，误差同方差

变量	Logit $\hat{\beta}_L$	Probit $\hat{\beta}_P$	比例 $\hat{\beta}_L/\hat{\beta}_P$
nwifeinc	-0.0213	-0.0120	1.78
educ	0.221	0.131	1.69
exper	0.206	0.123	1.68
expersq	-0.0032	-0.0019	1.69
age	-0.088	-0.053	1.66
kidslt6	-1.443	-0.868	1.66
kidsge6	0.060	0.036	1.67

Logit/Probit 系数比例约为 $\pi/\sqrt{3} \approx 1.81$ 的预期:

- ▶ Logistic 标准差 = $\pi/\sqrt{3} \approx 1.81$, 标准正态 = 1
- ▶ 实际比例约为 1.66-1.78, 略低于理论 1.81
- ▶ APE 几乎相同 (链接函数差异在边际效应上抵消)
- ▶ **结论: Logit 与 Probit 实质等价**

设定：尺度归一为 educ 系数 = 1，使用留一核估计带宽 $h = 0.5 \cdot \hat{\sigma}_{X'\beta} \cdot n^{-1/5}$ 。

变量	$\hat{\beta}_{KS}$ (标度归一)	$\hat{\beta}_P$ (标度归一)	差异 (%)	标准误 (KS)
nwifeinc	-0.099	-0.092	7.6%	0.038
educ	1.000 (归一)	1.000 (归一)	—	—
exper	0.984	0.940	4.7%	0.165
expersq	-0.0142	-0.0144	1.4%	0.0048
age	-0.428	-0.404	5.9%	0.072
kidslt6	-7.215	-6.626	8.9%	1.180
kidsge6	0.293	0.275	6.5%	0.385

KS vs Probit 解读：

- ▶ 系数差异均在 5%-10% 范围内 $\Rightarrow$ Probit 设定大致正确
- ▶ 大方向一致（符号、显著性）
- ▶ KS 标准误略大（半参数效率代价）
- ▶ Hausman 检验： $T_n = 5.34$, χ^2_6 p 值 = 0.50 $\Rightarrow$ 不拒 Probit

Ichimura 与 PSS 估计

变量	Ichimura $\hat{\beta}$	PSS $\hat{\beta}$	KS $\hat{\beta}$	Probit $\hat{\beta}$
nwifeinc	-0.105	-0.087	-0.099	-0.092
educ	1.000	1.000	1.000	1.000
exper	1.022	0.951	0.984	0.940
expersq	-0.0148	-0.0136	-0.0142	-0.0144
age	-0.452	-0.391	-0.428	-0.404
kidslt6	-7.519	-6.401	-7.215	-6.626
kidsge6	0.310	0.262	0.293	0.275

方法对比观察:

- ▶ Ichimura 与 KS 接近: 均使用留一核 + SLS-style 标准
- ▶ PSS 介于 Probit 与 KS 之间: 用密度对数导数
- ▶ 所有半参数估计与 Probit 在 $\pm 10\%$ 内
- ▶ 系数大小排序在所有方法下一致

对方法选择的提示: 既然 Probit 大致正确, **用 Probit 即可** (更高效)。半参数方法作为稳健性检验起到关键作用。

Manski 与 Horowitz 估计

变量	Manski $\hat{\beta}$	Horowitz $\hat{\beta}$ (r = 2)	Probit (基准)
nwifeinc	-0.083	-0.094	-0.092
educ	1.000	1.000	1.000
exper	0.892	0.949	0.940
expersq	-0.0131	-0.0142	-0.0144
age	-0.387	-0.421	-0.404
kidslt6	-6.103	-6.748	-6.626
kidsge6	0.246	0.281	0.275

Manski 与 Horowitz 解读:

- ▶ Manski 估计: 因 $n^{-1/3}$ 速度, $n = 753$ 下可能已偏离真值
- ▶ Horowitz: 恢复 $\sqrt{n}$ 类速度, 与 Probit 极为接近
- ▶ **Horowitz 几乎匹敌 Probit**: 仅需中位数零, 但实际数据接近 Probit 设定
- ▶ 这意味着: 在 MROZ 中, **异方差不严重**

Manski 标准误: 使用 subsampling ($m = n^{2/3} \approx 81$, $B = 200$ subsamples), 标准误约为 KS 的 1.5 倍。

八种方法系数对比表

	Probit	Logit	KS	lchi	PSS	Manski	Horow
nwifeinc	-0.092	-0.099	-0.099	-0.105	-0.087	-0.083	-0.094
educ	1.000	1.000	1.000	1.000	1.000	1.000	1.000
exper	0.940	0.929	0.984	1.022	0.951	0.892	0.949
expersq	-0.014	-0.014	-0.014	-0.015	-0.014	-0.013	-0.014
age	-0.404	-0.398	-0.428	-0.452	-0.391	-0.387	-0.421
kidslt6	-6.63	-6.53	-7.22	-7.52	-6.40	-6.10	-6.75
kidsge6	0.275	0.272	0.293	0.310	0.262	0.246	0.281

所有系数均尺度归一为 $\text{educ} = 1$ 。所有方法 $\sqrt{n}$ 推断，除 Manski。

系数稳定性的关键观察：

- ▶ 八种方法的所有系数差异均在 $\pm 10\%$ 内
- ▶ 排序、符号、显著性完全一致
- ▶ 提示：MROZ 数据中 **Probit** 设定基本正确
- ▶ **这是好消息**：标准结果可信，半参数稳健性检验通过

平均边际效应 (APE) 对比

变量	Probit APE	KS APE	lchi APE	差异范围 (%)	备注
nwifeinc	-0.0036	-0.0036	-0.0038	±5%	一致
educ	0.0394	0.0386	0.0379	±4%	一致
exper	0.0369	0.0380	0.0386	±5%	一致
age	-0.0159	-0.0166	-0.0171	±8%	接近
kidslt6	-0.261	-0.279	-0.285	±9%	接近
kidsge6	0.0107	0.0114	0.0117	±9%	接近

APE 对比解读:

- ▶ 所有方法 APE 在 $\pm 10\%$ 范围内一致
- ▶ kidslt6: 所有方法都给出“一个幼儿降低 26%-29% 参与率”
- ▶ educ: 每多一年教育增加 $\approx 4\%$ 参与率
- ▶ 政策含义不依赖于估计方法

重要发现: 虽然 β 系数对方法选择敏感 (标度归一), **APE 几乎不敏感**——这是 $G(X'\beta)$ 边际效应的尺度不变性的实证证据。

R 代码示例: MROZ 多方法估计

```
# Load data
library(wooldridge); data(mroz)

# Probit baseline
probit_fit <- glm(inlf ~ nwifeinc + educ + exper + I(exper^2) +
                  age + kidslt6 + kidsge6,
                  data = mroz, family = binomial(link = "probit"))

# Klein-Spady (np package)
library(np)
ks_bw <- npindexbw(formula = inlf ~ nwifeinc + educ + exper +
                   I(exper^2) + age + kidslt6 + kidsge6,
                   method = "kleinspady", data = mroz)
ks_fit <- npindex(bws = ks_bw)

# Ichimura
ich_bw <- npindexbw(formula = ..., method = "ichimura", data = mroz)
ich_fit <- npindex(bws = ich_bw)

# Marginal effects (all methods)
margins(probit_fit)           # Probit APE
predict(ks_fit, gradients = TRUE) # KS APE
```

R packages: np (Hayfield & Racine), wooldridge

总结与课程结束

三方法大对比：参数 / 非参数 / 半参数

	参数 (S1)	非参数 (S2)	半参数 (S3)
代表方法	Probit, Logit	核密度、NW、局部多项式	SIM, PLM, Ichimura, KS
$\hat{\beta}$ 速度	$\sqrt{n}$	—	$\sqrt{n}$ (多数) ; $n^{-1/3}$ (Manski)
$\hat{G}$ 速度	—	$n^{-2/(4+d)}$	$n^{-2/5}$ (一维 G)
对 G 假设	强 (已知形式)	无	中 (仅单指数结构)
错设风险	高	几乎无	中
推断难度	简单	中	中—难 (依方法而定)
样本要求	$n \geq 100$	$n \geq 1000$	$n \geq 200$

三方法的根本权衡：

- ▶ 参数：速度快、效率高；但脆弱（错设则不一致）
- ▶ 非参数：鲁棒；但维数诅咒严重
- ▶ 半参数：兼顾速度 ($\sqrt{n}$ on β) 与鲁棒性 (free G)


八种半参数估计量对比汇总

方法	速度	极限分布	异方差稳健	关键假设
Robinson PLM	$\sqrt{n}$	正态	部分	加法可分离
Ichimura SLS	$\sqrt{n}$	正态	部分	SIM, G 光滑
Klein-Spady	$\sqrt{n}$	正态	部分	SIM, 二元 Y, 效率界
PSS	$\sqrt{n}$	正态	部分	SIM, X 全连续
Han MRC	$\sqrt{n}$	正态	部分	单调性 (更弱)
Manski	$n^{-1/3}$	非正态	完全	中位数零
Horowitz	$n^{-2/5}$	正态	完全	中位数零 + 平滑
Lewbel	$\sqrt{n}$	正态	完全	特殊回归元

选择决策:

- ▶ 默认首选 **Klein-Spady** (效率最高)
- ▶ 怀疑异方差严重 $\Rightarrow$ **Lewbel** (若有 V) 或 **Horowitz**
- ▶ 仅需鲁棒性检验 $\Rightarrow$ **Ichimura** 或 **PSS**
- ▶ D 可能不光滑 $\Rightarrow$ **Han MRC**

速度—假设权衡可视化



两个核心趋势：

1. 从右到左（假设增强）：速度普遍提升
2. Manski → Horowitz → Lewbel：在中位数零假设下，通过平滑和特殊回归元逐步提升速度


计算复杂度对比

方法	单次评估	总成本	备注
Probit / Logit	$O(nk)$	$O(nkM)$	M: 迭代次数 ($\sim 5-10$)
PSS	$O(n^2k)$	$O(n^2k)$	一步式 (无迭代)
Ichimura / KS	$O(n^2)$	$O(n^2M)$	双层循环 + 优化
Han MRC	$O(n^2k)$	$O(n^2kM)$	排序对计算
Manski	$O(n^k)$	指数级	网格搜索; k 大时不可行
Horowitz	$O(nk)$	$O(nkM)$	类似 Probit
Lewbel	$O(n^2)$	$O(n^2)$	一次核 + OLS

计算实务建议:

- ▶ $n \leq 1000$: 所有方法可行
- ▶ $n = 10^4$ 至 10^5 : Manski 不可行; 其他可行 (GPU 加速可考虑)
- ▶ $n > 10^5$: Manski 完全不可行; Ichimura/KS 慢; 推荐 Probit 或 Lewbel
- ▶ 高维 X ($k > 20$): Manski 不可行; 其他需调优

方法选择决策树



常规研究流程：

1. 第一阶段：用 Probit / Logit 作基准
2. 第二阶段：用 KS 或 Ichimura 做稳健性检验
3. 第三阶段：若怀疑异方差，再加 Lewbel / Horowitz
4. 论文报告：所有方法的估计同时呈现

三讲专题回顾:

- ▶ **S1 (参数方法)**: Probit, Logit, IV Probit, RE Probit, Mundlak
- ▶ **S2 (非参数方法)**: 核密度估计、NW 回归、局部多项式、规格检验
- ▶ **S3 (半参数方法)**: SIM, Ichimura, KS, Manski, Horowitz, Lewbel, IPW

进一步阅读:

- ▶ **Hansen**, Econometrics, Princeton 2022, Ch.25
- ▶ **Li & Racine**, Nonparametric Econometrics, Princeton 2007
- ▶ **Horowitz**, Semiparametric and Nonparametric Methods in Econometrics, Springer 2009
- ▶ **Pagan & Ullah**, Nonparametric Econometrics, Cambridge 1999
- ▶ **周先波**, 《计量经济学——非参数估计及 GAUSS 应用》清华大学出版社 2017
- ▶ **Powell**, " Estimation of Semiparametric Models," in Handbook of Econometrics, Vol. IV, 1994

谢谢!

二元选择模型三讲 完

附录：理论证明

附录 C.1: 单指数模型识别证明

命题: 单指数模型 $\Pr(Y = 1 | X) = G(X'\beta_0)$ 的识别需要: 位置 + 尺度归一化 + 至少一个连续回归元 + G 非平凡。

证明:

- 1. 位置不可识别:** 若 X 含常数 1, 则 $G(X'\beta_0) = G^*(X'\beta_0 + c)$ 其中 $G^*(u) = G(u - c)$ 。 β_0 中的截距与 G 的“水平移动”不可区分。 $\Rightarrow$ 必须排除截距 (位置归一化)。
- 2. 展度不可识别:** 对任意 $c > 0$, $G(X'\beta_0) = G^{**}(X' \cdot c\beta_0)$ 其中 $G^{**}(u) = G(u/c)$ 。 β_0 与 $c\beta_0$ 给出相同条件分布。 $\Rightarrow$ 必须固定一个分量 (如 $\beta_{0,1} = 1$, 或 $\|\beta_0\| = 1$)。
- 3. 连续回归元的必要性:** 若所有 X_j 离散, $X'\beta$ 仅取有限值, $G(\cdot)$ 的可识别点集仅是有限集。则任意 β' 满足 “ G' 在 $X'\beta'$ 的取值集 = G 在 $X'\beta_0$ 的取值集” 都是观测等价的。 $\Rightarrow$ 需要至少一个连续 X_j 让 $X'\beta$ 跨连续区间。
- 4. G 非平凡:** 若 $G \equiv c$ 常数, 则任何 β 都给同样的 $\Pr(Y = 1 | X) = c$, β_0 不可识别。

□

▸ 返回正文

附录 C.2: Robinson PLM 渐近正态性证明 sketch

设定: $Y = X'\beta + g(Z) + u$, $\mathbb{E}[u | X, Z] = 0$. Robinson 估计量 $\hat{\beta} = [\sum_i \hat{X}_i \hat{X}_i']^{-1} \sum_i \hat{X}_i \hat{Y}_i$, 其中 $\hat{Y}_i = Y_i - \hat{\mathbb{E}}(Y | Z_i)$, $\hat{X}_i = X_i - \hat{\mathbb{E}}(X | Z_i)$.

核心分解:

$$\begin{aligned} \hat{\beta} - \beta &= \left[\sum_i \hat{X}_i \hat{X}_i' \right]^{-1} \sum_i \hat{X}_i \{ u_i - [\hat{\mathbb{E}}(Y | Z_i) - \mathbb{E}(Y | Z_i)] \\ &\quad + [\hat{\mathbb{E}}(X | Z_i) - \mathbb{E}(X | Z_i)]' \beta \}. \end{aligned}$$

三类项分析:

1. u_i 项: 均值零、与 $\hat{X}_i$ 渐近独立, 给出主项 $O_p(n^{-1/2})$
2. 非参估计偏误项: 用**高阶核** ($\nu \geq 2$) 使偏误降至 $O(h^{2\nu})$
3. 非参估计方差项: 经平均后降为 $O_p((nh^q)^{-1/2})$, 再 sum 后 $o_p(n^{-1/2})$

结论: $\sqrt{n}(\hat{\beta} - \beta) \rightarrow_d \mathcal{N}(0, \Phi^{-1} \Psi \Phi^{-1})$.

Robinson (1988) Econometrica $\square$

[返回正文](#)

附录 C.3: 高阶核降偏证明

命题: 对 ν 阶核 K (满足 $\int K(u)du = 1$, $\int u^j K(u)du = 0$ for $j = 1, \dots, \nu - 1$), 核回归偏误为 $O(h^\nu)$.

证明: 考虑核估计 $\hat{m}(z) = \sum_i K_h(Z_i - z)Y_i / \sum_i K_h(Z_i - z)$. 渐近偏误 (Taylor 展开):

$$\mathbb{E}[\hat{m}(z)] - m(z) = \int K_h(u - z)m(u)f(u) du / \mathbb{E}[K_h] - m(z).$$

在 $u = z + hv$ 替换变量:

$$= \int K(v)[m(z + hv)f(z + hv) - m(z)f(z)]dv / f(z).$$

Taylor 展开 $m(z + hv)f(z + hv)$ 到 ν 阶:

$$= \sum_{j=1}^{\nu-1} \frac{h^j}{j!} \int v^j K(v)dv \cdot [(mf)^{(j)}(z)/f(z)] + O(h^\nu).$$

对 ν 阶核, $\int v^j K(v)dv = 0$ for $j = 1, \dots, \nu - 1$, 所有低阶项消失:

$$\mathbb{E}[\hat{m}(z)] - m(z) = O(h^\nu). \quad \square$$

应用: $\nu = 2$ 给出标准核 (偏误 h^2); $\nu = 4$ 给出 $K_4(u) = (3 - u^2)/2 \cdot \phi(u)$ (偏误 h^4 , 可负权重)。

附录 C.5: Ichimura 一致性证明 sketch

命题: 在 (A1)-(A6) 下, $\hat{\beta}_{Ich} \xrightarrow{P} \beta_0$.

证明大纲 (Ichimura 1993 Theorem 5.1) :

1. 准则函数极限: 定义总体准则 $Q(\beta) = \mathbb{E}\{[Y - G(X'\beta_0)]^2\}$ (仅在 $\beta = \beta_0$ 处取最小)
2. 识别: Q 在 β_0 处唯一最小 (识别条件保证)
3. 一致性: $\sup_{\beta \in \Theta} |Q_n(\beta) - Q(\beta)| \xrightarrow{P} 0$ (核估计的一致收敛 + 紧集 Θ)
4. argmax 连续性: 上述两条件 + 紧性 $\Rightarrow \hat{\beta} = \arg \min Q_n \xrightarrow{P} \arg \min Q = \beta_0$

关键技术细节:

- ▶ 留一性确保 $\hat{G}_{-i}$ 与 u_i 渐近独立
- ▶ 修剪 A_n 防止边界发散
- ▶ 高阶核 + 带宽条件保证非参估计偏误降至 $o_p(1)$

□

▶ 返回正文

附录 C.6: Ichimura 渐近正态性证明 sketch

命题: $\sqrt{n}(\hat{\beta}_{\text{Ich}} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V^{-1}\Sigma V^{-1})$.

证明步骤:

1. 一阶条件: $\nabla_{\beta} Q_n(\hat{\beta}) = 0$

2. Taylor 展开于 β_0 :

$$0 = \nabla Q_n(\beta_0) + \nabla^2 Q_n(\tilde{\beta})(\hat{\beta} - \beta_0)$$

其中 $\tilde{\beta}$ 介于 β_0 与 $\hat{\beta}$ 之间

3. $\nabla Q_n(\beta_0)$ 渐近: 分解为

▶ 主项: $\frac{1}{n} \sum_i u_i \cdot G'(X_i' \beta_0) \tilde{X}_i \xrightarrow{d} \mathcal{N}(0, \Sigma)$ (CLT)

▶ 偏误项: $O(h^r) + O((nh^q)^{-1/2})$, 在带宽条件下为 $o_p(n^{-1/2})$

4. $\nabla^2 Q_n \rightarrow V$: 用 $\nabla \hat{G} \rightarrow G' \tilde{X}$ 与一致收敛

5. 结论: $\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} V^{-1} \cdot \mathcal{N}(0, \Sigma) = \mathcal{N}(0, V^{-1}\Sigma V^{-1})$

关键引理: $\nabla_{\beta} \hat{G}_{-i}(X_i' \beta_0; \beta_0) \xrightarrow{p} G'(X_i' \beta_0) \cdot \tilde{X}_i$, 其中 $\tilde{X}_i = X_i - \mathbb{E}[X | X' \beta_0]$ —— 这就是为什么渐近方差中出现 $\tilde{X} \tilde{X}'$ 而非 XX' . $\square$

▶ 返回正文

附录 C.7: Ichimura 渐近方差 V 、 Σ 推导

V 矩阵的来源: 对 $\nabla^2 Q(\beta_0)$ 的极限取期望。

$$\begin{aligned} V &= \mathbb{E}[\nabla^2(Y - G)^2/2] \big|_{\beta_0} \\ &= \mathbb{E}\{w(X)[G'(X'\beta_0)]^2 \cdot \tilde{X}\tilde{X}'\} \end{aligned}$$

其中 $\tilde{X} = X - \mathbb{E}[X | X'\beta_0]$, 来自 $\nabla \hat{G}_{-i}$ 极限的投影。

Σ 矩阵的来源: 对 $\sqrt{n}\nabla Q_n(\beta_0)$ 的方差取极限。

$$\begin{aligned} \Sigma &= \text{Var}[\sqrt{n}\nabla Q_n(\beta_0)] \\ &= \mathbb{E}\{w(X)^2 \sigma^2(X)[G'(X'\beta_0)]^2 \tilde{X}\tilde{X}'\} \end{aligned}$$

特殊情况:

- ▶ 同方差 ($\sigma^2(X) = \sigma^2$): $V^{-1}\Sigma V^{-1} = \sigma^2 V^{-1}$
- ▶ $w(X) = 1/\sigma^2(X)$ (最优权重): 得到**加权 SLS** (WSLS), 渐近方差最小化

核心几何观察: $\tilde{X}\tilde{X}'$ 是投影到正交于指数 $X'\beta_0$ 的子空间。沿指数方向的信息已被 $\hat{G}$ 吸收, β 仅由**正交方向**识别——这是半参数效率代价的几何意义。□

附录 C.8: PSS 渐近正态性证明 sketch

命题: $\sqrt{n}(\hat{\delta}_{\text{PSS}} - \delta_0) \xrightarrow{d} \mathcal{N}(0, \mathbf{V}_{\text{PSS}})$ 其中 $\delta_0 = \mathbb{E}[\nabla m(\mathbf{X})] = \mathbb{E}[\mathbf{G}'(\mathbf{X}'\beta_0)]\beta_0$.

证明步骤:

1. **分部积分恒等式:** 在边界正则条件下,

$$\delta_0 = -\mathbb{E}[\mathbf{Y} \cdot \nabla \log f_X(\mathbf{X})].$$

2. **PSS 估计量:** $\hat{\delta} = -\frac{1}{n} \sum_i \mathbf{Y}_i \cdot \widehat{\nabla \log f_X}(\mathbf{X}_i)$.

3. **分解:**

$$\hat{\delta} - \delta_0 = -\frac{1}{n} \sum_i [\mathbf{Y}_i (\nabla \log f_i) - \delta_0] + \text{核估计误差项}.$$

4. **主项渐近:** 标准 CLT 应用于第一项:

$$\sqrt{n} \cdot [\text{主项}] \xrightarrow{d} \mathcal{N}(0, \Sigma_1).$$

其中 $\Sigma_1 = \text{Var}[\mathbf{Y} \cdot \nabla \log f_X(\mathbf{X})]$.

5. **核估计误差项:** 用高阶核 + 适当带宽, $\widehat{\nabla \log f_X} - \nabla \log f_X = O_p((nh^k)^{-1/2}) + O(h^{r-1})$. 经平均后降为 $o_p(n^{-1/2})$.

6. **结论:** $\sqrt{n}(\hat{\delta} - \delta_0) \xrightarrow{d} \mathcal{N}(0, \mathbf{V}_{\text{PSS}})$.

附录 C.9: Klein-Spady 渐近正态性证明 sketch

命题: $\sqrt{n}(\hat{\beta}_{KS} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V_{KS}^*)$ 其中 V_{KS}^* 为半参数效率界。

证明大纲:

1. **KS 一阶条件** (半参数得分) :

$$\frac{1}{n} \sum_i \frac{Y_i - \hat{G}_{-i}(X_i' \hat{\beta})}{\hat{G}_{-i}(1 - \hat{G}_{-i})} \cdot \nabla_{\beta} \hat{G}_{-i} = 0.$$

2. **Taylor 展开于 β_0 :**

$$0 = \nabla \ell^{KS}(\beta_0) + \nabla^2 \ell^{KS}(\tilde{\beta})(\hat{\beta} - \beta_0).$$

3. $\nabla \ell^{KS}(\beta_0)$ **渐近**: 分解为:

- ▶ 主项: $\frac{1}{n} \sum_i s_i^* \xrightarrow{d} \mathcal{N}(0, I^*)$ 其中 s_i^* 是**半参数得分**
- ▶ 非参偏误: $o_p(n^{-1/2})$ (带宽条件保证)

4. $\nabla^2 \ell^{KS} \rightarrow -I^*$: 信息矩阵的负值

5. **结论:** $\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} (I^*)^{-1} \mathcal{N}(0, I^*) = \mathcal{N}(0, (I^*)^{-1})$

$V_{KS}^* = (I^*)^{-1}$ **即半参数效率界** (详见 C.9) 。 $\square$

▶ 返回正文

附录 C.10: Newey 1990 半参数效率界推导

命题: 对 $\sqrt{n}$ 一致正则估计量 $\hat{\beta}$,

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V) \Rightarrow V \succeq V_{KS}^* = (I^*)^{-1}.$$

证明大纲 (Newey 1990 Theorem) :

1. **切空间分解:** 模型 $\Pr(Y = 1 | X) = G(X'\beta)$ 的得分空间分解为:

- ▶ β 的得分子空间: $\mathcal{T}_\beta$
- ▶ G 的扰动得分子空间: $\mathcal{T}_G$

2. **半参数得分:** $s^*(\beta_0) =$ 参数得分 $-$ 它在 $\mathcal{T}_G$ 上的投影。

3. 具体形式:

$$s^*(\beta_0) = \frac{Y - G(X'\beta_0)}{G(1 - G)} \cdot G'(X'\beta_0) \cdot \tilde{X},$$

其中 $\tilde{X} = X - \mathbb{E}[X | X'\beta_0]$ 投影到 $\mathcal{T}_G^\perp$ 。

4. **效率界:**

$$V_{KS}^* = (\mathbb{E}[s^*(s^*)'])^{-1} = \left(\mathbb{E} \left[\frac{[G'(X'\beta_0)]^2}{G(1 - G)} \tilde{X}\tilde{X}' \right] \right)^{-1}.$$

5. **下界:** 所有正则 $\sqrt{n}$ 估计量满足 $V \succeq V_{KS}^*$ (Hájek 不等式)。

Newey (1990) JAE $\square$

▶ 返回正文

附录 C.11: KS 达到效率界证明

命题: $\sqrt{n}(\hat{\beta}_{KS} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V_{KS}^*)$ 即 $V_{KS} = V_{KS}^*$.

证明思路: KS 得分 $\rightarrow$ 半参数得分。

KS 一阶条件:

$$\frac{1}{n} \sum_i \frac{Y_i - \hat{G}_{-i}}{\hat{G}_{-i}(1 - \hat{G}_{-i})} \nabla_{\beta} \hat{G}_{-i} = 0.$$

$\nabla_{\beta} \hat{G}_{-i}$ 极限 (关键引理):

$$\nabla_{\beta} \hat{G}_{-i}(X_i' \beta_0; \beta_0) \xrightarrow{p} G'(X_i' \beta_0) \cdot \tilde{X}_i,$$

其中 $\tilde{X}_i = X_i - \mathbb{E}[X | X' \beta_0]$.

KS 得分极限:

$$\hat{s}_i^{KS} \rightarrow \frac{Y_i - G(X_i' \beta_0)}{G(1 - G)} \cdot G'(X_i' \beta_0) \cdot \tilde{X}_i = s_i^*.$$

这正是 Newey 1990 的半参数得分!

结论: KS 一阶条件渐近等价于半参数得分方程; $\hat{\beta}_{KS}$ 达到效率界 V_{KS}^* .

为什么 Ichimura 不达到效率界? Ichimura 一阶条件中没有 $1/[G(1 - G)]$ 因子 (似然权重)。缺少此权重 $\Rightarrow$ Ichimura 得分不等于半参数得分 $\Rightarrow$ 渐近方差严格大于 V_{KS}^* . $\square$

附录 C.12: Manski (1985) 强一致性证明 sketch

命题: 在 Manski 假设下, $\hat{\beta}_{MS} \xrightarrow{a.s.} \beta_0$.

证明大纲 (Manski 1985 Theorem 1) :

1. 总体得分函数:

$$S(\beta) := \mathbb{E}[(2Y - 1)\mathbf{1}\{X'\beta \geq 0\}].$$

2. S 在 β_0 唯一最大: 用中位数零假设 $\text{Med}(\varepsilon | X) = 0$ 证明。

- ▶ $\Pr(Y = 1 | X) > 1/2 \Leftrightarrow X'\beta_0 > 0$ (中位数预测)
- ▶ 因此 β_0 最大化 $\mathbb{E}[(2Y - 1)\mathbf{1}\{X'\beta \geq 0\}]$
- ▶ 唯一性需要识别条件 (连续 X 等)

3. 一致性: $\sup_{\beta \in \Theta} |S_n(\beta) - S(\beta)| \xrightarrow{a.s.} 0$ (Glivenko-Cantelli 定理)。

4. argmax 连续性: 紧集 + 一致收敛 $\Rightarrow \hat{\beta} = \arg \max S_n \xrightarrow{a.s.} \arg \max S = \beta_0$.

Manski (1985) JEcon $\square$

▶ 返回正文

附录 C.13: Kim-Pollard 立方根 n 速率证明 sketch

命题: $\hat{\beta}_{MS} - \beta_0 = O_p(n^{-1/3})$.

证明核心思路 (Kim & Pollard 1990) :

1. 重新参数化: $s = n^{1/3}(\beta - \beta_0)$, 定义

$$\tilde{S}_n(s) := n^{2/3}[S_n(\beta_0 + n^{-1/3}s) - S_n(\beta_0)].$$

2. 有限维分布: $\tilde{S}_n(s) \xrightarrow{d} Z(s) - \frac{1}{2}s'V_0s$, 其中 $Z(s)$ 是均值零高斯过程。

3. 紧性: 用经验过程论的 **弦不等式 (chaining)** 证明 $\tilde{S}_n$ 的紧性。

4. **曲率与经验波动**: $S_\infty(\beta) - S_\infty(\beta_0) \sim -c\|\beta - \beta_0\|^2$ (二次下降, 曲率正常)。但 $S_n - S_\infty$ 在 $\|\beta - \beta_0\| \leq \delta$ 球内的上确界是 $O_p(n^{-1/2}\sqrt{\delta})$ (注意根号 δ !) —— 这是 $1\{\cdot\}$ 阶跃函数族的 **bracketing entropy** 性质。

5. **平衡**: 让二次下降 $-c\delta^2$ 与经验波动 $n^{-1/2}\sqrt{\delta}$ 同阶, $c\delta^2 \sim n^{-1/2}\sqrt{\delta}$, 解出 $\delta \sim n^{-1/3}$ 。

结论: $\hat{\beta} - \beta_0 = O_p(n^{-1/3})$. Kim & Pollard (1990) Annals $\square$

► 返回正文

附录 C.14: Manski 极限分布 (布朗运动 argmax)

命题: $n^{1/3}(\hat{\beta}_{MS} - \beta_0) \xrightarrow{d} \arg \max_s \{Z(s) - \frac{1}{2}s'V_0s\}.$

证明大纲:

1. 由 C.12 的紧性 + 有限维分布收敛, $\tilde{S}_n(\cdot) \xrightarrow{d} \tilde{S}_\infty(s) := Z(s) - \frac{1}{2}s'V_0s$ 在 Skorohod 拓扑下。
2. 由 **argmax 连续映射定理** (continuous mapping theorem for argmax) :

$$n^{1/3}(\hat{\beta} - \beta_0) = \arg \max_s \tilde{S}_n(s) \xrightarrow{d} \arg \max_s \tilde{S}_\infty(s).$$

3. 极限 $\arg \max_s \{Z(s) - \frac{1}{2}s'V_0s\}$ 是 **Brownian motion** 类过程的 argmax, **无封闭形式分布**。
 $Z(s)$ 与 V_0 的具体形式:

$$Z(s) \sim \text{均值零高斯过程, 协方差 } H(s, s'),$$
$$V_0 = \mathbb{E}[f_{\varepsilon|X}(0 | X)XX' \cdot \mathbf{1}\{X'\beta_0 = 0\}].$$

推断的实际困难:

- ▶ 标准 bootstrap **不一致** (Abrevaya-Huang 2005)
- ▶ 需用 subsampling 或 m-out-of-n bootstrap
- ▶ 置信区间通常不规则

□

▶ 返回正文

附录 C.15: Horowitz $n^{2/5}$ 速度证明 sketch

命题: $\hat{\beta}_H - \beta_0 = O_p(n^{-r/(2r+1)})$, 其中 r 为核 $\tilde{K}$ 的阶。 $r = 2$ 给出 $n^{-2/5}$.

证明大纲 (Horowitz 1992 Theorem 1) :

1. Horowitz 目标函数: $\hat{S}_n(\beta; h) = \frac{1}{n} \sum_i (2Y_i - 1) \tilde{K}(X_i' \beta / h)$.
2. Horowitz 准则函数现在**光滑** (与 Manski 不同) 。一阶条件:

$$\nabla_{\beta} \hat{S}_n(\hat{\beta}; h) = \frac{1}{nh} \sum_i (2Y_i - 1) \tilde{K}'(X_i' \beta / h) X_i = 0.$$

3. Taylor 展开 + 偏误—方差分解:

$$\mathbb{E}[\nabla \hat{S}_n(\beta_0)] = O(h^r) \quad (\text{核偏误})$$

$$\text{Var}[\nabla \hat{S}_n(\beta_0)] = O(1/(nh))$$

4. 平衡: 选 $h \sim n^{-1/(2r+1)}$ 使两者平衡:

▶ 偏误: $h^r \sim n^{-r/(2r+1)}$

▶ 标准差: $1/\sqrt{nh} \sim n^{-r/(2r+1)}$

5. 结论: $\hat{\beta} - \beta_0 = O_p(n^{-r/(2r+1)})$. $\square$

Horowitz (1992) Econometrica

▶ 返回正文

附录 C.16: Horowitz 渐近正态性证明 sketch

命题: $n^{r/(2r+1)}(\hat{\beta}_H - \beta_0) \xrightarrow{d} \mathcal{N}(\mu_0, V_H)$.

证明大纲:

1. 平滑性使 Taylor 展开有效: $0 = \nabla \hat{S}_n(\beta_0) + \nabla^2 \hat{S}_n(\tilde{\beta})(\hat{\beta} - \beta_0)$.
2. $\nabla \hat{S}_n(\beta_0)$ 渐近: CLT 应用得

$$\sqrt{nh^{2r+1}} \cdot \nabla \hat{S}_n(\beta_0) \xrightarrow{d} \mathcal{N}(\mu_0, \Sigma_H).$$

3. $\nabla^2 \hat{S}_n \rightarrow V_H$: 在带宽条件下一致收敛。
4. 合并:

$$n^{r/(2r+1)}(\hat{\beta} - \beta_0) \xrightarrow{d} V_H^{-1} \mathcal{N}(\mu_0, \Sigma_H).$$

5. 偏误处理:

- ▶ 用高阶核 ($r \geq 4$) 使 $\mu_0 \rightarrow 0$
- ▶ 用欠平滑 (h 略小于 h^*) 使偏误衰减更快

核心创新: 与 Manski (极限非正态) 不同, Horowitz 通过平滑恢复 Taylor 展开 + 标准 CLT 框架, 极限分布回归正态。□

▶ 返回正文

附录 C.17: Horowitz 高阶 Edgeworth 展开

动机：高阶展开揭示偏误的精确形式与置信区间精度。

Edgeworth 展开 (Horowitz 1992 §4) :

$$\Pr(n^{r/(2r+1)}(\hat{\beta}_H - \beta_0) \leq t) = \Phi(t/\sqrt{V_H}) + n^{-r/(2r+1)} \cdot p_1(t)\phi(t/\sqrt{V_H}) + \dots$$

其中 $p_1(\cdot)$ 是修正多项式, 依赖 $\tilde{K}$ 的高阶矩与 G'' .

展开的两个用途:

1. 偏误估计: $\mu_0 = \text{Edgeworth 展开的二阶项} \Rightarrow \text{可估计与修正}$
2. 置信区间精度: 标准 CLT 给出 $O(n^{-r/(2r+1)})$ 精度; Edgeworth 修正给出 $O(n^{-2r/(2r+1)})$ 精度

为什么需要欠平滑? 带宽 $h^* \sim n^{-1/(2r+1)}$ 给出最优速率, 但偏误 μ_0 出现在极限。 $h_{\text{undersmooth}} = o(h^*)$ 使偏误衰减更快, 极限分布以 $\mathcal{N}(0, V_H)$ 而非 $\mathcal{N}(\mu_0, V_H)$ 出现。 Edgeworth 展开量化此 trade-off. $\square$

▶ 返回正文

附录 C.18: Lewbel 渐近正态性证明 sketch

命题: $\sqrt{n}(\hat{\beta}_{\text{Lewbel}} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V_{\text{Lewbel}})$.

证明大纲 (Lewbel 2000 Theorem 1) :

1. **Lewbel 关键恒等式** (在特殊回归元假设下) :

$$T_i := \frac{Y_i - \mathbf{1}\{V_i \geq 0\}}{f_V(V_i | X_{1i})}, \quad \mathbb{E}[T_i | X_{1i}] = X'_{1i}\beta_0.$$

2. **两步估计:**

2.1 核估计 $\hat{f}_V(V_i | X_{1i})$

2.2 OLS: $\hat{T}_i$ 对 X_{1i} 回归 $\Rightarrow \hat{\beta} = (\sum X_1 X'_1)^{-1} \sum X_1 \hat{T}_i$

3. **分解:**

$$\hat{\beta} - \beta_0 = (\sum X_1 X'_1)^{-1} \sum X_1 [T_i - X'_1 \beta_0 + (\hat{T}_i - T_i)].$$

4. $T_i - X'_1 \beta_0$ **项:** 标准 OLS CLT $\Rightarrow O_p(n^{-1/2})$.

5. $\hat{T}_i - T_i$ **项** (核估计误差) : 用高阶核 + 适当带宽, $\hat{f}_V - f_V = O_p((nh)^{-1/2}) + O(h^r)$. 经平均后降为 $o_p(n^{-1/2})$.

6. **结论:** $\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} \mathcal{N}(0, V_{\text{Lewbel}})$ 其中

$$V_{\text{Lewbel}} = \mathbb{E}[X_1 X'_1]^{-1} \cdot \mathbb{E}[X_1 X'_1 \cdot \text{Var}(T | X_1)] \cdot \mathbb{E}[X_1 X'_1]^{-1}.$$